

SURVEY

用於 COVID-19 相關 Twitter 數據情緒分析的機器學習技術

NIKLAS BRAIG、ALINA BENZ、SOEREN VOTH、JOHANNES BREITENBACH 和 RICARDO BUETTNER, (IEEE 高級會員)

¹ 拜羅伊特大學資訊系統與資料科學系主任，95447 拜羅伊特，德國 2Fraunhofer FIT，95444 拜羅伊特，德國

通訊作者：Johannes Breitenbach (johannes.breitenbach@uni-bayreuth.de)

這項工作部分得到了 491183248 Deutsche Forschungsgemeinschaft (DFG, 德國研究基金會) 的資助，部分是聯邦經濟事務和氣候行動部 [Bundesministerium für Wirtschaft und Klimaschutz (BMWK)]，資助 16KN088849，部分是拜羅伊特大學的開放獲取中斷基金。

摘要 在 Twitter 上，COVID-19 是一個備受討論的話題。在大流行期間，世界各地的人們都使用 Twitter 表達他們的觀點和感受。先前的研究主要集中在特定主題上，例如封鎖期間公眾的情緒、他們對政府措施的看法或他們對 COVID-19 疫苗的立場。然而，直到今天，還沒有全面的概述來介紹 COVID-19 Twitter 數據情緒分析的可能應用領域。因此，本研究揭示了情緒分析如何通過應用行為和社會科學的視角為管理大流行提供相關見解。在此背景下，我們的系統文獻綜述側重於基於機器學習的情緒分析技術，並比較了 COVID-19 相關 Twitter 數據表現最佳的分類算法。我們在五個資料庫中進行了搜索，分別是：IEEE Xplore DL、ScienceDirect、SpringerLink、ACM DL 和 AIS 電子圖書館。這項搜尋產生了 2019 年 10 月至 2022 年 1 月期間發表的 40 篇論文，這些論文使用情緒分析來評估公眾對 COVID-19 相關主題的看法，我們對此進行了進一步調查。我們的研究表明，就準確性而言，表現最好的模型是包含各種機器學習分類器的集成模型。尤其是 BERT 和 RoBERTa 模型在對 Twitter 數據進行微調時提供了最有希望的結果。我們的研究旨在結合基於機器學習的情緒分析與社會和行為科學的見解，為決策者和公共衛生專家提供情緒分析在對抗 COVID-19 傳播中的應用指導。

索引術語 行為科學、COVID-19、深度學習、機器學習、情緒分析、社會科學、推特。

一、簡介

來自不同學科的研究人員急於提供解決方案，以減輕 COVID-19 大流行的影響，迄今為止，COVID-19 大流行已奪走超過五百萬人的生命 [1], [2]。自 COVID-19 爆發以來，社交媒體已成為與家人、朋友和同事保持聯繫的關鍵，也是保持信息靈通和討論新政策更新和法規的關鍵 [3]。政府和其他組織，例如世界

衛生組織 (WHO) 已使用社交媒體作為傳播信息和管理危機的直接溝通渠道 [4]、[5]。直到今天，COVID-19 仍然是 Twitter 上討論最多的話題之一。僅在 2020 年 1 月至 5 月期間，Twitter 上就發布了超過 120,000,000,000 條與 COVID-19 相關的消息 [6]。大量未經過濾的 Twitter 數據為公共衛生研究提供了充滿希望的機會 [7]。此外，與其他社交媒體平台相比，它通過 Twitter API 進行的簡單訪問使其成為研究人員的首選平台 [8]、[9]、[10]。擷取和分析大型的常用方法

協調這份手稿的審查並批准其出版的副主編是德里克·阿博特 (Derek Abbott)。

大量模糊的用戶生成數據稱為情感分析 [11]。特別是在 COVID-19 的背景下，先前的研究表明，情緒分析可以透過多種方式支持政府和衛生當局對抗 COVID-19：Twitter 用戶的「數位足跡」提供了對他們情緒和行為狀態的洞察，因此，可以揭示有關公眾對遏制措施的接受程度、疫苗準備情況或對政府的信任的相關資訊。特別是，疫苗猶豫是對公共衛生運動成功的重大威脅。先前的研究表明，情緒分析提供了一個強大的工具，可以在 Twitter 上即時研究導致疫苗猶豫的擔憂和情緒 [12]。這些見解可用於調整溝通策略並制定更多以目標為導向的政策措施，旨在刺激疫苗接種 [12]、[13]、[14]。此外，它還允許識別和監控趨勢和錯誤信息 [15]。上個世紀的研究強調，管理大流行需要實質性的行為改變——至少不是因為適應了身體距離規則 [1]。因此，社會和行為科學研究可以為有效應對 COVID-19 提供寶貴的見解，同時最大限度地減少心理困擾。先前的研究已經將著名的社會和行為理論 [16]、[17]、[18] 與情感分析領域 [19]、[20]、[21] 相結合。在這項研究中，我們從社會和行為科學的角度全面概述了 COVID-19 相關 Twitter 數據背景下可能的情緒分析應用。透過利用與管理 COVID-19 大流行相關的主題 [1]，我們注意到情緒分析如何透過深入了解公眾的思維、感受和行為來產生堅實的數據基礎，從而做出明智的決策。由於機器學習 (ML) 分類器在對推文進行分類方面越來越受歡迎 [22]、[23]，因此我們的主要關注點在於用於情緒分類的 ML 演算法。因此，我們通過綜合行為和社會科學以及情感分析的文獻來擴展當前的文獻。我們的目標是研究如何在 COVID-19 的背景下應用情緒分析，以及哪些 ML 分類器提供最有希望的結果。我們使用 van Bavel 等人提出的起源於行為理論的類別 (圖 6) [1] 作為指導，為政府和公共衛生專家提供一本手冊，以利用數據和機器學習的力量來管理大流行。據我們所知，不存在這樣的文獻綜述。現有文獻綜述側重於 COVID-19 早期階段的多種疾病 [24]，調查不同的社交媒體平台，或具有單一關注點，例如疫苗接種 [25]、[26]。我們更大程度地研究了用於情緒分析的分類技術，從而旨在加速開發新的更好的方法，以支持政府和衛生當局日常對抗 COVID-19。在臉上




圖 1. 對 COVID-19 相關推文的情緒分析可以為有效管理大流行及其影響提供相關見解。

考慮到 Twitter 數據的新見解，可能會改變當前大流行和未來公共衛生危機的進程。本文獻綜述的組織如下：在第二節中，我們介紹了我們的研究方法。第三節包括對情緒分析的簡要介紹以及用於 Twitter 數據情緒分析的技術。第四節從社會和行為科學的角度以及技術角度介紹了我們的發現。在第五節中，詳細討論了上一節的結果。第六節總結了我們的主要發現，重申了當前對 COVID-19 相關 Twitter 數據進行情緒分析的挑戰和局限性，並對未來的研究方向提出了建議。

二、方法

對 COVID-19 相關 Twitter 數據的情緒分析的研究廣泛分散，主要集中在感興趣的特定主題上。本研究應用系統文獻綜述的技術來概述 COVID-19 相關 Twitter 數據情感分析的可能應用領域。由於大流行的管理需要政府和衛生當局以某種方式影響公眾的行為以遏制冠狀病毒的傳播，因此我們應用了社會和行為科學的視角。除了社會和行為的角度，



圖 2. 根據 van Bavel 等人的說法，從社會和行為科學的角度管理 COVID-19 大流行的相關主題。

特別關注分類技術，例如所使用的演算法、特徵提取方法和資料集。我們遵循了本研究的系統評價和薈萃分析首選報告項目 (PRISMA) 指南。該方法最初是為健康科學開發的，因此非常適合我們的研究主題。由於其結構化的應用，它被許多其他領域用於回顧現有文獻。根據 PRISMA 指南，研究的整體選擇過程可分為四個步驟：識別、篩選、資格和納入。在前兩個步驟中，我們在五個數據庫中搜索了文獻，這些文獻將在以下小節中進一步描述，並根據我們的納入標準評估了我們的搜索命中率。在資格步驟中，每篇文章都使用全文搜尋進行評估。如果一篇文章符合我們的收錄標準，它就會被納入審查，從而轉發到收錄步驟 [27]、[28]。這四個階段將在後續段落和圖 3 中更詳細地描述。

A. 資料庫

為了收集文獻供我們審查，我們在五個學術知名數據庫中進行了搜索，這些數據庫因其科學認可和對此類研究的適用性而被選中：1) IEEE Xplore DL、2) ScienceDirect、3) SpringerLink、4) ACM DL 和 (5) AIS 電子圖書館。

B. 搜尋策略

我們的搜尋字詞是在迭代過程中開發的。它包括與我們的研究問題相關的關鍵字以及 van Bavel 等人的基本框架 [1]。搜索字符串可以分為四個集群，這些集群導致我們的文獻綜述的相關搜索命中。第一個

表 1. IEEE Xplore DL 中的搜尋字串驗證。

Cluster 1	Cluster 2	Cluster 3	Cluster 4	Outcome
("Sentiment Analysis" OR "Opinion Analysis" OR "Opinion Mining")	("Twitter" OR "Tweet*")	("Machine Learning" OR "NLP" OR "ML" OR "Deep Learning" OR "Natural Language Processing" OR "DL")	("COVID-19" OR "Pan-demic" OR "Corona")	Conferences: 62, Journals: 9, Early Access Articles: 4

與情緒分析領域相關並捕獲其同義詞，例如「意見分析」和「意見挖掘」。為了得出相關的同義詞，我們借鑒了 Maentylae 等人 [29]、Cambria 等人 [30] 和 Alamoodi 等人 [24] 的研究。第二個集群旨在僅捕獲基於 Twitter 數據或所謂的 Twitter「推文」的研究論文。集群三的設置方式包括屬於機器學習或深度學習範圍的文獻的特定技術特徵。通過比較相關文獻並仔細檢查我們在每個數據庫中的搜索命中，我們逐漸細化和優化了我們的搜索字符串 [31]、[32]。

我們發現機器學習 ("ML") 和深度學習 ("DL") 的縮寫沒有提供額外的相關搜索命中，因此被排除在外——如表 1 中的紅色所示。僅包含提供其他相關搜尋結果的個別關鍵字。對於我們捕獲與 COVID-19 大流行相關的文獻的最後一個集群，我們使用 Yousefinaghani 等人 [12] 研究的關鍵詞作為指導，並進一步考慮了 van Bavel 等人 [1] 強調的「大流行」一詞。

表 1 顯示了 IEEE Xplore DL 資料庫的範例流程。以綠色顯示的字詞對於產生搜尋命中很重要，因此包含在最終搜尋字符串中。以紅色表示的術語不會導致其他相關搜索結果，因此被排除在搜索字符串之外。在我們的搜尋查詢中，各個關鍵字與布林運算子 AND 或 OR 連接。

我們使用以下關鍵字搜尋了所有五個資料庫，分為四個主要集群：（情緒分析」或「意見分析」或「意見挖掘」）和（「Twitter」或「推文*」）和（機器學習」或「深度學習」或「自然語言處理」或「NLP」）和（「COVID-19」或「大流行」）

由於 ScienceDirect 的搜索限制，搜索字符串略有調整，如附錄 D 所示。

C. 納入和排除標準

為了選擇最相關的條目，我們應用了特定的包含和排除標準。首先，要涵蓋

COVID-19 大流行期間，研究的發表日期必須在 2019 年 10 月 1 日至 2022 年 1 月 31 日之間（最近）。其次，我們包括期刊預校樣。第三，僅考慮五個選定的英文數據庫中經過國際同行評審的期刊文章。其他類型的出版物，例如數據集或文獻綜述，不包括在內。

D. 具體選擇標準

進一步的標準涉及特定於內容的屬性：只有應用（1）情感分析方法、（2）使用 Twitter 數據集以及（3）分析與 COVID-19 相關主題的文章才被納入我們的文獻綜述。關於相關性，主題過於狹窄、特定領域或與我們的審查無關的研究論文被排除在外。

E. 研究選擇

通過遵循我們根據 PRISMA 指南的搜索策略，第一次文章搜索產生了 425 篇文章。我們收到以下按所選資料庫排序的搜尋結果：（1）IEEE Xplore DL：9 篇文章，（2）ScienceDirect：234 篇文章，（3）SpringerLink：153 篇文章，（4）ACM DL：18 篇文章，（5）AIS 電子圖書館：11 篇文章。

ScienceDirect 搜索中的一項研究被排除在外，因為它是重複的。我們仔細審查了所有檢索到的出版物的列表，並僅包括那些符合我們納入標準的出版物。在最初的 425 篇文章中，有 47 篇文章因我們的排除標準而被排除在外，導致 378 篇文章被轉發進行篩選。三位作者根據前面說明的資格標準詳細篩選了研究的標題、關鍵詞和摘要。如果作者對文章的刪除或包含意見存在分歧，則會檢查整篇論文。在對研究進行深入篩選後，確定了 40 篇文章與回答我們的研究問題相關。

識別過程基於三位審稿人的討論，審稿人間的可靠性為 92%。在審查文章後評估了可靠性。可靠性是 309 篇一致拒絕的文章和 38 篇接受的文章的總和除以審查的 378 篇文章總數。

圖 3 說明了我們的文獻檢索方法。

F. 數據提取

所有三位研究人員都從收錄的期刊文章中徹底提取了相關數據。一致認為，我們確定了將根據我們的研究目的進行分析的一組特徵。提取一般特徵，例如標題、作者、出版年份、出版期刊和關鍵字（作者）。

我們分析的主要部分涉及納入研究的方法學方面。這包括有關 Twitter 數據集的時間段、其語言、訓練和評估數據集的推文數量、分類算法及其準確性和特徵的信息。此外，所有研究都針對各自進行了篩選




圖 3. PRISMA 流程圖說明了我們識別合適文獻的過程 [27]。

表 2. 從所收錄文獻中提取的元素。

Data item	Description
General characteristics	Title, authors, publication year, journal and keywords (author)
ML algorithm	Used sentiment analysis method in the research
Dataset	Origin, sample size, time period, language, hashtags
Performance Parameters	Accuracy/recall/precision/F1-Score to compare different approaches
Use-cases	Possible application areas
Research focus	Research foundation and research gap

應用領域。表 2 提供了分析特徵的詳細集合。

三、TWITTER 情緒分析的基礎

A. 推特和 COVID-19

Twitter 是一個微博平台，人們可以透過短訊息（即所謂的“推文”）表達自己的感受、情緒和意見，最多可包含 280 個字元。每天，全球用戶在 Twitter 上發布了超過 5 億條消息。這使得信息能夠在全球範圍內實時傳播，並在龐大、多樣化的用戶群中傳播 [33]。從國家領導人到科學家和醫療保健組織，Twitter 已成為傳達政策更新和資訊的重要媒介 [34]。疫情期間最活躍的帳戶之一是世界衛生組織（Twitter：@WHO）的帳戶 [5]。Twitter 已成為公民分享意見和討論大流行相關資訊的首選平台。

在最初的 90 天裡，用戶已經發布了超過 520,000,000,000 條帶有 COVID-19 相關主題標籤的推文。這代表每天大約有八百萬條推文 [35]。近年來，微博網絡已發展成為公共衛生研究和監測的重要支柱 [3]、[7]。研究表明，分析 Twitter 消息有助於識別、監測或預測疾病 [36]。由於與其他平台相比，其訪問並不複雜，該領域的大多數研究都是基於 Twitter 數據 [8]。作為最大且開放可用的資料庫之一，研究人員可以使用 Twitter API 根據關鍵字和主題標籤選擇和下載特定資料。有無數與 COVID-19 相關的推文，從內容豐富、鼓舞士氣的言論到充滿情緒的觀點。使用 COVID-19 主題標籤 (#COVID-19) 的幾個示例是：

「今天早上，我的 COVID-19 檢測呈陽性。我感覺很好——本週我將繼續遠程工作，同時遵守公共衛生準則。大家，請留意！」

接種疫苗並加強接種。

「紐西蘭重新進入封鎖狀態，因為有四個人感染了 Covid 19。自從我不知道，可能是上週以來人類歷史上最大的過度反應。我正在輸現在跟踪。」

「我的叔叔昨天死於 COVID-19。在過去的三個月裡，我一直在懇求他接種疫苗。他拒絕了，因為 WhatsApp 和 FB 大學捏造了恐懼。病毒可能殺死了他，但事實確實如此。」

導致他死亡的虛假信息。

B. 推特情緒分析

情感分析是指用於自動提取和分析文本中情感的技術和方法。基本上，語言主要可以傳達兩種類型的信息：一種是事實的客觀信息，另一種是主觀的、充滿情感的信息 [37]。後者可以包括各種人類情緒，從意見或評估到觀點、態度和情緒 [38]。情感分析的大量研究都集中在極性分類上 [30]。情緒可以分為二元（正面或負面）或三向（正面、負面或中性）[33]。除了檢測極性外，情感分析還可用於檢測和建模情感主題、觀點、情緒以及社會或政治取向。情感分析和意見挖掘（OM）在文獻中通常互換使用 [11]。情感可以主要在三個層面上進行分析：文檔、句子和方面（實體）層面。在文件層級，將文字的情緒作為一個整體進行分析。在句子層面，每個句子的極性都會被評估並相應地分類。此外，在方面水平上，識別特定對象（實體）的極性 [39]。Twitter 上的情緒分析，也稱為 Twitter 情緒分析，是情緒分析的一個專門子領域 [33]。由於推文長度有限

文件和句子級別之間沒有實質區別。因此，對於 Twitter 情緒分析，分析可以應用於句子（此處：推文/消息）級別或實體級別 [23]。在 Twitter 上識別情緒並非沒有挑戰：與其他類型的文本（例如博客文章或論壇）相比，Twitter 消息包含各種語言特殊性，例如非正式的寫作風格和長度限制 [33]。

C. 情緒分析技術概述

情感分類主要有三種技術：基於詞典（基於知識）、機器學習（統計方法）和混合方法 [40]。基於詞典的方法根據文本中存在的單詞的單獨極性來確定文本的極性 [40]。這些方法依賴於字典，例如 WordNet [41]，其中包含大量單詞語料庫的極性值 [40]。文本的整體極性可以通過將各個極性分數相加來計算 [42]。例如，如果文本中包含的積極詞多於消極詞，則整體極性為正 [43]。如果文本包含等量的正面和負面詞，則整體情緒是中性的 [44]。這種方法的主要優點是不需要標記的訓練數據，並且可以輕鬆適應不同的語言 [42]。這種方法被認為是一種無監督學習方法 [42]。詞典方法的效能主要取決於詞典資源的品質。基於詞彙的方法在很大程度上是特定領域的，這意味著單詞根據其上下文具有不同的含義 [43]。一個缺點是他們無法處理自然語言文本中普遍存在的語義規則和語言特殊性，例如否定、俚語或諷刺 [40]。

ML 分類技術用於情緒分析，越來越受歡迎 [22]、[23]。機器學習方法可以區分監督方法和無監督方法；然而，監督方法最常用於 Twitter 情緒分析 [23]，因此如下圖所示。如前所述，基於機器學習的方法需要包含標記情緒類的訓練資料集 [44]。在這些訓練資料集上，分類模型會經過訓練和最佳化。機器學習模型根據自然語言文本的特徵表示來量化自然語言文本，並根據其特徵值預測文本的極性 [33]。它們的性能取決於所選特徵對文本的分類程度 [45]。典型功能是字包（BOW）方法，例如術語頻率逆文件頻率（TF-IDF）或 n-gram，以及單詞嵌入，例如 Word2Vec 或 GloVe。Word2Vec 和 GloVe 是預先訓練的無監督模型，它們創建了一個具有相似單詞簇的向量 [43]、[46]。學習資料集通常包含非結構化數據，即所謂的“噪音”，例如主題標籤、縮寫、停用詞、結構不良的句子、拼字錯誤、標點符號或非字典單字

可能會損害性能 [47]。因此，在特徵提取之前，需要一個數據預處理步驟，這主要是通過應用自然語言處理（NLP）技術來完成的。預處理可以分為歸一化、標記化和降噪。例如，降噪步驟可以包括替換負面提及、刪除 URL、刪除大寫或用非縮寫形式替換首字母縮略詞。這確保了僅提取相關特徵 [48]。為了標準化資料集，經常使用詞幹提取和詞形還原化。透過這些歸一化演算法，單字被轉換為沒有前綴或後綴的標準形式，以便能夠識別具有相似含義的相同單字 [49]。權杖化會將文字分割成一系列權杖，使其可用於 ML 分類器模型。然後，記號由 BOW 表示法定義。也可以選擇 N-gram 作為標記化方法 [50]。在預處理階段，每個步驟的順序很重要。根據分類器的不同，不同的預處理步驟和組合會產生不同的結果 [51]。

ML 方法的一個主要缺點是所需標記資料集的可用性有限。為了使 ML 分類模型正常運作，通常需要大型資料集來最佳化模型參數。因此，性能通常與標記訓練數據的可用性有關，而對於新主題來說並不常見 [23]。基於 ML 的情感分析模型很容易適應某個領域或可用於特定目的 [45]。同時，網域依賴性是它們的主要限制之一。當模型應用於與訓練資料（類似領域）相似的資料時，模型表現良好；不過，當套用至不相關的網域時，其效能會降低。這意味著當域發生變化時，必須重新訓練分類器 [45]。最常用的分類器是：樸素貝葉斯（NB）[52]、最大熵（ME）[53]、支持向量機（SVM）[54]、邏輯回歸（LR）和隨機森林（RF）[23]、[55]。情感分析分類器的效能通常在實驗環境中進行評估。常用的指標是準確度、精密度、召回率和 F1 分數 [56]。準確度表示正確預測與預測總數之間的關係。正確的預測由真陽性和真陰性組成。準確度、召回率、精確度和 F1 分數的方程是根據 Skolova 和 Lapalme [57] 假設的。

$$\text{準確度} = \frac{\text{正確預測數}}{\text{預測總數}} \quad (1)$$

$$\text{召回} = \frac{\text{真陽性}}{\text{真陽性} + \text{假陰性}} \quad (2)$$

$$\text{精度} = \frac{\text{真陽性}}{\text{真陽性} + \text{假陽性}} \quad (3)$$

$$\text{F1 分數} = \frac{2 \times \text{精確度} \times \text{召回率}}{\text{精確度} + \text{召回率}} \quad (4)$$

為了平衡基於詞典的方法和機器學習方法的缺點，提出了所謂的混合方法。

混合方法結合了基於詞典和基於機器學習的方法。

D. 用於 TWITTER 情緒分析的監督機器學習技術

1) 傳統機器學習分類器

監督式機器學習技術的一個特點是它們依賴於標記的先驗資料。傳統的 ML 技術要求領域專家選擇應用的功能，以降低演算法的複雜性。最常用的傳統 ML 演算法之一是 NB 演算法，它是一種機率分類器。該技術基於這樣一種假設，即類別中的某個特徵獨立於其他特徵的出現。該方法需要預先分配標籤 [43]。使用條件機率和貝葉斯定理，計算類別的後驗機率，即所選特徵屬於某個類別。該模型因其計算速度和實施簡單性而適用於大型資料集 [46]。此 ML 模型在類別資料上顯示出比數值資料更好的效能。SVM 旨在找到不同類別之間的最佳邊界。當各個類別之間的距離最大化時，可以實現理想的分離。SVM 會建立一組超平面，並針對分類程序使用線性迴歸。最好的分隔符是與其他類別的距離最大的分隔符 [58]。這些方法需要訓練數據，對於半結構化或非結構化數據非常有效 [46]，適用於 Twitter 情緒分析 [58]。效能會隨著「嘈雜」資料的出現而降低。這種方法的一個缺點是大量資料集需要較長的訓練時間 [43]。除了 SVM 之外，另一個廣泛使用的分類器是 RF 演算法。RF 由一組單獨的樹預測器組成，這些預測器作為一個整體組合運行。收集每棵樹的預測，並通過應用多數投票，獲得最多票數的類別決定分類 [55]。

2) 深度學習分類器

深度學習（DL）是機器學習的一個子領域，它模仿人腦的學習過程 [59]。最初的想法可以追溯到神經網路的概念：透過經驗，可以調整大腦中子連接的組成和強度 [60]。在過去的幾年裡，它已成為機器學習的“黃金標準”，在各種認知任務上實現了尖端性能 [61]。DL 在許多應用領域（例如 NLP）中優於流行的傳統 ML 技術 [61]。通過使用人工神經網路和多層活動向量，可以學習發現新的表示 [62]。對於每個抽象級別，通過應用非線性轉換，特定表示被提升到更抽象的水平。此機制允許篩選分類任務的相關輸入或特徵。層的層次反映了網路的深度。相比之下

對於層數較少的模型，DL 模型由大量的神經元和處理層組成。DL 模型可以通過應用反向傳播算法從非結構化和未標記的數據中檢測結構 [63]。深度學習模型的另一個優點是它們不依賴手動設計的特徵提取，因為可以自動提取理想的特徵 [63]。因此，它們不需要領域專家的知識。DL 中最常用的技術是卷積神經網路（CNN）、循環神經網路（RNN）、長短期記憶（LSTM）和來自 Transformers 的雙向編碼器表示（BERT）。CNN 是一個前饋網絡，其靈感來自視覺感知機制。CNN 多層架構旨在降低一般前饋反向傳播訓練過程中的參數數量 [64]。它根據主要由三種類型的層組成的學習過程過濾和提取特徵：卷積層、池化層和全連接層 [65]。卷積層學習並提取相關特徵。集區層會執行功能縮減。全連接層將特徵與預測的目標標籤類別連結起來，隨後在輸出層中說明 [66]。CNN 可以以無監督的方式提取相關特徵 [61]。

RNN 廣泛應用於語音處理和 NLP。

RNN 是一類人工神經網絡，允許將先前的輸出序列儲存在可以影響決策過程的隱藏狀態中。RNN 可以從嵌入的句子結構中學習，以破譯特定於上下文的含義。RNN 可以將先前的輸入保存在隱藏層中，具有一種短期記憶 [46]。RNN 的缺點之一是它們無法處理遙遠的依賴關係以及對梯度爆炸或衰變的敏感性 [61]。新的資料輸入可能會導致網路低估先前的輸入。這種靈敏度衰減的解決方案提供了 LSTM 模型，該模型具有可以保存先前狀態並相互交互的內存塊 [67]。

BERT 是機器理解文本中歧義語言含義的模型。它是由 Google 專家團隊開發並由 Devlin 等人提出的模型 [68]。根據 Vaswani 等人的說法，該模型的基礎是變壓器 [69]。這使得 BERT 能夠透過在句子中所有其他單字的上下文中處理給定單字而不是單獨處理來理解上下文和歧義。在這種情況下，雙向意味著 BERT 可以同時讀取雙向文本輸入，而不是按順序讀取文本輸入，這與其他語言模型不同。變壓器也為模型帶來了這種能力。雙向學習使得使用比需要一系列數據的 RNN 和 CNN 更多的數據進行訓練成為可能。預訓練是使用掩碼語言模型

（MLM）和下一個句子預測（NSP）完成的。使用的訓練語料庫是 BooksCorpus，有 800 萬個單詞，英文維基百科有 2,500 萬個單詞。透過預訓練方法，BERT 透過上下文預測掩碼單字來理解語言的口語

由於未標記的學習，它會在運作時繼續學習，並使用預訓練作為基礎層。在微調中，BERT 可以通過監督學習來適應特定領域，方法是使用特定任務的輸入和輸出進行預訓練 [68]。

四、結果

結果部分總結了我們文獻綜述的主要發現，結構如下：在第一部分中，我們從行為和社會科學的角度審查了情感分析在 COVID-19 背景下的適用性所收錄的論文。在第二部分中，我們從技術角度分析納入的研究，重點關注分類技術。

本文獻綜述總共收錄了 40 篇論文。

如圖 4 所示，在 40 項觀察研究中，有 38 項使用英語推文作為分析基礎。然而，值得注意的是，有幾篇論文使用了多個資料集，包括非英語資料集。因此，我們觀察到了 47 個不同的數據集，不包括標準情感庫。例如，Behl 等 [70] 使用來自尼泊爾和義大利的兩個資料集來訓練其分類器，並使用一個全球自提取的 COVID-19 資料集進行評估。根據我們的分類方法，本文將表示三類：尼泊爾、義大利和全球。朱明確指定類別包含由於缺少規範而無法識別資料集原產國的所有論文。除了英語數據集外，還有兩篇論文使用了西班牙語推文，一篇論文分別使用了葡萄牙語、阿拉伯語、法語、波斯語和印度尼西亞語的推文。圖 5 描述了資料集的地理位置。大多數收錄的論文都使用了大流行開始時的數據集，如圖 8 所示。

A. 將情緒分析與社會和行為科學的見解相結合

在遏制 COVID-19 傳播的鬥爭中，世界各國政府都採取了預防措施，例如保持身體距離規則。由於人類本質上是社會物種，因此這些措施伴隨著高昂的附加成本：日常習慣和人際關係的破壞引發了焦慮感、社會孤立感和學習障礙 [71]。美國政府已經宣布啟動一項應對所謂「國家心理健康危機」的策略，以應對 COVID-19 對公民造成的損失 [72]。適應政府的預防措施需要人類行為的重大轉變。為了減少心理困擾，行為和社會科學可以提供最佳實踐方法，說明如何使人類行為與健康專家的建議保持一致 [1]。因此，社會和行為科學可以為管理大流行及其影響提供有價值的見解 [73]。先前的研究已經確定了與流行病背景相關的六個社會和行為研究主題：威脅感知、領導力、科學傳播、社會背景、壓力和應對以及個人和集體利益 [1]。




圖 4. 按語言排序的納入研究的 Twitter 數據集概述。

本文從社會和行為科學的角度回顧了可能的情緒分析應用。本著這種精神，我們將 40 篇收錄論文中的每一篇都歸入 van Bavel 等人 [1] 根據其研究貢獻或分析領域確定的六個類別。[1] 確定了從社會和行為角度對遏制大流行很重要的主題。我們在圖 6 中總結了分類。在每個部分中，我們簡要描述了行為和社會科學知識如何為管理大流行提供建議。然而，我們的主要重點是說明如何應用情感分析來收集相關數據，以深入了解公眾的思維、感受和行為。沒有分配的類別和子類別將不會被解決，並將包含在討論部分。

我們的文獻綜述旨在為決策者和公共衛生專家提供有關在 COVID-19 背景下應用情緒分析的指導。通過使用 van Bavel 等人的分類 [1] 作為參考點，為決策者提供了如何在相應類別中應用情感分析的示例，這些類別可以作為決策的數據基礎。數據基礎越好，對公眾行為的了解越好，政府和衛生組織就越能做出更好的決策，以減少預防措施的破壞性影響。

1) 威脅感知

人們以不同的方式應對大流行對人類生命迫在眉睫的威脅。COVID-19 大流行大規模引發了焦慮和壓力

以及大片人口的抑鬱症 [74]。在本小章中，我們將仔細研究人們對威脅的看法和反應以及他們的情緒反應。此外，我們亦會研究恐懼的後果，恐懼可能導致對他人的偏見和歧視，以及恐慌行為[1]。對於我們的分析框架，我們將前兩個子類別（威脅和情緒以及風險感知）合併到一個集群“情緒”中。人類的自然反應是在面對威脅時切換到防禦模式。一方面，當威脅被認為可以克服時，恐懼可以成為效率的驅動力；然而，當恐懼超出一個人的應對機制和能力時，就會引發更強烈的防禦反應 [1]。最終，人們在低估感染病毒的可能性時會產生“樂觀偏見”[75]。情感分析允許從文本中調查人們的情感和情緒。例如，三項研究 [76]、[77]、[78] 僅專注於從 COVID-19 數據集中提取用戶的極性，目的是建立更準確的分類模型。這三項研究都使用了 2020 年（即 COVID-19 全球爆發的那一年）提取的 Twitter 數據集。[79] 將 COVID-19 作為當前關鍵事件的一個例子進行調查。普遍的負面情緒會導致資訊更有可能被視為不利並引發負面情緒。因此，人們根據相當負面的信息庫做出決定 [1]。情緒分析的主要應用領域是情緒檢測，這在大流行期間經常被應用 [80]、[81]、[82]、[83]。此外，Chourdrie 等人。[84] 進行了一項研究，分析了不同國家不同時間點的情緒。此外，情緒分析可用於預測感染人數、康復人數和死亡人數，正如 Mittal 和 Aggarwal 的一項研究表明的那樣 [85]。同樣，Sing 等 [86] 發現負面推文與全球累積感染人數、全球累積死亡人數和累積康復人數（在中國）之間存在相關性。在大流行期間，恐慌性購買已成為人們在面臨威脅時的一種明顯的應對機制 [87]。當人們面臨危險時，常見的反應是驚慌失措地做出反應，並採取以自我為中心的行動來保護自己——這可能會損害社會其他成員的利益 [1]。Prentice 等人 [88] 研究了政府措施與恐慌性購買之間的聯繫。該研究的重點是更多地了解施加的措施與相應反應之間的時間效應。此外，情緒分析可以應用於救災，正如 Behl 等人 [70] 所提出的那樣。透過分析災難期間發布的推文，當局可以評估緊急物資的需求和可用性。他們在尼泊爾和義大利地震的 Twitter 資料集上預先訓練了他們的模型，並在 70,000 條與 COVID-19 相關的推文上進行了測試。從上面的例子中可以看出，情感分析可用於從推文中提取情感極性和情緒，以更好地了解人群的潛在感受和情緒。此外，情緒分析可用於了解公眾普遍存在的恐懼，這可以




圖 5. 按地理位置排序的納入研究的 Twitter 數據集數量。




圖 6. van Bavel [1] 的論文類別分佈。

通過調整溝通來緩解。除此之外，「恐慌性購買」等具體的公眾反應也可以透過情緒分析來識別。這可以幫助公共衛生當局分析觸發因素，並使他們能夠採取必要的措施來防止過度反應。

2) 領導力

Van Bavel 等人[1] 區分了大流行期間三種不同類型的領導力：信任和合規、身份領導以及在不貶低他人的情況下提升群體內部。信任和合規子類別需要人們幫助建立對衛生官員、衛生組織或政府機構信任的所有行動

對機構和政府的高度信任可能會對衛生服務的利用產生積極影響 [89]。例如，Gupta 等[90]研究了印度公眾對 2020 年 4 月實施的封鎖的看法。他們得出的結論是，通過情緒分析，他們可以研究普通公眾對印度政府實施封鎖的反應。根據這項檢查，他們認為大多數印度人支持並同意政府實施封鎖以減少新感染的決定。例如，可以通過比較公眾對本土或進口疫苗的看法來衡量對機構的信任。Nezhad 和 Deihimi [91] 通過使用情緒分析，將輝瑞/BioNTech、阿斯利康/牛津、Moderna 和國藥集團等外國疫苗與伊朗疫苗 COVIran Barekat 的看法進行了比較。他們得出的結論是，對外國疫苗的信任度高於對伊朗本土疫苗 COVIran Barekat，這反映了對該國機構和政府的信任。公眾對預防措施或政府的看法可能會隨著時間的推移而改變。因此，Miao 等人 [92] 分析某個城市（紐約）推特上的推文的分析提供了輿論的狀況圖景。在論文中，他們試圖實時處理推文，以監控公眾對政府實施的干預措施的意見和信任。其他作者試圖研究公眾在宣布疫苗開發時的情緒 [93]。Yu 等人 [93] 以及 Rahmanti 等人 [94] 強調，社交媒體數據可用於監測公眾對 COVID-19 事件的反應，例如限制和其他政府措施。Goel 和 Sharma [95] 專門研究了極具影響力的人（「領導者」），並使用文本分析對這個有影響力的群體的推文進行聚類。社會領袖主要討論了民眾關注的疾病症狀、疫苗接種、疾病對策或衛生、疾病傳播途徑等。社會領袖分為四類，即來自學術界、新聞界、健康和政界人士。有趣的是，很多普遍的擔憂是

有影響力的人正在討論的是 van Bavel 等人 [1] 在他們的論文中預期的例子。在 COVID-19 的背景下，情緒分析可用於分析公眾對領導人、政府或公共衛生機構的看法。它允許對特定主題進行即時評估，例如公眾對疫苗或遏制措施的看法。這些知識可以用於評估可能的後果和迫在眉睫的阻力的輸入 [96]。

3) 科學傳播

在 COVID-19 爆發前兩年發表的一項研究已經指出，社交媒體上的錯誤信息是未來大流行中最大的公共衛生威脅之一 [97]。撰寫 2022 年，目前的研究報告稱，由於社交媒體平台上的“假新聞”，全球範圍內有一定比例的人口不信任有關 COVID-19 的科學證明信息。這種發展是危險的，因為對錯誤信息的敏感性、疫苗猶豫和遵守預防措施的意願之間存在相關性 [98]。在此背景下，van Bavel [1] 揭示了區分科學資訊和誤導性資訊的策略以及如何有效應對它們。因此，在本小節中，我們提出了提供處理錯誤訊息解決方案的論文。陰謀論和「假新聞和錯誤訊息」類別由於在調查論文中的相似性而被分組。在採取反制行動之前，首先需要識別錯誤信息。[99] 提供了一種情緒分析方法來過濾掉摩洛哥新冠相關推文中的 COVID-19 流行假新聞。另一項研究提出了一種能夠檢測信息推文的解決方案。反過來，該方法將允許限制不相關的信息並避免負面情緒的傳播 [100]。有效的科學傳播對於刺激 COVID-19 疫苗的接種尤為重要。以下「說服」部分中包含的論文揭示了情緒分析如何幫助提取公民對 COVID-19 疫苗的擔憂，從而支持衛生當局或決策者設計有效的溝通策略。例如，[101] 使用主題建模來確定印度公民對 COVID-19 疫苗副作用的擔憂。報告最多的恐懼包括工作場所效率低下、對死亡的恐懼、對長期影響的恐懼、對血栓的恐懼以及疫苗的效率。同一作者進行了另一項研究，調查了印度對 COVID-19 疫苗的普遍態度。Liu 和 Liu [14] 也進行了類似的研究，他們也研究了公眾對 COVID-19 疫苗的態度。研究顯示，在 BioNTech/輝瑞宣布首款 COVID-19 疫苗的有效性達到 90% 後，公眾情緒和推文數量顯著增加，然後緩慢下降，直到 2020 年 12 月底。科特法斯等人

[102] 在第一種有效疫苗宣布後的第一個月監測了英國公眾對 COVID-19 疫苗的立場。特別是，他們將各自的推文與媒體報導的重大事件進行了匹配。他們發現，大多數推文都持中立立場，支持疫苗的推文數量超過了反對疫苗的推文數量。該研究的一個有趣發現是，反對推文的峰值記錄在 BioNTech/輝瑞 COVID-19 疫苗授權當天。Yousefinaghani 等 [12] 在分析中包括其他維度，例如按時間、地理分佈、主題、關鍵字、帖子參與度指標和帳戶特徵的進展。從 2020 年 1 月 7 日到 2021 年 1 月 3 日，總共收集了 4,522,652 條英文推文，以識別和比較疫苗情緒。負面情緒主要集中在對疫苗開發的擔憂、對疫苗安全性的懷疑或對政府、政治人物和製造商的反應上。兩位作者仔細研究了被轉發的熱門推文。一項研究進一步了解了決定推文受歡迎程度的系統設計，並可用作增加轉發量的工具 [103]，另一項研究研究了熱門推文（被轉發至少 1000 次的推文）的情緒極性 [83]。健康從業者查找相關帖子在很大程度上取決於所選的主題標籤。通過分析包含至少一個主題標籤的六百九十多萬條推文，Petersen 和 Gerken [104] 注意到只有 1,192 個主題標籤被使用超過 1,000 次，從而產生了 13 個不同的主題。除了訊息及其來源之外，訊息的時間可能也很重要，例如，對於決定何時啟動行銷活動。本著這種精神，Satu 等人旨在識別經常出現的話題並分析他們的情緒。作者得出的結論是，這些發現可能有助於制定整合人類行為的策略。此外，Lyu 等人的一項研究 [105] 探討了在美國發布有關 COVID-19 疫苗的推文的人的不同特徵。作者從 2020 年 9 月 28 日到 2020 年 11 月 4 日收集了 1,874,468 條英文推文。研究表明，女性比男性更有可能對疫苗接種持猶豫不決的看法。此外，老年人往往支持疫苗。低收入群體和宗教人士更有可能對疫苗辯論持有兩極分化的意見。政治轉移（由政黨賬戶或政客的追隨者衡量）表明對美國潛在的 COVID-19 疫苗存在分歧。總之，情緒分析提供了識別公眾關注問題的有效工具。在科學傳播中，它可用於檢測社交媒體平台上的錯誤信息。此外，了解公眾的關切可以作為設計目標導向的傳播策略的基礎。

4) 社會背景

我們周圍的社會和文化環境影響著改變和適應我們行為的過程和速度。

這一類別可以細分為四個較小的小節，即社會規範、社會不平等、文化和兩極分化 [1]。van Bavel 等人 [1] 的論文就如何識別風險因素和計劃干預措施提供了進一步的建議，而我們指出了專注於提取社會背景問題的情緒分析工具。社會規範以及遵守和遵守這些規範的努力會影響人類行為 [1]。儘管如此，人們的看法並不是普遍的，可以通過積極的、強化的信息來糾正，這些信息可以宣傳有關大多數人正在做什麼的信息 [1]。Imran 等 [106] 在新冠疫情爆發之初進行了一項研究，研究了鄰國之間的文化差異。他們從 2020 年 2 月到 2020 年 4 月從巴基斯坦、印度、挪威、瑞典、美國和加拿大提取了 560,286 條英文推文。同樣，Garcia 和 Berton [107] 使用主題識別和情緒分析來研究來自 Twitter 的葡萄牙語和英語數據集的國家之間的差異。情緒不僅在國家層面上有所不同，而且在城市層面也可能有所不同。這可以通過 Yao 等人 [108] 的一項研究來說明。他們調查了紐約、倫敦、洛杉磯、芝加哥、華盛頓、西雅圖、波士頓、新加坡和羅馬的公眾情緒如何演變，發現即使在同一個國家，大城市的情緒也並不相同。

COVID-19 對個人的影響取決於多種社會經濟因素。邊緣化社區或少數族裔的成員表現出更高的脆弱性，更容易受到病毒的負面影響，並且可能更容易受到公共衛生信息的影響 [1]。在國家層面上，Rahman 等人 [109] 探討了與美國公民在 COVID-19 大流行期間重新開放美國經濟的積極和消極情緒相關的社會經濟因素。結果顯示，「居住在美國西部地區」、「工人階級」、「家庭租金總額」和「低收入」等因素與經濟重新開放呈正相關。而「平均家庭規模」和「家庭收入」等因素與重新開放情緒呈負相關。這些發現表明，在美國各地，反應並不統一，並受到社會經濟狀況的影響，這得到了 Surano 等人的一項研究的支持。政治因素和對某個政黨的堅持會影響個人對 COVID-19 的看法。Caliskan [111] 進行的一項研究調查了俄亥俄州對 COVID-19 的認識，發現民主黨支持者和共和黨支持者之間存在驚人的差異。

本節介紹的結果表明，情感分析可用於篩選跨文化差異，並從興趣、種族、政治取向或其他因素方面提取有關各個社會群體的信息

這使得衛生當局和決策者能夠根據社會背景調整他們的溝通策略。

5) 壓力與應對

封鎖和隔離的心理後果可能會影響迄今為止倖免於病毒的家庭，即壓力、焦慮和經濟困難。我們將社會孤立和人際關係以及健康的心態等子類別分組進行分析。與他人聯繫以調節情緒、管理壓力並毫無傷心地度過困難時期是人類的本能。孤立不僅會對心理健康產生負面影響，還會對心血管和免疫健康產生負面影響，尤其是對於外向的人 [112]。孤立與孤獨不同，但它可以加劇和促進孤獨。透過媒體傳播，必須明確，即使身體分開，例如透過線上互動，社交聯繫也是可能的。特別是對於老一輩人來說，他們孤獨的風險更高，尤其是通過隔離 [113]。這裡還要考慮的是，態度和情境評估會影響壓力結果。因此，壓力反應可以通過積極思考導致積極情緒，從而預防心理和生理問題 [114]。Kabir 和 Madria [115] 使用了最大的自提取 Twitter 數據集之一，該數據集總共包含 56,014,158 條英文推文。他們發現，在大流行期間負面情緒有所增加。此外，特定州的 COVID-19 病例數量與檢測到的負面情緒相關。與這些發現相匹配，Kaur 等人 [116] 發現通過社交媒體進行的 COVID-19 交流對人們的生活既有積極的影響，也有消極的影響。一項針對印度的研究研究了 COVID-19 期間壓力、焦慮和創傷的一般原因 [117]。他們的研究結果表明，死亡和封鎖對印度人民的心理健康影響最大。另一項研究調查了居住在澳大利亞的人們的情緒和心理健康。[118] 分析了大流行期間澳大利亞推文的情緒。作者收集了最大的數據集，其中包含來自 183,104 名 Twitter 用戶的 94,707,726 條英文推文，這些用戶根據他們在澳大利亞新南威爾士州的 Twitter 位置生活。結果顯示，政策和疫情事件在不同階段對人們情緒的影響不同。例如，在 COVID-19 感染增加和實施封鎖的時期，總體情緒顯著轉向負面情緒。所有四項研究都提取了特定情況下的情緒健康以及政府溝通對公眾的影響。Twitter 的情緒分析可以為人們當前的心理健康狀況提供重要的見解。這些信息可用於對公共醫療保健系統可能出現的迫在眉睫的問題做出實時反應

表 3. 根據 van Bavel 等人 [1] 根據相關社會和行為科學主題對納入的研究進行分類。

Ref.	Author	Subcategory
Threat perception		
[79]	Alhashmi et al.	Emotion
[76]	Alsayat	
[83]	Chakraborty et al.	
[84]	Choudri et al.	
[82]	Kaur et al.	
[85]	Mittal and Aggarwal	
[80]	Morshed et al.	
[77]	Ramya et al.	
[81]	Ridwhan and Hargreaves	
[86]	Singh et al.	Disaster and panic
[78]	Yigitcanlar et al.	
[70]	Behl et al.	
[88]	Prentice et al.	
Leadership		
[95]	Goel and Sharma	Identity leadership
[90]	Gupta et al.	Trust and Compliance
[92]	Miao et al.	
[91]	Nezhad and Deihimi	
[94]	Rahmanti et al.	
[93]	Yu et al.	
Science Communication		
[102]	Cotfas	Misinformation
[14]	Liu and Liu	
[105]	Lyu et al.	
[99]	Madani et al.	
[103]	Mahdikhani	
[100]	Malla and P.J.A.	
[104]	Petersen and Gerken	
[120]	Satu et al.	
[121]	Sv et al.	
[101]	Sv et al.	
[12]	Yousefinaghani et al.	
Social Context		
[107]	Garcia and Berton	Culture
[106]	Imran et al.	
[108]	Yao et al.	
[111]	Caliskan	Polarization
[110]	Surano et al.	
[109]	Rahman et al.	Social norms
Stress and coping		
[115]	Kabir and Madria	Mental health
[116]	Kaur et al.	
[117]	Sv et al.	
[118]	Zhou et al.	

在即將到來的未來必須應對 [119]。我們在表 3 中根據其類別和子類別總結了所有論文。

B. 情緒分析技術

前一章從社會和行為科學的角度闡明了情感分析。情緒分析解決了提取和分析大量資訊的問題，這些資訊可以深入了解公眾的行為。我們通過回顧文獻中的實際例子來說明情感分析如何支持




圖 7. 文獻綜述中使用的分類算法類別。

van Bavel 等人確定的社會和行為類別的決策。通過充分了解公眾的感受和情緒，可以改善 COVID-19 背景下的決策。然而，為情感分析提出的分類算法在所收錄論文的表現方面有所不同。因此，必須確保情緒分類器提供可靠且準確的結果。因此，分類器報告的準確性進一步表明了其整體性能和可靠性。在接下來的三個子章節中，我們從技術角度回顧了所收錄的論文。特別是，這些研究根據它們使用的分類技術進行分類。

1) 分類技術概述

在綜述的文獻中，主要使用了三種分類方法：基於詞彙的方法、基於機器學習的方法和基於 DL 的方法。van Bavel 等人 [1] 在框架中對納入研究中使用的分類算法及其各自分配的類別的概述可以在表 4 中找到。在本次文獻綜述中包含的 40 篇論文中，有 7 篇論文使用基於詞典的分類方法，16 篇使用基於傳統 ML 的分類方法，17 篇使用基於 DL 的分類方法。如果在一項研究中分析了各種算法，則僅選擇性能最佳的算法（見圖 7）。

基於詞典的論文的一個共同特徵是所有論文都使用了開源的 Valence Aware Dictionary and sEntiment Reasoner (VADER)，這是一種基於規則的詞典情感分析工具，用於分析情感。這些研究的共同點是，大多數極性檢測是

表 4. 納入研究中使用的情緒分類算法概述。

Ref.	General approach	Specific classification algorithm used
Threat perception		
[85]	Lexicon based	VADER
[88]	Lexicon based	VADER
[79]	Traditional ML	MultinomialNB, RF, SVM, Bi-LSTM, CNN, Bayes Factor Tree Augmented Naïve Bayes technique (BFTAN)
[83]	Traditional ML	32 different ML-algorithms (MultinomialNB, LinearSVC, RF, ...)
[82]	Traditional ML	IBM Watson Tone Analyzer
[77]	Traditional ML	NB
[81]	Traditional ML	Sentiment analysis: VADER, Emotion detection: Pre-trained RNN
[76]	DL	Ensemble Method (LSTM with FastText + BERT + IBM Watson + Microsoft Sentiment Analysis API)
[70]	DL	MLP-W
[84]	DL	RoBERTa, BiLSTM, BERT
[80]	DL	DL model; not explicitly specified
[86]	DL	BERT
[78]	DL	WEKA
Leadership		
[93]	Lexicon based	VADER
[90]	Traditional ML	MultinomialNB, BernoulliNB, LR, LinearSVC, AdaBoostClassifier, RidgeClassifier, PassiveAggressiveClassifier, Perceptron
[95]	DL	SVC, RF, NN, BERT
[92]	DL	LSTM + GloVe Distillation
[91]	DL	CNN-LSTM model
[94]	Traditional ML	NB, Maximum Entropy
Science communication		
[14]	Lexicon based	VADER
[12]	Lexicon based	VADER
[99]	Traditional ML	Sentiment analysis: TextBlob2, Fake detection: LR, DT, RF, NB, Gradient Boosting, SVM, MLP
[103]	Traditional ML	RF, SGD, LR, EVC
[121]	Traditional ML	TextBlob
[101]	Traditional ML	TextBlob
[102]	DL	MNB, RF, SVM, Bi-LSTM, CNN, BERT
[105]	DL	XLNet, VADER, LDA
[100]	DL	MVEDL (Majority Voting technique-based Ensemble Deep Learning model) based on RoBERTa, BERTweet, CT-BERT
[104]	DL	SpaCy library
[120]	DL	TClustVID (Ensemble method with clustering)
Social context		
[110]	Lexicon based	VADER
[107]	Traditional ML	LR, RF, Linear SVM
[109]	Traditional ML	LR
[108]	Traditional ML	NB
[111]	DL	RNN, CNN
[106]	DL	DNN (Baseline), LSTM + FastText, LSTM + GloVe, LSTM + GloVe Twitter, LSTM without pre-trained embedding, BERT, BiLSTM, GRU
Stress and coping		
[118]	Lexicon based	VADER
[116]	Traditional ML	Hybrid Heterogeneous SVM, RNN, Linear SVM
[117]	Traditional ML	TextBlob
[115]	DL	SVM, NTUA-SLP, BiLSTM

Abbreviations included in the table:

Support Vector Classifier (SVC), Random Forest (RF), Logistic Regression (LR), Convolutional Neural Network (CNN), Recurrent Neural Network (RNN), Random Neural Network (NN), Random Neural Network and Bidirectional Encoder Representations from Transformers (BERT), Deep Neural Network (DNN), Long-short term memory (LSTM), Multinomial Naïve Bayes (MNB), Multi-Layer Perceptron (MLP), Bidirectional Long Short-Term Memory (Bi-LSTM), Bayes Factor Tree Augmented Naïve Bayes technique (BFTAN), Tree Augmented Naïve Bayes (TAN), MVEDL based on RoBERTa, BERTweet and CT-BERT, Decision Tree (DT), Waikato Environment for Knowledge Analysis (WEKA), Global Vectors for Word Representation (GloVe), Ensemble Voting Classifier (EVC), NTUA-SLP is a DL model and the winner of the SemEval-2018 Task1 competition.

執行。極性檢測通常等同於情感分析 [11];然而,這只是一個特定方面。極性檢測涉及將文本的情緒分為積極、消極或中性 [23]。可以使用 VADER

探索各種主題的情感 [88]、[93]。基於詞典的方法提供了一種研究新主題的簡單方法,因為它們不需要標記數據。例如, Liu 和 Liu [14] 評估了 COVID-19

關於其極性分數的疫苗相關推文。在各個國家，觀察到不同的趨勢：巴西的極性得分最低，阿拉伯聯合酋長國最高。Yousefinaghani 等人 [12] 的一項類似研究使用 VADER 和 Gensim 庫中的關鍵字函數對有關其情緒和疫苗接種特定主題的推文進行分類。有趣的是，他們發現負面推文主要由機器人或政治活動家發布。這可以幫助當局採取必要的對策來消除疫苗猶豫，並設計以目標為導向的溝通策略。因此，Zhou 等 [118] 研究了大流行期間澳大利亞新南威爾士州地區推文中的情緒。Mittal 等 [85] 分析了公眾情緒與全球感染、全球死亡或康復等因素之間的相關性，Surano 等 [110] 使用情緒極性作為其他社會經濟因素的預測因子。

對於情感分析，ML 分類技術被廣泛使用 [23]。這是因為基於詞典的方法有一個明顯的缺點：它們完全依賴帶註釋的單字詞典，而不考慮特定於上下文的資訊或特定領域的資訊。對於 Twitter 上的情緒分析，主題經常出現和變化，預先錄製的字典必須不斷更新。此外，基於機器學習的方法可以包括用於分類的上下文特定信息 [23]。由於這個原因，兩個子章節將明確處理根據 COVID-19 Twitter 數據的情緒分析使用的傳統 ML 和 DL 分類方法。此外，傳統機器學習類別的四項研究使用了 Python 函式庫 TextBlob [99]、[101]、[117]、[121]。該庫經常用於 NLP 任務，例如短語提取、詞性標記、標記化、情感分析、分類以及單詞和短語的頻率。然而，這項研究的重點主要集中在情感分析的用例上，沒有詳細報告績效指標，即準確性或 F1 分數。這種現象可以在另一項使用 IBM

WatsonAnalyzer 的研究中觀察到，IBM WatsonAnalyzer 是一種可以檢測情緒和語言語調的 NLP 工具 [82]。由於我們比較了 ML 分類器的性能以展示最佳實踐，因此沒有或報告準確性數據不足的研究被排除在以下兩個子章節的詳細分析之外。因此，除了前面提到的論文外，我們還排除了 [80]、[81]、[91]、[104]、[108]、[116] 和 [107] 的論文，理由是缺少性能指標和無法獲得補充性能數據 [108]。

在下一章中，將更詳細地研究具有報告性能指標的 ML 分類器。如前所述，我們只包括了性能最佳的分類算法的準確性。儘管如此，將情感分析論文的準確性相互比較存在一些困難。每項研究在數據集方面都有其獨特的特徵，其中包括提取時間和持續時間的變化

用於資料擷取的主題標籤和關鍵字、所選位置、觀察數量或預處理步驟。此外，不同的分類演算法、特徵提取方法以及各種參數的微調（例如交叉驗證中的折疊數），使得各個研究之間的比較具有挑戰性。這些基本參數的微小變化會顯著影響分類器的整體性能。在我們的文獻綜述中，在 33 項使用 ML 分類器的研究中，有 15 項應用了傳統 ML 分類器，18 項應用了 DL 分類器。由於我們只包括報告了績效指標的研究，因此詳細檢查了其餘 6 項使用傳統 ML 分類器的研究和 13 項使用 DL 分類器的研究。

回顧一下，當沒有可用的標記數據並且字典已調整為特定領域時，基於詞典的方法是有益的。ML 方法需要大量標記資料來訓練其分類演算法，但可以包含特定於上下文的資訊和語言特殊性，這在 Twitter 訊息中很常見。因此，對於 Twitter 上的情緒分析，主要使用 ML 分類器 [23]。

2) 傳統機器學習分類器

本章回顧了所包含論文中用於進行情緒分析的 ML 分類器。總共有六篇論文報告了其傳統 ML 分類器的準確性。大多數研究評估了各種機器學習演算法。只有兩項研究使用了單一分類器 [77]、[109]。最常用的是 RF [95]、機率分類器（例如 NB [77]）或其他監督模型，例如 SVC [90] 或邏輯迴歸（LR）[83]、[109]。兩項研究採用了集成分類器方法（在本文中，我們認為 RF 不是集成分類器）。組合不同分類器的優點是每個單獨分類器的泛化誤差不太可能在集體決策中產生錯誤 [122]。

Mahdikhani 等人 [103] 創建了一個由 RF、隨機梯度下降（SGD）和 LR 組成的集合投票分類器（EVC）[103]。Alhashmi 等人將 RF 與 NB 分類器結合，創建了所謂的貝葉斯因子樹增強樸素貝葉斯（BFTAN）分類器 [79]。ML 分類器已在多項研究中與不同的特徵提取方法相結合進行了評估。最受歡迎的是 TF-IDF [95]、[123]、n-grams [77]、[90]、[107]、[123] 和 Word2Vec [79]。

Goel 和 Sharma [95] 調查了世界領導人及其在大流行期間表達的擔憂。他們的模型預測推文屬於以下四個類別之一的概率：「政治」、「健康」、「研究」或「新聞」。他們的評估基於 42,468 條推文的數據集。此外，他們還使用 TF-IDF 嵌入來提取公眾關注，並使用 LDA 和 Gibbs 抽樣方法來檢測情緒，對超過 30,000,000 條推文進行了預處理。他們將情緒聚類為期待、憤怒、信任、驚訝、悲傷、喜悅、恐懼和厭惡，並將它們用作分類演算法的標準化輸入特徵。作者

比較了有關接收者工作特徵曲線下面積 (AUC ROC) 的不同分類模型。他們測試了 SVC、RF、隨機神經網路 (CNN 和 LSTM 的組合) 和 BERT。最有效的模型是 AUC ROC 為 96% 的射頻分類器，用於選擇正確的聚類。具有最佳精度的分類器實現了 Mahdikhani [103] 的模型，該模型開發了一個模型來預測推文的可轉發性。分類程序的設置與 Goel 和 Sharma [95] 的分類程序類似。第一步，使用 LDA 演算法識別 Tweet 資料集中的常見主題。在第二步中，使用 CrystalFeel 演算法測量他們的情緒強度並將其分類為恐懼、憤怒、喜悅和悲傷。使用 LDA、LDA 加 TF-IDF、BOW by TF-IDF、Doc2Vec 和 Doc2Vec 加 TF-IDF 進行主題建模和評估。這些被用作附加內容功能。集成模型用於集成 RF、SGD 和 LR 算法的分類任務。研究表明，LDA 加 TF-IDF 矢量化器結合集成投票分類器可以達到 95.04% 的最高準確率和 95% 的 F1 分數。準確率超過 92.49% 的第三好分類器是 Ramya 等人採用的 NB 算法 [77]。作者使用 NB 方法結合 n-gram 作為特徵分析了推文的情緒極性。根據推文的長度，模型的準確率在 92.49% (少於 70 個字元的短訊息) 和 60.56% (70 到 150 個字元之間的訊息) 之間變化。有趣的是，同一分類器的準確性會隨著推文長度而變化。除了 NB 分類器之外，他們還可以發現 LR 方法以 74% 的準確率執行分類任務。

Gupta 等[90]的研究與之前在數據標註過程中的研究不同。作者結合使用 TextBlob 和 VADER 來標記他們提取的資料集。只有當兩種演算法為推文分配相同的極性時，它才會包含在樣本中。在提取的 12,741 條帶有主題標籤 #Indianlockdown 的推文中，合併後，最初數據集只剩下大約一半 (7,284 條推文)。訓練和測試了八種不同的 ML 分類器，即多項式樸素貝葉斯 (MNB)、伯努利樸素貝葉斯、LR、LinearSVC、AdaBoostClassifier、RidgeClassifier、PassiveAggressiveClassifier 和 Perceptron。80% 的數據用於訓練，20% 用於測試。他們還對每個變體進行了十倍的交叉驗證，並表明具有單克特徵的 LinearSVC 達到了 84.4% 的最高準確率。當特徵提取為二元組 (81.2%) 或三元組 (78.3%) 時，相同的模型會達到較低的準確度。有趣的是，在標記步驟中，TextBlob 和 VADER 為近一半的樣本分配了不同的標籤，這些標籤又被丟棄並且不包含在樣本中。與 Mahdikhani [103] 類似，Alhashmi 等[79]使用集合模型來評估當前大流行等關鍵事件期間的情緒。他們提出的模型是 SVM 與樸素貝葉斯的結合

所謂的貝葉斯樹增強樸素貝葉斯技術 (BFTAN) 的性能優於所有其他基準模型。作者根據樹增強樸素貝葉斯、NB、SVM 和 RF 等標準模型評估了他們的模型。以 Word2Vec 作為特徵提取方法，模型達到了 82.8% 的準確率。

Chakraborty 等人 [83] 在兩個不同的樣本上評估了超過 32 個傳統 ML 分類器。評估的分類器包括 MNB、LinearSVC、AdaBoostClassifier 和 LR。與 Gupta 等人 [90] 的研究相比，LinearSVC 達到了最高的準確性，Chakraborty 等人發現，儘管樣本量不同 (數據集一包含大約 23,000 個，數據集二包含 226,000 個轉發)，並且儘管它們在大流行期間的觀察期不同，但 LR 分類器在兩個數據集上的性能優於所有其他 32 個評估的 ML 分類器。LR 分類器在較小資料集上的準確率為 81% (TF-IDF 下的三元組)，在較大資料集上的準確率為 75% (TF-IDF 下的二元組)。

另一項使用 LR 預測類別標籤的研究是 Rahman 等人的研究 [109]。它調查了美國居民在經濟重新開放背景下與積極或消極情緒相關的驅動因素。作者在從 Twitter 下載的 2,507 條推文的數據集上使用了 R 包 Syuzhet 和 sentimentr。在確定情緒極性後，使用 LR 來尋找影響相關情緒的潛在因素。他們使用 BoW、文檔術語矩陣 (DTM)、POS、依賴解析 (DP) 和 N-gram 作為探索技術。該模型的準確率為 56.18%。表 5 提供了傳統 ML 分類算法的摘要。

用於執行情緒分析的基於機器學習的分類器在 COVID-19 的背景下顯示出超過 80% 的相當高的準確率 - 除了一個例外 [109]。由於基於機器學習的分類模型需要標記數據，因此可以觀察到各種獲取數據的方法：要么使用預先標記的開源數據集來訓練分類器 [86]、[106]，要么使用機器驅動的註釋過程對數據集進行註釋，例如，使用 TextBlob 或 VADER 註釋數據 [83]、[90]、[109]，或者手動標記數據集的一部分 [70]，[77]，[124]。由於推文包含非結構化數據，因此需要執行預處理步驟。特別是對於實時情緒分析，下一章中分析的 DL 模型比基於 ML 的分類方法具有一定的優勢。

3) 深度學習分類器

報告其分類器績效指標的二十項研究中有十二項使用了 DL 模型。六項研究使用了基於變壓器的模型，例如 BERT、RoBERTa 或 XLNet [76]、[84]、[86]、[100]、[102]、[105]。四項研究使用 LSTM 模型，作為單個分類器或作為集成分類器的一部分 [76]、[92]、[106]、[115]。其餘研究採用了一種模型，該模型是 RNN 和 CNN 的組合 [111]，即多層

表 5. 已報告效能計量的傳統機器學習分類方法摘要。

Ref.	Traditional Machine Learning	Ensemble method	Best-performing feature extraction and classification method	Accuracy
[95]	x		TF-IDF + Random Forest	96% (AUC ROC)
[103]	x	x	Ensemble Voting Classifier (RF, SGD, LR)	95.04%
[77]	x		N-grams + Naïve Bayes	92.49% Short tweets (<70 characters), 60.56% Long tweets (>150 characters)
[90]	x		Unigram + LinearSVC	84.4%
[79]	x	x	Word2Vec + Bayes Factor Tree Augmented Naïve Bayes technique (BFTAN)	82.8%
[83]	x		Trigrams and TF-IDF + Logistic Regression	81.4%
[109]	x		BOW, DTM, POS, DP and n-grams + Logistic Regression	56.18%

Abbreviations included in the table:

Term Frequency-Inverse Document Frequency (TF-IDF), Support Vector Classifier (SVC), Random Forest (RF), Stochastic Gradient Descent (SGD), Logistic Regression (LR), Bag-Of-Words (BOW), Document Term Matrix (DTM), Part-of-Speech (POS), and Dependency Parsing (DP)

感知器 (MLP) [70]，或將不同的 DL 模型組合在集成分類器中 [120]。如表 6 所示，三個性能最好的分類器都使用了 BERT。從第二好的分類器到第四好的分類器都是整體準確率可以達到 90% 以上的集成方法。

Singh 等人 [86] 的研究中觀察到了準確度最高的模型。BERT 模型用於情緒檢測。他們使用了一個自選的數據集，分為全球數據集和印度數據集。此外，他們將數據分為測試集和訓練集，並使用 VADER 和 TextBlob 確定每條推文的極性——類似於 Gupta 等人的研究 [90]。BERT 使用測試資料集和開源「情緒資料集」進行了微調。定制的 BERT 模型在提取推文情感方面達到了 93.89% 的準確率。此外，它還將 LSTM 模型與 FastText 作為單詞嵌入技術和單詞作為三元組相結合。此外，它還使用 BERT、IBM Watson、BERT 和 Microsoft Sentiment Analysis API 等預先建置的模型來評估 LSTM 模型的結果。整體方法的準確度高於個別模型的準確度。集成模型的整體準確率為 92.65%。客製化的 DL 分類器在 Twitter 資料集上實現了 90.25% 的準確率，高於單獨使用 BERT 所達到的準確率。作者發現，具有 200 個隱藏層的神經網路在測試資料集上產生最佳結果。在類似的環境中，Malla 等人 [100] 在 Twitter 數據上應用了集成 DL 模型，以根據其內容過濾信息推文。他們提出了一種集成算法，一種「基於多數投票技術的集成深度學習 (MVDEL)」模型，該模型使用三種 DL 算法：RoBERTa、BERTweet 和 CT-BERT。該分類器是在包含 10,000 多條標記推文的資料集上進行訓練的。ML 演算法在將資料分類為資訊性和非資訊性類別時達到了 91.75% 的準確率和 91.14% 的 F1 分數。薩圖等人。[120]也採用了合奏方法；然而，它們在分類之前引入了進一步的聚類步驟。他們提出了一種新穎的方法，其中包括在使用 GloVe 進行預處理後

使用 k-means 演算法將標記的資料集細分為不同的叢集。分組有助於將 ML 分類器模型的準確性提高 5 個百分點以上。作者比較了各種 ML 和 DL 分類器：決策樹、梯度提升、K 最近鄰、LR、MLP、NB、RF、SVM、XGBoost 和 LSTM。在大多數集群中，使用 LSTM 模型實現了最佳性能。所提出的演算法 TClustVID 選擇每個聚類中性能最佳、精度最高的分類器，從而優化了整體精度。

Kabir 和 Madria [115] 提出了一種 DL 模型，該模型表明在考慮推文特定內容細節方面具有可靠的穩健性。作者使用 DL 分類器自動預測 COVID-19 數據集中的十種特定情緒。作者在自選和手動標記的資料集、SemEval2018-Task 1 資料集和情緒資料集上評估了不同的 ML 模型：SVM-Unigrams、NTUA-SLP 和 BiLSTM。他們提出的多層神經元網路基於使用預訓練的 RoBERTa 模型的雙向 LSTM 模型。該模型的準確率達到了 89.51%。Behl 等人 [70] 的一項研究是少數在看不見的數據集上測試其分類器的研究之一。他們探索了 Twitter 信息在救災行動中的可用性。因此，作者在一個公開可用的數據集上訓練了五種不同的 DL 分類器，該數據集包含尼泊爾和意大利地震期間錄製的推文。他們評估了模型在 COVID-19 資料集上的可重複使用性。作者評估了不同模型將推文正確分類為「資源需求」、「資源可用性」和「其他」類別的表現，這可以支持自然災害期間的援助分配。作者評估了尖端的 ML 分類器，例如具有 TF-IDF 特徵的 LT (LR-TF)、沒有微調的 CNN、有微調的 CNN、有 TF-IDF 特徵的 MLP 和沒有 TF-IDF 特徵的 MLP

(MLP-W)，而是 Word2Vec 嵌入。這些模型在兩個單獨的數據集以及一個組合的數據集上進行了預訓練和測試。比較分析

在組合資料集上訓練的模型顯示，MLP-W 在所有指標上都優於所有其他分類器。此外，該研究是為數不多的同時測試 ML 和 DL 分類器的研究之一。他們的分析表明，DL 分類器預測正確的標籤比傳統的 ML 分類器具有更高的準確性。該模型在手動標記的 COVID-19 數據集上實現了 83% 的準確率和 85% 的 F1 分數。一個引人注目的觀察結果是，儘管所有其他評估模型在組合測試訓練數據集上都達到了更高的準確性，但 MLP 模型在看不見的數據上表現更好。

Imran 等[106]的研究很好地說明了所選特徵可以對分類器的性能產生影響。作者比較了六種不同的 DL 模型使用可公開訪問的 Sentiment140 數據集預測極性的能力。評估的 DL 模型如下：深度神經網路（DNN）、帶有 FastText 的 LSTM、帶有 GloVe 的 LSTM、帶有 GloVe 的 LSTM，在 Twitter 資料上有和沒有預先訓練的嵌入。基於 FastText 的 LSTM 模型在檢測極性任務中實現了最高的準確率（82.4%）和 82.4% 的 F1 分數。在 COVID-19 數據上進行測試時，模型的準確率降至 76%。不過，必須強調的是，作者將推文的表情符號視為其實際標籤——這可能會扭曲他們的發現。除了極性檢測之外，作者還測試了 DL 分類器在預測積極情緒（喜悅和驚訝）和消極情緒（悲傷、恐懼和憤怒）方面的表現。對於情緒檢測，作者在公開可用的情緒推文資料集上訓練了他們的演算法。如先前的評估所示，LSTM 模型再次優於所有其他分類器。正確預測的積極和消極情緒的準確率分別為 81.9% 和 69.9%。然而，GloVe 作為一種特徵提取方法，這次表現出了最好的性能。在這兩種情況下，模型都是在 Twitter 數據上進行預訓練的。Choudrie 等人[84]與 Imran 等人[106]具有相同的分析重點，創建了一個用於基於文本的情緒分析的 DL 模型。RoBERTa、BERT、BiLSTM 和 LSTM 作為分類器模型進行測試。該模型基於 RoBERTa，並使用 CrowdFlower 的開源“文本中的情感”數據集進行了遷移學習進行微調。模型的準確率為 80.33%。Coftas 等人[102]沒有使用開源數據集，而是手動標記了 7,530 條推文，約佔整個數據集的 1%，以檢查英國公民對 COVID-19 疫苗接種的立場。他們使用了流行的 ML 和 DL 分類演算法，例如 MNB、RF、DVM、雙向 LSTM 和 CNN。最佳性能的分類器 BERT 的準確率為 78.94%，其次是 SVM（76.23%）和帶有 GloVe 嵌入的雙向 LSTM（74.7%）。

GloVe 嵌入經常與 DL 模型一起使用。此外，在以下兩項研究中，GloVe 在 Twitter 數據上進行了預訓練，並用作特徵提取方法。在 Caliskan [111] 的研究中，DL 算法被用來提取意識和情緒。對於情緒的分類，使用了 Twitter 數據上預先訓練的 GloVe 向量。他們的 DL 模型

基於一系列 RNN 和 CNN 演算法，平均準確率達到 71%。Miao 等[92]分析了紐約推特上的推文的輿論。由於標記數據量有限，因此應用了訓練數據的數據增強。作者測試了三種表示模型和三種分類演算法。他們使用現有資料集 StanceData 和 Sentiment140 以及手動標記的資料訓練了分類器模型。對 SVM（帶 BOW）的合成少數過採樣技術（SMOTE）進行了測試，以解釋不平衡。該技術沒有帶來改進，也沒有用於其他模型。此外，標記訓練資料集與 SVM 結合使用會產生最佳結果。因此，僅使用標記的訓練資料集來測試模型。他們可以發現，深度學習模型 LSTM with GloVe（使用 50 維和蒸餾）顯著優於其他測試的分類模型。LSTM-GloVe 的準確率達到了 66%。在 Lyu 等人的研究中可以觀察到驚人的發現。他們收集了一個 Twitter 數據集，其中包含超過 1,850,000 條與 COVID-19 疫苗和疫苗相關關鍵字相關的獨特推文。該研究的重點是 Twitter 用戶對 COVID-19 疫苗接種的立場檢測。這三位研究人員從數據集中採樣了 2,000 條獨特的推文，並手動獨立地為每條推文標註了標籤。這四個類別分別是「無關緊要」、「支持疫苗」、「對疫苗猶豫不決」或「反疫苗」。此資料用作 XLNet 模型的訓練資料。然而，當該模型在包含 400 條標記推文的新穎外部數據集上進行驗證時，其準確率僅為 63%。簡而言之，結合多個 DL 分類器的集成方法顯示出最有希望的結果。與 ML 模型相比，用於訓練 DL 模型的資料集平均更大。上面包含的樣本表明，DL 分類器可以處理特定於上下文的信息，Kabir 和 Madria [115] 的研究就是例證。然而，在大多數研究中，訓練和績效評估都是在同一個數據集上進行的。[124] 的研究令人印象深刻地表明，DL 模型在接觸看不見的數據時也會面臨困難。

五、討論

先前的研究從應用程式的角度 [24]、健康和福祉的角度 [125]、疫苗猶豫的背景 [26] 或用於預測疾病爆發的方法和機器學習技術 [86] 調查了對抗多種傳染病的情緒分析。在這篇文獻綜述中，我們以 van Bavel 等人 [1] 的框架為基礎，並將以前不相關的社會和行為科學研究流與情感分析相結合。專家強調，只有對我們日常的人類行為進行實質性改變，才能控制疫情 [73]。因此，我們研究了情感分析如何為在人類行為相關領域做出決策提供有價值的見解和可靠的數據基礎，這些領域對人類行為至關重要

表 6. 已報告效能指標的深度學習分類方法摘要。

Ref.	Deep Learning	Ensemble method	Best-performing feature extraction and classification method	Accuracy
[86]	x		BERT	93.89%
[76]	x	x	Ensemble Classifier (LSTM + FastText, BERT, ...)	92.65%
[100]	x	x	MVEDL (RoBERTa, BERTweet, CT-BERT)	91.75%
[120]	x	x	TClustVID (Ensemble method w. DL-Models)	>90%
[115]	x		Bidirectional LSTM	89.51%
[70]	x		Word2Vec + Multi-Layer Perceptron (MLP) + Twitter	83%
[106]	x		Polarity detection: LSTM + FastText, Emotion detection: LSTM + GloVe (Twitter)	Polarity detection: 82.4% Emotion detection: 81.9% (positive emotions); 69.9% (negative emotions)
[84]	x		RoBERTa	80.33%
[102]	x		BERT	78.94%
[111]	x		GloVe + DL model (RNN, CNN)	71%
[92]	x		GloVe + LSTM	66%
[105]	x		XLNet	63%

Abbreviations included in the table:

Bidirectional Encoder Representations from Transformers (BERT), Long-short term memory (LSTM), MVEDL is based on RoBERTa, BERTweet and CT-BERT, TClustVID is an ensemble method with Deep Learning models, Global Vectors for Word Representation (GloVe), Deep Learning (DL), Recurrent Neural Network (RNN), and Convolutional Neural Networks (CNN)

遏制大流行。情緒分析經常應用於醫療環境，為研究提供了豐富的機會[126]。在本節中，我們旨在重點介紹和討論 COVID-19 相關 Twitter 資料中效能最佳的 ML 分類演算法。

在仔細分析了 COVID-19 相關 Twitter 數據情感分析領域的現有研究後，我們的研究結果揭示了 COVID-19 Twitter 數據領域情感分析的廣闊前景。從技術角度來看，我們的結果表明，集成分類器對於 COVID-19 Twitter 數據特別有效。先前的研究已經表明，以獨特的方式組合各個分類器的預測的集成分類器比每個單獨的基本分類器具有更高的準確性 [127]。其他學者發現，理想情況下，分類器應該以更異質的方式組合，包括更多樣化的分類器集，即從 ML 到基於詞典的分類器，這可以導致性能提高 5% 以上 [127]。在我們的研究中，由於缺乏比較數據，我們無法批准這一發現。特別是在使用 DL 分類器的研究中，四個表現最好的分類器中有三個是集成分類器。這一發現與 Zimbra 等人的觀察結果完全吻合 [33]。其他在情感分析其他相關領域進行研究的學者也強調了集成分類器的卓越性能 [58]、[128]、[129]。這可以歸因於他們更好地處理階級失衡 [33]、[130]。

總的來說，在報告了績效指標的分類器中，最先進的 DL 分類器在納入的研究中得到了廣泛的應用，並與當前情緒分析研究的實踐相匹配 [59]

最先進的 DL 技術在 COVID-19 相關 Twitter 數據上顯示出高性能 [76]、[86]、[100]。與更傳統的方法相比，DL 方法有幾個優點：與需要不斷更新字典以包含新單字或縮寫的基於詞典的方法或需要耗時的特徵設計的傳統 ML 方法相比，DL 可以自動化特徵學習過程 [131]。我們的結果表明，包括上下文嵌入的 BERT 或 ROBERTa 等分類器已被證明對 COVID-19 Twitter 數據效果很好。這一發現也已在將情緒分析應用於災害預測的相關研究中得到證實。此外，分類器在特定領域的詞彙上進行了預訓練，以進行微調 [86]、[100]。我們看到了進一步研究的可能性，以更多地闡明預訓練部分的特徵。基於詞典的語言資源有助於克服正確處理 Twitter 數據的挑戰 [33]。

然而，必須對分類模型報告的準確性提出嚴格質疑。總體而言，報告了高精度，在一些研究中，它甚至超過了 90% 的準確率。這一發現與 Zunic 等人 [125] 的一項研究形成鮮明對比，該研究通過情感分析調查了健康和福祉，並報告了總體準確度較低。即使在報告績效指標的納入研究中，也並非所有研究都將各種分類器相互比較以得出最佳模型。此外，每項研究都使用不同的數據集、不同的預處理步驟和評估程序。因此，由於設計方法不同，上述研究與各自性能最佳的分類器之間的直接比較受到限制。因此，沒有

「一刀切」的分類器解決方案，其性能優於所有其他分類器。儘管如此，根據我們的發現，我們可以為 COVID-19 相關 Twitter 數據的情緒分析的技術實施提供具體建議。此外，我們提高了人們對使用情緒分析作為政府政策工具時必須考慮的常見挑戰的認識。

我們在絕大多數納入的研究中發現的一個主要缺點是單一資料集用於訓練、測試和效能評估。只有少數研究根據看不見的數據或在不同時間點提取的數據評估了他們的模型。當對新的、未見過的數據進行測試時，納入的研究顯示性能顯著下降 [70]、[124]。研究的普遍趨勢是最大限度地提高分類器對訓練數據的預測精度——這是監督機器學習中的常見問題 [132]。當機器學習模型被訓練為以最佳方式擬合訓練數據時，存在顯著的過度擬合風險，例如，模型整合了“噪聲”而不是搜索一般預測規則 [132]。我們強烈鼓勵未來的研究專注於最大限度地提高分類器對新數據的預測準確性，而不是訓練數據的準確性。進一步的研究應該調查其分類器在不同時間點的性能，並根據看不見的數據對其進行評估。

由於 ML 方法的性質，出現了另一個挑戰：它們需要大量標記數據才能達到預期結果 [63]。性能最佳的 DL 分類模型是在包含至少 5,000 條標記推文的數據集上進行訓練的。在大型資料集上訓練時，DL 模型比傳統 ML 模型更具優勢，因為它們可以學習更多表示並捕獲非線性和複雜模式 [32]。標記的資料集通常不可用，標記資料是一個繁瑣的過程。在我們的文獻綜述中，我們觀察到沒有標準的標記過程，研究訴諸於標記數據本身或使用模型，例如基於詞典的方法來標記數據。因此，沒有標準的標籤流程。遵守標籤指南可以確保數據首先被正確分類 [133]。否則，訓練的模型會因為錯誤標記的資料而產生偏差。最先進的深度學習模型通常被許多研究人員視為“黑盒子”。很難理解神經網路的動態，即其特徵選擇和預測過程 [32]。

在為 COVID-19 相關數據開發情緒分析工具時，我們觀察到分類模型的可轉移性存在很大的限制。大多數研究都依賴英文推文資料集。由於語言之間的語言和語義差異，無法推斷在英語數據集上效果良好的方法在非英語數據集上也具有相同的作用 [25]，[134]。這在 COVID-19 的背景下尤其重要。為了捕捉公眾的情緒，政府必須包含各種語言的推文。國家和社會的語言並不同質

如果只選擇一種語言的推文，可能會出現代表偏差 [135]。此外，在某些國家/地區，對 Twitter 的訪問受到限制，因此無法保證人口的真實代表。如果特定用戶群體在 Twitter 數據集中代表性過高或不足，情緒分析可能會導致誤導性結論。

特別是對於依賴預訓練或使用通用詞彙的分類模型，使用非英語推文尤其具有挑戰性，因為標準詞典幾乎完全是英語 [136]。進一步的研究應探索對英語以外的語言的 Twitter 數據進行情感分析，以將研究領域擴展到其他國家的政府和衛生組織。

六、結論

鑑於 COVID-19，政府和衛生組織分析社交媒體上公眾情緒的需求不斷增長。透過應用社會和行為科學研究的視角，我們探討了情緒分析如何為管理大流行提供相關資訊。文獻綜述是按照 PRISMA 指南進行的，旨在搜索和分類有關 COVID-19 Twitter 數據情感分析的現有文獻，特別關注 ML 技術。在著名期刊上發表的 425 篇初步研究中，有 40 篇論文是通過多階段篩選過程選出的。我們的研究旨在為政府和衛生當局提供有關 COVID-19 Twitter 數據情緒分析應用可能領域的指導，並激發創新應用程序和算法的開發。由於遏制大流行需要人類行為的重大改變，我們從社會和行為科學中採用了 van Bavel 等人 [1] 的結構。因此，決策者可以提取、分析和衡量公眾的思維、感受和行動，並利用這個“情緒儀表板”來設計以目標為導向的措施和傳播活動。我們更深入地比較了納入研究的機器學習分類方法的表現，並指出了缺點和需要進一步研究的領域。我們的研究結果表明，COVID-19 背景下的情緒分析主要是特定領域和應用程序的。這意味著在一個數據集上表現良好的分類技術不一定在另一個數據集上獲得令人滿意的結果。一般來說，大多數研究都依賴於英語數據集；因此，其結果的可轉移性可能會受到限制。在效能方面，我們發現包含各種 ML 分類器的集成模型通常優於單一分類器模型。此外，鑑於有足夠標記的數據，DL 分類器顯示出高精度。特別是，BERT 或 RoBERTa 模型在 Twitter 資料上進行預訓練時提供了有希望的結果。在與冠狀病毒和未來變種的日常鬥爭中，對 COVID-19 Twitter 數據的情緒分析可以為政府和衛生當局提供一種工具




圖 8.提取的 Twitter 數據的觀察期和研究發表日期的概述。

表 7. 根據資料集、推文數量、觀察週期、特徵、分類演算法和準確性對 ML 方法進行詳細分類。

Ref.	Dataset	Number of tweets	Observation period	Features and classification algorithm	Accuracy
[106]	1) Self-collected COVID-19 dataset for testing 2) Emotional tweets dataset for training	1) 27,357 2) 21,051	1) Early Feb. 2020 until the end of Apr. 2020 2) N/A	1) GloVe (Twitter) + LSTM 2) FastText + LSTM	1) 81.9% (pos. emotions); 69.9% (neg. emotions) 2) 82.4%
[90]	Self-collected COVID-19 dataset that is split in 80% data for training and 20% for testing	12,741	5 Apr. 2020 to 17 Apr. 2020	Unigram + LinearSVC	84.4%
[102]	Self-collected COVID-19 dataset of which 1% is manually annotated for training and 99% for testing	2,349,659	9 Nov. 2020 and 8 Dec. 2020	BERT	78.94%
[79]	1) COVID-19 dataset 2) Expo2020 dataset The authors merged both datasets and used 70% for training and 30% for testing	1) 120,000 2) 5,000	1) 11 May 2020 to 15 May 2020 and 27 Sep. 2020 to 3 Oct. 2020 2) 14 May 2020 and 16 May 2020	Word2Vec + Bayes Factor Tree Augmented Naive Bayes technique (BFTAN)	82.8%
[92]	LockdownTweets dataset (by Chen et al. 2020) where 1,098 randomly selected tweets got manually labeled and split into 733 labeled-train tweets and 365 labeled-test tweets	1,098	22 Jan. 2020 and 30 Sep. 2020	GloVe + LSTM	66%
[100]	WNUT 2020 Shared Task2 (Nguyen et al. 2020) contains around 10,000 tweets of which 7,000 tweets were used for training, 1,000 tweets were used for validation, and 2,000 tweets were used for testing	10,000	N/A	MVEDL Ensemble model consisting of RoBERTa, BERTweet, and CT-BERT	91.75%
[83]	Self-collected COVID-19 dataset of which 90% of the data is for training, 5% for validation, and 5% for testing	22,985	1 Jan. 2019 to 23 Mar. 2020	Trigrams and TF-IDF score + Logistic Regression	81.4%
[103]	Self-collected COVID-19 dataset of which the tweets were classified using five-fold cross-validation with a split ratio of 75% to train the classifiers	1,251,216	1. 20 Jan. 2020 to 29 May 2021	CrystalFeel Ensemble Voting Classifier (RF, SGD, LG)	95.04%
[120]	COVID-19 dataset, which is a subset of IEEE Data portal developed by Rabindra Lamsal	16,000,000	1 Jan. 2020 to 20 Mar. 2020	TClustVID (Ensemble method with DL-Models)	>90%
[115]	Self-collected COVID-19 dataset of which 10,000 tweets were manually labeled into 10 different emotions. Kabir and Madria applied a 5-fold cross-validation with that self-extracted dataset, using 80% of the tweets as training data and 20% as testing data	56,014,158	5 Mar. 2020 to 31 Dec. 2021	Bidirectional LSTM	89.51%
[70]	1) Nepal earthquake (2015) by Basu et al. (2019) for training 2) Italian earthquake (2016) by Basu et al. (2019) for training 3) Self-collected COVID-19 dataset for testing	1) 70,897 2) 51,846 3) 2,274	1) 2015 2) 2019 3) N/A	Word2Vec + MLP	83%
[109]	Self-collected COVID-19 dataset	293,597	30 Apr. 2020 to 8 May 2020	Various exploration techniques used: BOW, DTM, POS, DP and n-grams, Logit model	56.18%
[105]	Self-collected COVID-19 dataset	6,314,327	28 Sep. 2020 to 4 Nov. 2020	XLNet	63%
[84]	1) Self-collected COVID-19 dataset for testing 2) "Emotion in Text" dataset by Crowdfunder for training	1) 2,000,000 2) 39,740	1) Feb. 2020 to Jun. 2020 2) N/A	RoBERTa	80.33%
[77]	Self-collected COVID-19 dataset with a total of 11,000 tweets, 10,000 were used as training data and 1,000 as testing data	11,000	Feb. 2020 to Jun. 2020	Naive Bayes	92.49% short tweets (<70 characters), 60.56% long tweets (<150 characters)
[76]	1) Self-collected COVID-19 dataset for testing 2) Crowdfunder dataset for training and validation 3) Yelp dataset Challenge Repository 2015 for training and validation 4) Amazon dataset for training and validation	1) 4,242 2) 18,000 3) 299,000 4) 2,000,000	1) N/A 2) N/A 3) N/A 4) N/A	Ensemble Classifier (LSTM + FastText, BERT, ...)	92.65%
[86]	1) Self-collected COVID-19 dataset from various countries for training and testing 2) Self-collected COVID-19 dataset from India for training and testing 3) Github-data for testing	1) 417,023 2) 189,761 3) N/A	1) 20 Jan. 2020 to 25 Apr. 2020 2) 20 Jan. 2020 to 25 Apr. 2020 3) N/A	BERT	93.89%

表 7. (續) 根據資料集、推文數量、觀察週期、特徵、分類演算法和準確性對 ML 方法進行詳細分類。

[111]	Self-collected COVID-19 dataset	46,078,750	1 Jan. 2020 to 30 Apr. 2020	Pre-trained GloVe + Deep Learning Model (RNN, CNN)	71%
[95]	Self-collected COVID-19 dataset. A 5-fold cross-validation has been applied.	29,469,349	1 Feb. 2020 to 2 May 2020	TF-IDF Random Forest	96% (AUC ROC)

Abbreviations included in the table:

Global Vectors for Word Representation (GloVe), Long-short term memory (LSTM), Linear Support Vector Classifier (LinearSVC), Valence Aware Dictionary for Sentiment Reasoning (VADER), Bidirectional Encoder Representations from Transformers (BERT), MVEDL is based on RoBERTa, BERTweet and CT-BERT (all differentiations of BERT), Term Frequency-Inverse Document Frequency (TF-IDF), Affin, Random Forest (RF), Stochastic Gradient Descent (SGD), Logistic Regression (LR), Iterative deepening A* (IDA), Latent Dirichlet Allocation (LDA), TClustVID is an ensemble method with Deep Learning models, Multi-Layer Perceptron (MLP), Bag-Of-Words (BOW), Document term matrix (DTM), Part-of-Speech (POS), Dependency Parsing (DP), Recurrent Neural Network (RNN), and Convolutional Neural Network (CNN).

透過做出及時且明智的決策來改變大流行的軌跡。

A. 限制

我們的研究並非沒有局限性。由於系統文獻綜述的性質，我們的文獻檢索字串可能定義過於狹隘，沒有涵蓋所有相關研究。根據設計，我們僅包含來自知名數據庫的同行評審期刊論文，不包括會議論文。此外，還發現了進一步的局限性：首先，我們的研究沒有發現明確的模式表明某種分類器在哪種類別或情況下表現最好。其次，大多數研究都是基於英語數據集。因此，結果向其他非英語國家的可轉移性是有限的。第三，ML 分類模型在 COVID-19 背景下的穩健性尚未得到詳盡的檢查，並且可能無法證明應用情感分析而不是進行技術性較低的調查研究是合理的。第四，由於表述錯誤，推特上表達的觀點可能無法反映公眾的意見。

B. 未來工作

我們的文獻綜述已經確定了未來研究的幾個機會。遵循 van Bavel 等人的類別 [1]，未來的工作可以集中在未研究的主題“個人和集體利益”上，從行為和社會科學的角度進一步探索情感分析。從技術角度來看，我們認為需要未來的研究來刺激情緒分析在 COVID-19 背景下的實際應用的開發和實施。因此，分類演算法的性能應在不同時間點對新的、看不見的數據進行評估。此外，更關注交叉驗證的結果，而不是優化分類器對訓練資料的準確性，可能有助於為 COVID-19 Twitter 資料開發新的情緒分析應用程式。我們的研究表明，大多數納入的論文使用的數據集可以追溯到 2020 年前兩個季度

進行後續研究以評估所提出的分類模型在最新數據上的可用性會很有趣。這可以提供有關分類模型穩健性的更多信息。由於大多數納入的研究都是基於英語數據集，因此我們確定需要使用另一種語言的數據集進行情感分析。最後，我們希望通過將情緒分析與行為和社會科學研究相結合，激發更多的跨學科研究，支持抗擊 COVID-19 大流行。

附錄 A 版權聲明

“TWITTER、TWEET、RETWEET 和 Twitter Bird 徽標是 Twitter Inc. 或其附屬公司的商標 <https://about.twitter.com/en/who-we-are/brand-toolkit>。”
UXWing 的所有圖標均可免費下載，並可用於個人和商業項目 <https://uxwing.com/license>。
所有表情符號均由 OpenMoji 設計 - 開源表情符號和圖標項目。許可證：CC BY-SA 4.0 <https://openmoji.org>。

附錄 B 觀察期和出版日期

(見圖 8)

附錄 C 機器學習方法的詳細技術分類

(見表 7)

附錄 D SCIENCE DIRECT 的搜尋字串

在這裡，我們詳細介紹了 ScienceDirect 的搜索字串。在 ScienceDirect 資料庫中，布林運算子的限制為 8。此外，資料庫搜尋中不支援萬用字元 (“*”)。我們原始的搜尋字串有 10 個布林運算子和一個萬用字元。因此，搜尋字串會分割成下列三個搜尋字串：

- 1) (“情緒分析”) AND (“Twitter” OR “推文”) AND (“機器學習” OR “深度學習” 或 “自然語言處理” 或 “NLP”) 和 (“COVID-19” 或 “大流行”)

- 2) (“意見分析”) AND (“Twitter” OR “Tweet”) AND (“機器學習”或“深度學習”或“自然語言處理”或“NLP”) 和 (“COVID-19”或“大流行病”)
- 3) (“意見挖掘”) AND (“Twitter”或“推文”) AND (“機器學習”或“深度學習”或“自然語言處理”或“NLP”) 和 (“COVID-19”或“大流行病”)

搜尋字串 1) 產生 220 項研究，搜尋字串 2) 產生 7 項研究，搜尋字串 3) 產生 46 項研究。消除重複項後，在 ScienceDirect 數據庫中搜索總共產生 234 項研究。

鳴謝

(尼克拉斯·布雷格和阿麗娜·本茨對這項工作做出了同樣的貢獻。

參考

- [1] JJ Van Bavel 等人，“使用社會和行為科學來支持 COVID-19 大流行應對”，《自然人類行為》，第 4 卷，第 5 期，第 460-471 頁，2020 年 4 月。[2] D. Adam，“大流行的真實死亡人數：比官方統計多數百萬人”，《自然》，第 601 卷，第 7893 期，第 312-315 頁，2022 年 1 月。[3] S.-F. Tsao, H. Chen, T. Tisseverasinghe, Y. Yang, L. Li 和 Z. A. Butt，“社交媒體在 COVID-19 時代告訴我們的內容：範圍界定審查”，柳葉刀數字。《健康》，第 3 卷，第 3 期，第 e175-e194 頁，2021 年 3 月。[4] A. Górska, D. Dobija, G. Grossi 和 Z. Staniszevska，“共同度過 COVID-19：了解地方政府的社交媒體傳播”，《城市》，第 121 卷，2022 年 2 月，Art. 沒有 103453。[5] M. Perez-Cepeda 和 LG Arias-Bolzmann，“COVID-19 大流行期間的社會文化因素：Twitter 上的信息消費”，J. Bus. Res.，第 140 卷，第 384-393 頁，2022 年 2 月。
- [6] E. Chen, K. Lerman 和 E. Ferrara，“跟蹤有關 COVID-19 大流行的社交媒體話語：公共冠狀病毒 Twitter 數據集的開發”，JMIR 公共衛生監測，第 6 卷，第 2 期，2020 年 5 月，Art. 編號 E19273。[7] M. Paul 和 M. Dredze，“你就是你推特的東西：分析 Twitter 公共衛生”，載於 Proc. Int. AAAI Conf. Web Social Media，第 5 卷，第 1 期，2011 年，第 265-272 頁。
- [8] A. Amara, M. A. H. Taieb 和 M. B. Aouicha，“基於 Facebook 數據分析追蹤 COVID-19 趨勢的多語言主題建模”，Appl. Intell.，第 51 卷，第 5 期，第 3052-3073 頁，2021 年 2 月。[9] D. Antonakaki, P. Fragopoulou 和 S. Ioannidis，“Twitter 研究調查：數據模型、圖形結構、情感分析和攻擊”，Exp. Syst. Appl.，第 164 卷，2021 年 2 月，Art. 114006 號。
- [10] R. Buettner 和 K. Buettner，“Twitter 的系統文獻綜述從社會政治革命角度進行研究”，第 49 屆夏威夷國際會議 (HICSS)，2016 年 1 月，第 2206-2215 頁。
- [11] B. Pang 和 L. Lee，“意見挖掘和情感分析”，發現。Trends Inf. Retr.，第 2 卷，第 1-2 期，第 1-135 頁，2008 年 1 月。
- [12] S. Yousefinaghani, R. Dara, S. Mubareka, A. Papadopoulos 和 S. Shahrzad，“Twitter 上 COVID-19 疫苗情緒和意見的分析”，Int. J. Infectious Diseases，第 108 卷，第 256-262 頁，2021 年 7 月。
- [13] H. Piedrahita-Valdés, D. Piedrahita-Castillo, J. Bermejo-Higuera, P. Guillem-Saiz, J. R. Bermejo-Higuera, J. Guillem-Saiz, JA Sicilia-Montalvo 和 F. Machío-Regidor，“社交媒體上的疫苗猶豫：2011 年 6 月至 2019 年 4 月的情緒分析”，疫苗，第 9 卷，第 1 期，第 28 頁，2021 年 1 月。
- [14] S. Liu 和 J. Liu，“公眾對 COVID-19 疫苗的態度和英語 Twitter：情緒分析”，疫苗，第 39 卷，第 39 期，第 5499-5505 頁，2021 年 9 月。
- [15] S. 索馬里瓦, J. 莫特, HB 邦, H. 拉扎芬德萊貝, D. 拉托沃扎納尼, V. Rasoamanana, S. Abeyesekera, P. Muhamedkhojaeva, T. Bashar, J. James 和 M. Sani，“東部和南部非洲的社會聆聽，聯合國兒童基金會應對 COVID-19 信息流行病的風險溝通和社區參與戰略”，Health Secur.，第 19 卷，第 1 期，第 57-64 頁，2021 年 2 月。
- [16] A. Bandura，“自我效能：邁向行為改變的統一理論”，Psychol. Rev.，第 84 卷，第 2 期，第 191-215 頁，1977 年 2 月。
- [17] I. Aizen，“計劃行為理論”，Org. Behav. 管理。Process.，第 50 卷，第 2 期，第 179-211 頁，1991 年 12 月。
- [18] JR Martin 和 PRR White，評估語言。英國貝辛斯托克：Palgrave Macmillan，2005 年。[19] P. Korenek 和 M. Šimko，“微博利用的情緒分析”，評估理論，萬維網，第 17 卷，第 4 期，第 847-867 頁，2014 年 8 月。
- [20] C. Whitelaw, N. Garg 和 S. Argamon，“使用評估小組情緒分析”，在第 14 屆 ACM 國際會議論文集中。Manage.，2005 年 10 月，第 625-631 頁。
- [21] C. Soo-Guan Khoo, A. Nourbakhsh 和 J. Na，“情感分析在新聞文本：評估理論的案例研究”，Online Inf. Rev.，第 36 卷，第 6 期，第 858-878 頁，2012 年 11 月。
- [22] A. Kumar 和 A. Jaiswal，“基於群體智能的最優特徵選擇增強 Twitter 上的預測情緒準確性”，Multimedia Tools Appl.，第 78 卷，第 20 期，第 29529-29553 頁，2019 年 10 月。
- [23] A. Giachanou 和 F. Crestani，“不管你喜歡與否：Twitter sentiment 分析方法”，ACM Comput. Surv.，第 49 卷，第 2 期，第 1-41 頁，2016 年 6 月。
- [24] AH Alamoodi, BB Zaidan, AA Zaidan, OS Albahri, KI Mohammed, RQ Malik, EM Almahdi, MA Chyad, Z. Tareq, AS Albahri, H. Hameed 和 M. Alaa，“情緒分析及在對抗 COVID-19 和傳染病中的應用：系統評價”，Exp. Syst. Appl.，第 167 卷，2021 年 1 月，Art. 114155 號。
- [25] K. K. Agustiniingsih, E. Utami 和 H. Al Fatta，“情緒分析”Twitter 社交媒體上的 COVID-19 疫苗：系統文獻綜述，在 Proc. IEEE 5th Int. Conf. Inf. Technol.，Inf. Syst. Electr. 英語。(ICITISEE)，2021 年 11 月，第 121-126 頁。
- [26] AH Alamoodi, BB Zaidan, M. Al-Masawa, SM Tareh, S. Noman, AY Ahmaro, S. Garfan, J. Chen, MA Ahmed, AA Zaidan, OSA Albahri, U. Aickelin, NN Thami, JA Fadhil 和 A. Salahaldin，“情緒分析對疫苗猶豫應用的多視角系統評價”，計算。Biol. Med.，第 139 卷，2021 年 12 月，Art. 104957 號。
- [27] MJ Page 等人，“PRISMA 2020 聲明：更新指南報告系統性回顧”，系統修訂版，第 10 卷，第 1 期，2021 年 12 月，Art. 105906 號。
- [28] J. Bandy，“有問題的機器行為”，Proc. ACM Hum.-Comput. Interact.，第 5 卷，第 1 期。CSCW1，第 1-34 頁，2021 年 4 月。
- [29] M. V. Mäntylä, D. Graziotin 和 M. Kuuttila，“情感的演變”分析——對研究主題、地點和被引用次數最多的論文的重視，“計算。Sci. Rev.，第 27 卷，第 16-32 頁，2018 年 2 月。
- [30] E. Cambria, B. Schuller, Y. Xia 和 C. Havasi，“意見的新途徑離子挖掘和情緒分析”，IEEE Intell. 系統，第 28 卷，第 2 期，第 15-21 頁，2013 年 3 月。
- [31] NV Babu 和 EGM Kanaga，“社交媒體數據中的情緒分析”使用人工智慧進行憂鬱症檢測：綜述，J. Social Netw. 計算。科學，第 3 卷，第 1 期，第 74 頁，2021 年 1 月。
- [32] A. Yadav 和 DK Vishwakarma，“使用深度的情感分析學習架構：回顧”，Artif. 告訴。Rev.，第 53 卷，第 6 期，第 4335-4385 頁，2020 年 8 月。
- [33] D. Zimbra, A. Abbasi, D. Zeng 和 H. Chen，“最先進的 Twitter 情緒分析”，ACM Trans. Inf. Syst.，第 9 卷，第 2 期，第 1-29 頁，2018 年 6 月。
- [34] SR Rufai 和 C. Bunce，“世界領導人對 Twitter 的使用以回應 COVID-19 大流行：內容分析”，J. Public Health，第 42 卷，第 3 期，第 510-516 頁，2020 年。
- [35] U. Qazi, M. Imran 和 F. Ofli，“GeoCoV19：包含數百個的數據集數以百萬計的帶有位置資訊的多語言 COVID-19 推文”，SIGSPATIAL Special，第 12 卷，第 1 期，第 6-15 頁，2020 年。
- [36] O. Osagie, B. De La Iglesia, I. Lake 和 O. Edeghere，“Twitter 用於公共衛生研究的範圍界定審查”，Comput. 生物學。醫學，第 122 卷，2020 年 7 月，藝術。編號 103770。
- [37] Z. Nanli, Z. Ping, L. Weiguo 和 C. Meng，“情感分析：一升ature review”，在 Proc. Int. Symp. Manage. (ISMOT)，2012 年 11 月，第 572-576 頁。
- [38] K. Sunil 和 S. Beniwal，“情緒分析：挖掘意見的工具和情緒”，在 Proc. Int. Conf. Innov. 計算。公社，2020 年 12 月，第 1-8 頁，doi: 10.2139/ssrn.3746951。
- [39] R. Feldman，“情感分析的技術和應用”，Commun. ACM，第 56 卷，第 4 期，第 82-89 頁，2013 年。

- [40] E. Cambria, “情感計算和情感分析”, IEEE Intell. 系統, 第 31 卷, 第 2 期, 第 102-107 頁, 2016 年 3 月/4 月。
- [41] GA Miller, “WordNet”, 公社. ACM, 第 38 卷, 第 11 期, 第 39-41 頁, 1995 年 11 月。[42] Z. Drus 和 H. Khalid, “社交媒體中的情緒分析”, 在 Proc. 科學, 第 161 卷, 第 707-714 頁, 2019 年 1 月。
- [43] C. Bhadane, H. Dalal 和 H. Doshi, “情緒分析: 衡量意見”, Proc. Comput. 科學, 第 45 卷, 第 808-814 頁, 2015 年 1 月。[44] A.P. Jain 和 P. Dandannavar, “機器學習技術的應用”, 在 Proc. 2nd Int. Conf. Appl. Theor. 計算. 公社. (iCATccT), 2016 年 7 月, 第 628-632 頁。
- [45] M. Gonçalves, M. Araújo, F. Benevenuto 和 M. Cha, “比較和結合情感分析方法”, 載於第 1 屆 ACM 會議論文集。
- [46] K. Ayyub, S. Iqbal, E. U. Munir, MW Nisar 和 M. Abbasi, “探索-使用機器學習演算法進行情感量化的多樣化功能”, IEEE Access, 第 8 卷, 第 142819-142831 頁, 2020 年。
- [47] D. Effrosynidis, S. Symeonidis 和 A. Arampatzis, “Twitter 情緒分析預處理技術的比較”, 載於 Proc. 會議理論實踐. 數字. 圖書館, 2017 年 9 月, 第 394-406 頁。
- [48] Z. Jianqiang 和 G. Xiaolin, “Twitter 情感分析文本預處理方法的比較研究”, IEEE Access, 卷 5, 第 2870-2879 頁, 2017 年。
- [49] P. Han, S. Shen, D. Wang 和 Y. Liu, “單詞正規化在英文文檔聚類中的影響”, 收錄於 Proc. IEEE Int. Conf. Comput. 科學. (CSAE), 2012 年 5 月, 第 116-120 頁。
- [50] E. D'Andrea, P. Ducange, A. Bechini, A. Renda 和 F. Marcelloni, “從推文分析中監測有關疫苗接種主題的公眾輿論”, Exp. Syst. Appl., 第 116 卷, 第 209-226 頁, 2019 年 2 月。
- [51] S. Symeonidis, D. Effrosynidis 和 A. Arampatzis, “比較評估 Twitter 情緒分析的預處理技術及其交互作用”, Exp. Syst. Appl., 第 110 卷, 第 298-310 頁, 2018 年 11 月。
- [52] A. McCallum 和 K. Nigam, “天真的事件模型比較貝葉斯文本分類”, 在 Proc. AAAI 研討會學習. 文本分類, 第 752 卷, 第 1 期, 1998 年, 第 41-48 頁。
- [53] E.T. Jaynes, “信息理論和統計力學”, Phys. Rev., 第 106 卷, 第 4 期, 第 620-630 頁, 1957 年。[54] B. E. Boser, I. M. Guyon 和 V. N. Vapnik, “訓練支持向量機”, 在 Proc. AAAI 研討會學習. 文本分類, 第 752 卷, 第 1 期, 1998 年, 第 41-48 頁。
- [55] L. Breiman, “隨機森林”, Mach. Learn., 第 45 卷, 第 1 期, 第 5-32 頁, 2001 年 10 月。[56] A. Qazi, RG Raj, G. Hardaker 和 C. Standing, “系統文獻意見類型和情緒分析技術的評論”, Internet Res., 第 27 卷, 第 3 期, 第 608-630 頁, 2017 年 6 月。
- [57] M. Sokolova 和 G. Lapalme, “對性能的系统分析分類任務的措施”, Inf. Manage., 第 45 卷, 第 4 期, 第 427-437 頁, 2009 年 7 月。
- [58] Ankit 和 N. Saleena, “Twitter 情緒分析的集成分類系統”, Proc. Comput. 科學, 第 132 卷, 第 937-946 頁, 2018 年 1 月。[59] L. Zhang, S. Wang 和 R. Liu, “用於情感分析的深度學習”, A 調查, “WIREs 數據挖掘和知識發現”, 第 8 卷, 第 e1253 頁, 2018 年 3 月。
- [60] N. Jones, “計算機科學: 學習機器”, 《自然》, 第 505 卷, 第 7482 期, 第 146-148 頁, 2014 年 1 月。[61] L. Alzubaidi, J. Zhang, AJ Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamaria, MA Farhan, M. Al-Amidlo 和 I. Farhan, “深度學習回顧: 概念、CNN 架構、挑戰、應用、未來方向”, J. Big Data, 第 8 卷, 第 1 期, 第 1-74 頁, 2021 年 3 月。
- [62] Y. Bengio, Y. LeCun 和 GE Hinton, “人工智能深度學習”, Commun. ACM, 第 64 卷, 第 58-65 頁, 2021 年 6 月。
- [63] Y. LeCun, Y. Bengio 和 GE Hinton, “深度學習”, 《自然》, 第 521 卷, 第 436-444 頁, 2015 年 12 月。[64] I. Arel, DC Rose 和 TP Kanaouk, “深度學習應用”, A 調查, “WIREs 數據挖掘和知識發現”, 第 8 卷, 第 e1253 頁, 2018 年 3 月。
- [65] J. Gu, Z. Wang, J. Kuen, L. Ma, A. Shahroudy, B. Shuai, T. Liu, G. Wang, J. Cai 和 T. Chen, “卷積神經網絡的最新進展”, Pattern Recognit., 第 77 卷, 第 354-377 頁, 2018 年 5 月。
- [66] M. U. Salur 和 I. Aydin, “一種用於情感分類的新型混合深度學習模型”, IEEE Access, 第 8 卷, 第 58080-58093 頁, 2020 年。
- [67] S. Hochreiter 和 J. Schmidhuber, “長短期記憶”, Neural Comput., 第 9 卷, 第 8 期, 第 1735-1780 頁, 1997 年。[68] J. 德夫林, M.-W. Chang, K. Lee 和 K. Toutanova, “BERT: 用於語言理解的深度雙向轉換器的預訓練”, 在 Proc. NAACL-HLT, 2018 年 10 月, 第 4171-4186 頁。
- [69] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser 和 I. Polosukhin, “注意力就是你所需要的一切”, 在 Proc. 科學, 第 30 卷, 第 5998-6008 頁。
- [70] S. Behl, A. Rao, S. Aggarwal, S. Chadha 和 HS Pannu, “推特通過對 COVID-19 和自然災害危機的情緒分析進行救災”, 國際 J. Disaster Risk Reduction, 第 55 卷, 2021 年 3 月, Art. 102101。
- [71] Z. Taheri Zadeh, S. Rahmani, F. Alidadi, S. Joushi 和 K. Esmaeilpour, “社會孤立的抑鬱、焦慮和其他認知後果: 藥物和非藥物治療”, Int. J. Clin. 實踐, 第 75 卷, 第 12 期, 2021 年 12 月, Art. 102101。
- [72] (2022 年 3 月 1 日)。情況說明書: 拜登總統將宣布戰略解決我們國家的心理健康危機, 作為他第一次國情咨文中團結課程的一部分。白宮。[在線]。可用: <https://www.whitehouse.gov/briefing-room/statementsreleases/2022/03/01/fact-sheet-president-biden-to-announce-strategy-to-address-our-national-mental-health-crisis-as-part-of-univ-aenda-in-his-first-state-of-the-union-address/>
- [73] C. Betsch, “行為科學數據如何幫助緩解 COVID-19 危機”, 《自然人類行為》, 第 4 卷, 第 5 期, 第 438 頁, 2020 年 3 月。[74] N. 薩拉尼, A. 薩塞尼安, 法蘭克, R. 賈拉利, A. 瓦西, 雷加尼, S. 拉薩爾普, M. Mohammadi, S. Rasoulpoor 和 B. Khaledi-Paveh, “COVID-19 大流行期間普通人群壓力、焦慮、抑鬱的盛行率: 系統評價和荟萃分析”, 《全球化健康》, 第 16 卷, 第 1 期, 第 57 頁, 2020 年 12 月。
- [75] T. Sharot, “樂觀主義偏見”, Current Biol., 第 21 卷, 第 23 期, 第 R941-R945 頁, 2011 年 12 月。[76] A. Alsayat, “改進社交媒體應用程序的情緒分析”, Arabian J. Sci. Eng., 第 47 卷, 第 2 期, 第 2499-2511 頁, 2022 年 10 月。
- [77] BN Ramya, SM Shetty, AM Amaresh 和 R. Rakshitha, “聰明 Simon Bot 對新型 COVID-19 推文分層進行公眾情緒分析”, Social Netw. 計算. 科學, 第 2 卷, 第 3 期, 第 227 頁, 2021 年 5 月。
- [78] T. Yigitcanlar, N. Kankanamge, A. Preston, PS Gill, M. Rezayee, M. Ostadnia, B. Xia 和 G. Ioppolo, “社交媒體分析如何幫助當局做出與流行病相關的政策決策? 來自澳大利亞各州和領地的見解”, Health Inf. Sci. Syst., 第 8 卷, 第 1 期, 第 37 頁, 2020 年 10 月。
- [79] SM Alhashmi, AM Khedr, I. Arif 和 M. El Bannany, “使用在關鍵事件期間分析 Twitter 數據的混合分類方法”, IEEE Access, 第 9 卷, 第 141023-141035 頁, 2021 年。
- [80] SA Morshed, SS Khan, RB Tanvir 和 S. Nur, “影響基於大規模 Twitter 數據分析的叫車服務中的 COVID-19 大流行”, J. Urban Manage., 第 10 卷, 第 2 期, 第 155-165 頁, 2021 年 6 月。
- [81] K. Mohamed Ridhwan 和 CA Hargreaves, “利用 Twitter 數據了解公眾對新加坡 COVID-19 疫情的情緒”, Int. J. Inf. 管理. Data Insights, 第 1 卷, 第 2 期, 2021 年 11 月, Art. 100021。
- [82] S. Kaur, P. Kaul 和 PM Zadeh, “監測情緒的動態在 COVID-19 期間使用 Twitter 數據”, Proc. 科學, 第 177 卷, 第 423-430 頁, 2020 年 1 月。
- [83] K. Chakraborty, S. Bhatia, S. Bhattacharyya, J. Platos, R. Bag 和 AE Hassanien, “深度學習分類器對 COVID-19 推文的情緒分析——一項顯示受歡迎程度如何影響社交媒體準確性的研究”, Appl. Soft Comput., 第 97 卷, 2020 年 12 月, Art. 106754。
- [84] J. Choudrie, S. Patil, K. Kotecha, N. Matta 和 I. Pappas, “申請和了解先進、新穎的深度學習方法: 基於文本的 COVID 19 情緒分析研究”, Inf. Syst. Frontiers, 第 23 卷, 第 6 期, 第 1431-1465 頁, 2021 年 12 月。
- [85] R. Mittal, A. Mittal 和 I. Aggarwal, “情感效價的識別”, Social Netw. 計算. 科學, 第 11 卷, 第 1 期, 第 108 頁, 2021 年 12 月。
- [86] M. Singh, AK Jakhar 和 S. Pandey, “使用 BERT 模型對冠狀病毒對社會生活影響的情緒分析”, Social Netw. 紅門. 探礦, 第 11 卷, 第 1 期, 第 33 頁, 2021 年 12 月。

- [87] S. Billore 和 T. Anisimova, “恐慌性購買研究：系統性的升
ature 審查和未來的研究議程”, *Int. J. Consum. Stud.*, 第 45
卷, 第 4 期, 第 777-804 頁, 2021 年 7 月。
- [88] C. Prentice、J. Chen 和 B. Stantic, “COVID-19 的定時干預
和恐慌性購買”, *J. Retailing Consum. 服務*, 第 57 卷, 2020 年
11 月, 第 11 條, 102203 號。
- [89] M. Alsan 和 M. Wanmaker, “塔斯基吉和黑人健康”, *夸特. J.
Econ.*, 第 133 卷, 第 1 期, 第 407-455 頁, 2018 年 2 月。[90] P.
Gunta、S. Kumar、DD Suman 和 V. Kumar, “情感訂閱。
COVID-19 期間印度封鎖的 ysis: Twitter 案例研究”, *IEEE
Trans. 社會系統*, 第 8 卷, 第 4 期, 第 992-1002 頁, 2021 年
6 月。
- [91] Z. B. Nezhad 和 M. A. Deihimi, “分析伊朗的觀點
邁向 COVID-19 疫苗接種”, *IJID 地區*, 第 3 卷, 第 204-210
頁, 2022 年 6 月。
- [92] L. 苗, M. 最後, 和 M. Litvak, “在
COVID-19 大流行: 紐約州封鎖案例研究”, *Exp. Syst. Appl.*, 第
187 卷, 2022 年 1 月, Art. 不 115797。
- [93] X. Yu、MD Ferreira 和 FV Paulovich, “Senti-COVID19: An
用於從社交媒體檢測公眾對 COVID-19 的情緒和見解的交互式視
覺分析系統”, *IEEE Access*, 第 9 卷, 第 126684-126697 頁,
2021 年。
- [94] AR Rahmanti, DNA Ningrum, L. Lazuardi, HC 楊, 以及
Y.-C. Li, “用於疫情風險溝通的社交媒體數據分析: 印度尼西亞
COVID-19 大流行期間公眾對新規範的關注”, *Comput. 方法
Programs Biomed.*, 第 205 卷, 2021 年 6 月, Art. 106083 號。
- [95] R. Goel 和 R. Sharma, “使用在線研究領導者及其擔憂
危機時期的社交媒體——新冠疫情影响案例研究”, *Social Netw.
《礦業》*, 第 11 卷, 第 1 期, 第 46 頁, 2021 年 12 月。
- [96] M. Siegrist、L. Luchsinger 和 A. Bearth, “信任和風險的影響
對接受減少 COVID-19 病例的措施的看法”, *Risk Anal.*, 第 41
卷, 第 5 期, 第 787-800 頁, 2021 年 5 月。
- [97] HJ Larson, “最大的大流行風險? 病毒式錯誤信息”, *自然*, 第
562 卷, 第 7727 期, 第 309 頁, 2018 年 10 月。[98] J.
Benzenebak、CP Schneider、S. Durburst、I. Kern、AI I
G. Recchia、AM Van Der Bles 和 S. Van Der Linden, “對世界
各地有關 COVID-19 的錯誤信息的敏感性”, *Roy. Soc. Open
Sci.*, 第 7 卷, 第 10 期, 2020 年 10 月, Art. 沒有 201400。
- [99] Y. Madani、M. Erritali 和 B. Bouikhalene, “使用人工智能
檢測摩洛哥推文中 COVID-19 流行假新聞的技術”, *Results
Phys.*, 第 25 卷, 2021 年 6 月, Art. 沒有 104266。
- [100] S. Malla 和 PJA Alphonse, “COVID-19 爆發: 一個合奏
訓練有素的深度學習模型用於檢測信息推文”, *Appl. Soft
Comput.*, 第 107 卷, 2021 年 8 月, Art. 107495 號。
- [101] P. Sv、J. Tandon、Vikas 和 H. Hinduja, “印度公民的觀點
關於 COVID-19 疫苗的副作用——一項機器學習研究”, *糖尿病代
謝綜合徵, 克林. Res. Rev.*, 第 15 卷, 第 4 期, 2021 年 7
月, Art. 102172 號。
- [102] 洛杉磯. Cotfas、C. Delcea、I. Roxin、C. Ioanas、DS Gherai 和 F.
“最長的一個月: 從首次疫苗發布後一個月的推文中分析 COVID-
19 疫苗接種意見動態”, *IEEE Access*, 第 9 卷, 第 33203-
33222 頁, 2021 年。
- [103] M. Mahdikhani, “通過分析 COVID-19 大流行不同階段的輿論和
情緒來預測推文的受歡迎程度”, *國際雜誌。
管理. Data Insights*, 第 2 卷, 第 1 期, 2022 年 4 月, Art. 100053 號。
- [104] K. Petersen 和 JM Gerken, “#COVID-19: 探索性研究
Twitter 上主題標籤的使用範圍”, *《健康政策》*, 第 125 卷, 第
4 期, 第 541-547 頁, 2021 年 4 月。
- [105] H. Lyu、J. Wang、W. Wu、V. Duong、X. Zhang、TD Dye 和 J. Luo,
“社交媒體對潛在 COVID-19 疫苗的輿論研究: 告知異議、差異和
傳播”, *Intell. 醫學*, 第 2 卷, 第 1 期, 第 1-12 頁, 2022 年 2
月。
- [106] AS Imran、SM Daudpota、Z. Kastrati 和 R. Batra, “跨文化
使用情緒分析和深度學習對 COVID-19 相關推文進行極性和情緒
檢測”, *IEEE Access*, 第 8 卷, 第 181074-181090 頁, 2020
年。
- [107] K. Garcia 和 L. Berton, “來自巴西和美國的 Twitter 內容中與
COVID-19 相關的主題檢測和情緒分析”, *Appl.
Soft Comput.*, 第 101 卷, 2021 年 3 月, Art. 107057 號。
- [108] Z. Yao、J. Yang、J. Liu、M. Keith 和 C. Guan, “比較推文”
使用機器學習技術的特大城市的情緒: 在 COVID-19 之中, “城
市”, 第 116 卷, 2021 年 9 月, 藝術。沒有 103273。
- [109] M.M. 拉赫曼, G.G.M.N. 阿里, X.J. 李, J. 塞繆爾, K.C. 保羅,
P. H. J. Chong 和 M. Yakubov, “利用 Twitter 和人口普查數據分
析 COVID-19 美國重新開放情緒的社會經濟因素分析”,
Heliyon, 第 7 卷, 第 2 期, 2021 年 2 月, Art. 編號 E06200。
- [110] F. V. Surano、M. Porfiri 和 A. Rizzo, “COVID-19 大流行期間美國
封鎖感知的分析”, *Eur. Phys.*
專題, 第 231 卷, 第 9 期, 第 1625-1633 頁, 2022 年 7 月。
- [111] C. Caliskan, “美國的一點點如何感受
新冠肺炎 (COVID-19)? Twitter 對俄亥俄州大流行的定量分
析”, *J. Comput. 社會科學*, 第 5 卷, 第 1 期, 第 19-45 頁,
2023 年 5 月。
- [112] M. Makowski、SJ Truche 和 K. Schlegel, “孤獨-
COVID-19 大流行期間的活力和幸福: 與人格和情緒調節的關
聯”, *J. Happiness Stud.*, 第 22 卷, 第 5 期, 第 2323-2342
頁, 2021 年 6 月。
- [113] CL Jarzyna, “準社會互動、COVID-19 隔離和數字時代媒體”,
Human Arenas, 第 4 卷, 第 3 期, 第 413-429 頁, 2021 年 9 月。
- [114] A. L. Crum、S. Pater 和 A. Shawn, “重新思考壓力: 心靈的作田。
確定壓力反應的設定”, *J. Personality Social Psychol.*, 第 104
卷, 第 4 期, 第 716-733 頁, 2013 年 2 月。
- [115] M. Y. Kabir 和 S. Madria, “EMOCOV: 情感機器學習
使用 COVID-19 推文進行檢測、分析和可視化”, “在線社交網絡。
媒體”, 第 23 卷, 2021 年 5 月, 藝術。100135 號。
- [116] H. Kaur、S. U. Ahsaan、B. Alankar 和 V. Chang, “用於分析
COVID-19 推文的情緒分析深度學習算法”, *Inf.*
Syst. Frontiers, 第 23 卷, 第 6 期, 第 1417-1429 頁, 2021 年 12 月。
- [117] SV Praveen、R. Ittamalla 和 G. Deepak, “分析印度將軍
公眾對 COVID-19 期間焦慮、壓力和創傷的看法——一項針對
840,000 條推文的機器學習研究”, “糖尿病代謝綜合徵, 克林。
Res. Rev., 第 15 卷, 第 2 期, 第 667-674 頁, 2021 年 5 月。
- [118] J. Zhou、S. Yang、C. Xiao 和 F. Chen, “社區檢查”
COVID-19 大流行導致的情緒動態: 澳大利亞一個州的案例研
究, “Social Netw. 計算。科學”, 第 2 卷, 第 3 期, 第 201 頁,
2021 年 5 月。
- [119] C. Moreno 等人, “精神衛生保健應該如何改變作為結果——
COVID-19 大流行的後果”, *《柳葉刀精神病学》*, 第 7 卷, 第 9
期, 第 813-824 頁, 2020 年 9 月。
- [120] MS Satu、MI Khan、M. Mahmud、S. Uddin、MA Summers、
J. M. W. Quinn 和 MA Moni, “TClustVID: 一種用於調查
COVID-19 推文中主題和情緒的新型機器學習分類模型”, *Knowl.-
Based Syst.*, 第 226 卷, 2021 年 8 月, Art. 107426 號。
- [121] S. Praveen、R. Ittamalla 和 G. Deepak, “分析印度人的態度”
公民接種 COVID-19 疫苗——一項文本分析研究, “糖尿病代謝綜
合徵: 克林. Res. Rev.”, 第 15 卷, 第 2 期, 第 595-599 頁,
2021 年 2 月。
- [122] L. K. Hansen 和 P. Salamon, “神經網絡集成”, *IEEE Trans.*
模式識別. *Mach. Intell.*, 第 12 卷, 第 10 期, 第 993-1001 頁, 1990 年
10 月。
- [123] A. O. Akkrabarty 和 S. Bose, “60 天環遊世界: An
COVID-19 對全球在線新聞情緒影響的探索性研究”, *J.
Comput. 社會科學*, 第 3 卷, 第 2 期, 第 367-400 頁, 2020 年
12 月。
- [124] M. El-Han 和 GK Luli, “Twitter 上的 COVID-19 疫苗相關
討論: 主題建模和情緒分析”, *J. Med.*
Internet Res., 第 23 卷, 第 6 期, 2021 年 6 月, Art. 編號 E24435。
- [125] A. Zunic、P. Corcoran 和 I. Spasic, “健康和情緒分析
幸福: 系統評價”, *JMIR Med. Informat.*, 第 8 卷, 第 1 期,
2020 年 1 月, Art. 編號 E16023。
- [126] K. Denecke 和 Y. Deng, “醫療環境中的情緒分析:
新的機會和挑戰”, *阿蒂夫. 告訴. 醫學*, 第 64 卷, 第 1 期,
第 17-27 頁, 2015 年 5 月。
- [127] J. Kazmaier 和 J. H. van Vuuren, “合奏學習的力量——
情緒分析”, *Exp. Syst. Appl.*, 第 187 卷, 2022 年 1 月,
Art. 115819 號。
- [128] G. Wang、J. Sun、J. Ma、K. Xu 和 J. Gu, “情感分類:
合奏學習的貢獻”, *德西斯. 支持系統*, 第 57 卷, 第 77-93
頁, 2014 年 1 月。
- [129] R. Srivastava 和 M. P. S. Bhatia, “在線微文本情感分析的集成方
法”, 收錄於 *Proc. Int. Conf. Recent Adv. Innov.*
(ICRAIE), 2016 年 12 月, doi: 10.1109/ICRAIE.2016.7939525。
- [130] A. Hassan、A. Abbasi 和 D. Zeng, “Twitter 情緒分析: A
bootstrap ensemble framework”, 載於 *Proc. Int. Conf. Social
Comput.*, 2013 年 9 月, 第 357-364 頁。
- [131] Z. Pan 和 W. Xu, “公共衛生緊急情況下基於深度學習的情緒分
析”, 第 13 屆國際會議論文集。喻喻聲-馬赫。
賽伯倫. (IHMSC), 2021 年 8 月, 第 137-140 頁。

- [132] T. Dietterich, “機器學習中的過度擬合和計算不足”, ACM Comput. Surv., 第 27 卷, 第 3 期, 第 326-327 頁, 1995 年 9 月。
- [133] S. Mohammad, “情感計算應用指南: 理論和解決方案”, 在第 7 屆研討會計算中。Approaches Subjectivity, 情感社交媒體分析, 2016 年, 第 174-179 頁。
- [134] H. Peng, E. Cambria 和 A. Hussain, “對情感的回顧漢語研究”, Cognit. Comput., 第 9 卷, 第 4 期, 第 423-435 頁, 2017 年 8 月。
- [135] Y. Huang, D. Guo, A. Kasakoff 和 J. Grieve, “了解美國 Twitter 數據分析的區域語言變化”, Comput. Environ. Urban Syst., 第 59 卷, 第 244-255 頁, 2016 年 9 月。
- [136] MFRA Bakar, N. Idris, L. Shuib 和 N. Khamis, “情感分析” 嘈雜的馬來語文本: 藝術現狀、挑戰和未來工作”, IEEE Access, 第 8 卷, 第 24687-24696 頁, 2020 年。



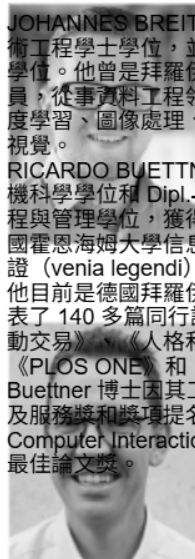
NIKLAS BRAIG 於 2019 年獲得奧地利因斯布魯克管理中心 (MCI) 的商業和管理學士學位。他目前正在德國拜羅伊特大學攻讀工商管理 M.Sc 學位。2017 年至 2018 年, 他在墨西哥自治技術研究所 (ITAM) 工作了一年。他目前的研究興趣包括企業財務和機器學習之間的交叉點。



ALINA BENZ 於 2019 年獲得德國奧格斯堡應用科學大學工商管理學士學位。她目前正在德國拜羅伊特大學攻讀工商管理碩士學位, 專攻資訊系統。她目前的研究興趣包括供應鏈管理和流程管理領域的機器學習和深度學習。



SOEREN VOTH 於 2021 年獲得德國拜羅伊特大學經濟學學士學位, 目前正在該校攻讀經濟學碩士學位, 專攻資訊系統。他目前的研究興趣包括機器學習、自然語言處理和深度學習。



JOHANNES BREITENBACH 於 2019 年獲得德國科堡大學汽車技術工程學士學位, 並於 2021 年獲得德國阿倫大學信息系統 M.Sc 學位。他曾是拜羅伊特大學資訊系統與資料科學系主任的研究員, 從事資料工程領域的工作。他的研究興趣包括機器學習、深度學習、圖像處理、材料科學、醫學和健康科學界面上的計算機視覺。

RICARDO BUETTNER (IEEE 高級會員) 獲得了 Dipl.-Inf. 計算機科學學位和 Dipl.-Wirtsch.-Ing. 德國伊爾梅瑙工業大學工業工程與管理學位, 獲得 Dipl.-Kfm. 德國哈根大學工商管理學位, 德國霍恩海姆大學信息系統博士學位, 德國特里爾大學信息系統認證 (venia legendi) 學位。

他目前是德國拜羅伊特大學信息系統和數據科學講座教授。他發表了 140 多篇同行評審文章, 包括《電子市場》、《AIS 人機互動交易》、《人格和個體差異》、《歐洲心理評估雜誌》、《PLOS ONE》和 IEEE A 上的文章。

Buettner 博士因其工作獲得了 17 篇國際最佳論文、最佳審稿人以及服務獎和獎項提名, 包括 AIS Transactions on Human-Computer Interaction、Electronic Markets 雜誌和 HICSS 頒發的最佳論文獎。