

G-EVAL：使用 GPT-4 進行 NLG 評估，並具有更好的人類對齊性

Yang Liu Dan Iter Yichong Xu
Shuohang Wang Ruochen Xu
Chenguang Zhu
Microsoft 認知服務研究
{yaliu10, iterdan, yicxu, shuowa, ruox, chezhu}@microsoft.com

摘要

自然語言生成 (NLG) 系統產生的文字品質很難自動衡量。傳統的基於參考的指標，如 BLEU 和 ROUGE，已被證明與人類判斷的相關性相對較低，特別是對於需要創造力和多樣性的任務。最近的研究建議使用大型語言模型 (LLMs) 作為 NLG 評估的無參考指標，其好處是適用於缺乏人類參考的新任務。然而，這些基於 LLM 的評估器仍然比中型神經評估器具有較低的人類對應性。在這項工作中，我們提出了 G-E，這是一個使用具有思維鏈 (CoT) 的大型語言模型和表單填寫範式的框架，以評估 NLG 輸出的品質。我們嘗試了兩個生成任務，文字摘要和對話生成。我們表明，以 GPT-4 為骨幹模型的 G-E 在摘要任務上與人類的 Spearman 相關性達到了 0.514，大大優於之前的所有方法。我們還提出了對基於 LLM 的評估者的行為進行分析，並強調了基於 LLM 的評估者對 LLM 生成的文本有偏見的潛在擔憂。

與人類判斷的相關性相對較低，特別是對於開放式生成任務。此外，這些指標需要相關的參考輸出，為新任務收集這些輸出的成本很高。

最近的研究建議直接使用 LLM 作為無參考的 NLG 評估器 (Fu 等人，2023 年; Wang 等人，2023 年)。這個想法是使用 LLM 根據其生成概率對候選輸出進行評分，沒有任何參考目標，假設 LLM 已經學會了為高質量和流暢的文本分配更高的概率。然而，使用 LLM 作為 NLG 評估器的有效性和可靠性尚未得到系統研究。此外，薈萃評估表明，這些基於 LLM 的評估器仍然比中型神經評估器具有較低的人類對應性

(Zhong et al., 2022)。因此，需要一個更有效、更可靠的框架來使用 LLM 進行 NLG 評估。

在本文中，我們提出了 G-EVAL，這是一個使用具有思維鏈 (CoT) 的 LLM 的框架 (Wei et al., 2022)，以表單填寫範式評估生成文本的質量。通過僅提供任務介紹和評估標準作為提示，我們要求 LLM 生成詳細評估步驟的 CoT。然後，我們將提示與生成的 CoT 一起使用來評估 NLG 輸出。評估者輸出被格式化為表格。此外，輸出評級代幣的機率可用於細化最終指標。我們對兩個 NLG 任務的三個元評估基準進行了廣泛的實驗：文本摘要和對話生成。結果表明，G-EVAL 在與人類評估的相關性方面可以大幅優於現有的 NLG 評估者。最後，我們對基於 LLM 的評估者的行為進行了分析，並強調了基於 LLM 的評估者對 LLM 生成的文本有偏見的潛在問題。

1 介绍

評估自然語言生成系統的品質是一個具有挑戰性的問題，即使大型語言模型可以產生高品質和多樣化的文本，而這些文本通常與人類編寫的文本沒有區別 (Ouyang et al., 2022)。傳統的自動指標，如 BLEU (Papineni et al., 2002)、ROUGE (Lin, 2004) 和 METEOR (Banerjee and Lavie, 2005)，被廣泛用於 NLG 評估，但它們已被證明

¹<https://github.com/nlpyang/geval>




圖 1：G-E 的整體框架。我們首先將任務介紹和評估標準輸入到 LLM，並要求它產生詳細評估步驟的 CoT。然後，我們使用提示以及產生的 CoT 來評估表單填寫範式中的 NLG 輸出。最後，我們使用輸出分數的機率加權總和作為最終分數。

總而言之，我們在本文中的主要貢獻是：

1. 在與人類品質判斷的相關性方面，基於 LLM 的指標通常優於基於參考和無參考的基線指標，特別是對於開放式和創造性的 NLG 任務，例如對話回應生成。
2. 基於 LLM 的指標對指令和提示很敏感，而思維鏈可以通過提供更多上下文和指導來提高基於 LLM 的評估者的績效。
3. 基於 LLM 的指標可以透過根據各自的標記機率重新加權離散分數來提供更精細的連續分數。
4. 基於 LLM 的指標存在一個潛在的問題，即更喜歡 LLM 生成的文本而不是人類書面文本，如果將基於 LLM 的指標用作自我改進的獎勵信號，這可能會導致 LLM 的自我強化。

2 術

G-EVAL 是一個基於提示的評估器，具有三個主要組件：1) 包含評估任務定義和所需評估標準的提示，2) 思維鏈 (CoT)，它是 LLM 生成的一組描述詳細評估步驟的中間指令，以及 3) 調用 LLM 並根據返回代幣的概率計算分數的評分函數。

NLG 評估提示提示是定義評估任務和所需評估標準的自然語言指令。例如，對於文字摘要，提示可以是：

您將獲得一篇為新聞文章撰寫的摘要。您的任務是根據一個指標對摘要進行評分。

請確保您仔細閱讀並理解這些說明。請在審閱時保持本文件開啟，並根據需要參考。

提示也應該包含自訂的評估-

不同 NLG 任務的 evaluation 標準，例如連貫性、簡潔性或語法。例如，為了評估文本摘要中的連貫性，我們將以下內容添加到提示中：

評審標準：

連貫性（1-5） - 所有句子的集體品質。我們將此維度與結構和連貫性的 DUC 品質問題保持一致，即「摘要應該結構良好且組織良好。摘要不應只是一堆相關信息，而應從一個句子到另一個句子構建為有關某個主題的連貫資訊主體。」

NLG 評估的自動思維鏈

思維鏈（CoT）是 LLM 在文字產生過程中產生的一系列中間表示。對於評估任務，有些標準需要超越簡單定義的更詳細的評估指令，並且為每個任務手動設計這樣的評估步驟非常耗時。我們發現 LLM 可以自行產生這樣的評估步驟。CoT 可以為 LLM 評估生成的文字提供更多的上下文和指導，也可以幫助解釋評估過程和結果。例如，為了評估文字摘要中的連貫性，我們在提示中加入一行「評估步驟：」，讓 LLM 自動產生以下 CoT：

1. 仔細閱讀新聞文章並確定主題和重點。
2. 閱讀摘要並將其與新聞文章進行比較。檢查摘要是否涵蓋了新聞文章的主題和要點，以及是否可以清晰、合乎邏輯的順序呈現它們。
3. 為連貫性分配分數
等級為 1 至 5，其中 1 為最低，5 為最高。

評分函數 評分函數使用設計的提示、自動 CoT、輸入上下文和需要評估的目標文字呼叫 LLM。與 GPTScore（Fu et al., 2023）不同，GPTScore 使用產生目標文字的條件機率作為評估指標

G-EVAL 直接使用表單填寫範式執行評估任務。例如，為了評估文字摘要的連貫性，我們將提示、CoT、新聞文章和摘要連接起來，然後呼叫 LLM 根據定義的標準，為每個評估方面輸出從 1 到 5 的分數。

不過，我們注意到這個直接評分函式有兩個問題：

1. 對於某些評估任務，通常以一位數字主導分數的分佈，例如 3 表示 1 - 5 的等級。這可能導致分數的變異數較低，與人類判斷的相關性較低。

2. LLM 通常只輸出整數分數，即使提示明確請求十進制值也是如此。這導致評估分數中有許多平局，這些分數無法捕捉生成文本之間的細微差異。

為了解決這些問題，我們建議使用 LLM 輸出標記的機率來歸一化分數，並將其加權求和作為最終結果。形式上，給定一組在提示 $S = \{s_1, s_2, \dots, s_n\}$ 中預先定義的分數（如從 1 到 5），每個分數 $p(s_i)$ 的機率由 LLM 計算，最終分數為：

$$\text{分數} = \sum_{i=1}^n p(s_i) \times \text{附註} \times \text{第 } i \text{ 條}$$

這種方法可以獲得更細粒度、連續的分數，更好地反映生成文本的質量和多樣性。

3 實驗

根據 Zhong 等人（2022 年），我們根據兩個 NLG 任務（摘要和對話響應生成）的三個基準（SummEval、Topical-Chat 和 QAGS）對評估者進行了盲評評估。

3.1 實作詳細資料

我們使用 OpenAI 的 GPT 家族作為我們的 LLM，包括 GPT-3.5（text-davinci-003）和 GPT-4。對於 GPT-3.5，我們將解碼溫度設定為 0，以增加模型的確定性。對於 GPT-4，由於它不支援代幣機率的輸出，我們將 'n = 20，溫度 = 1，top p = 1' 設定為採樣 20 次以估計代幣機率。我們使用 G-EVAL-4 來表示 G-EVAL 與 GPT-4

計量指標	連貫性 一致性 流暢度 相關性 AVG									
	ρ	τ	ρ	τ	ρ	τ	ρ	τ	ρ	τ
胭脂-1	0.167	0.126	0.160	0.130	0.115	0.094	0.326	0.252	0.192	0.150
胭脂-2	0.184	0.139	0.187	0.155	0.159	0.128	0.290	0.219	0.205	0.161
胭脂-L	0.128	0.099	0.115	-0.092	0.105	0.084	0.311	0.237	0.165	0.128
貝特斯科爾	0.284	0.211	0.410	0.090	-0.193	0.158	0.312	0.243	0.225	0.175
移動者分數	0.159	0.118	0.157	0.127	0.129	0.105	0.318	0.244	0.191	0.148
巴特核心	0.448	0.342	0.382	0.315	0.356	0.292	0.356	0.273	0.385	0.305
UniEval	0.575	0.442	0.446	0.371	0.449	0.371	0.426	0.325	-0.474	0.377
GPTScore	0.434	-0.449	-0.403	-0.381	-0.417	-0.417	-0.417	-0.417	-0.417	-0.417
G-EVAL-3.5	0.440	0.335	0.386	0.318	0.424	0.347	0.385	0.293	0.401	0.320
概率	0.359	0.313	0.361	0.344	0.339	0.323	0.327	0.288	0.346	0.317
G-EVAL-4	0.582	0.457	0.507	0.425	0.455	0.378	0.547	0.433	0.514	0.418
Probs	0.560	0.472	0.501	0.459	0.438	0.408	0.511	0.444	0.502	0.446
CoT	0.564	0.454	0.493	0.413	0.403	0.334	0.538	0.427	0.500	0.407

表 1：SummEval 基準上不同指標的匯總級 Spearman (ρ) 和 Kendall-Tau (τ) 相關性。G-E 沒有概率（斜體）不應被視為與 τ 上其他指標的公平比較，因為它會導致分數中有許多平局。這導致了更高的 Kendall-Tau 相關性，但它並不能公平地反映真實的評估能力。更多詳細信息在第 4 節中。

作為骨幹模型，G-EVAL-3.5 表示 G-EVAL，以 GPT-3.5 為骨幹模型。附錄中提供了每個任務的範例提示。

3.2 基準測試

我們採用三個薈萃評估基準來衡量 G-EVAL 與人類判斷之間的相關性。

SummEval (Fabbri 等人，2021 年) 是一個比較不同總結評估方法的基準。它對每個摘要的四個方面給出了人類評分：流暢性、連貫性、一致性和相關性。它建立在 CNN/DailyMail 數據集之上 (Hermann 等人，2015 年)

Topical-Chat (Mehri 和 Eskenazi，2020) 是一個測試平台，用於對使用知識的對話響應生成系統的不同評估者進行元評估。我們遵循 (Zhong 等人，2022 年) 將其人類評級用於

四個方面：自然、連貫、引人入勝和接地氣。

QAGS (Wang et al.，2020) 是評估摘要任務中幻覺的基準。它旨在衡量兩個不同摘要資料集上摘要的一致性維度。

3.3 基準線

我們根據實現最先進性能的各種評估者來評估 G-EVAL。

BERTScore (Zhang et al.，2019) 根據 BERT 的上下文嵌入來衡量兩個文本之間的相似性 (Devlin et al.，2019)。

MoverScore (Zhao 等人，2019) 通過添加軟對齊和新的聚合方法來改進 BERTScore，以獲得更穩健的相似性度量。

BARTScore (Yuan et al.，2021) 是一個統一的評估器，它使用預訓練編碼器-解碼器模型 BART (Lewis et al.，2020) 的平均似然進行評估。它可以根據源和目標的格式預測不同的分數。

FactCC 和 QAGS (Kry 'sci 'nski 等人，2020 年;Wang 等人，2020 年) 是兩個評估器，用於衡量生成摘要的事實一致性。FactCC 是一個基於 BERT 的分類器，用於預測摘要是否與源文檔一致。QAGS 是一個基於問答的評估器，它從摘要中生成問題並檢查是否可以在源文檔中找到答案。

USR (Mehri 和 Eskenazi，2020) 是從不同角度評估對話反應生成的評估器。它有多個版本，為每個目標響應分配不同的分數。

UniEval (Zhong et al.，2022) 是一個統一的評估器，可以評估文本生成的不同方面

2022) 是一個統一的評估器，可以將文字生成的不同方面評估為 QA 任務。它使用預訓練的 T5 模型 (Raffel et al., 2020) 將評估任務、來源和目標文字編碼為問題和答案，然後計算 QA 分數作為評估分數。它還可以透過改變問題格式來處理不同的評估任務。

GPTScore (Fu 等人, 2023) 是一個新框架，它使用 GPT-3 等生成式預訓練模型來評估文字。它假設生成式預訓練模型將按照給定的指令和上下文分配更高的質量生成文本的機率。與 G-EVAL 不同，GPTScore 將評估任務表述為條件生成問題，而不是表單填寫問題。

3.4 總結結果

我們採用與 Zhong 等人相同的方法

(2022 年)，使用摘要級 Spearman 和 Kendall-Tau 相關性來評估不同的摘要指標。表 1 的第一部分顯示了比較模型輸出和參考文本之間語義相似性的指標結果。這些指標在大多數維度上表現不佳。第二部分顯示了使用神經網路從人類對摘要品質的評級中學習的指標的結果。這些指標的相關性比基於相似性的指標高得多，這表明它們對於摘要評估更可靠。

在表 1 的最後一部分對應於基於 GPT 的評估器中，GPTScore 也使用 GPT 來評估摘要文本，但依賴於 GPT 對給定目標的條件機率。G-EVAL 在 SummEval 基準測試中大大超過了之前所有最先進的評估器。與 G-EVAL-3.5 相比，G-EVAL-4 在 Spearman 和 Kendall-Tau 相關性上實現了更高的人類對應關係，這表明 GPT-4 更大的模型大小有利於摘要評估。G-EVAL 在多個維度上也優於 GPTScore，證明了簡單表單填充範式的有效性。

3.5 對話生成的結果

我們使用 Mehri 和 Eskenazi (2020) 的 Topical-chat 基準來衡量不同評估者對對話反應質量的人類評分的同意程度。我們計算對話每一輪的 Pearson 和 Spearman 相關性。表 2 顯示，基於相似性的指標與人類具有良好的一致性

關於回應的吸引力和基礎性，但不取決於其他方面。關於基於學習的評估者，在 G-EVAL 之前，UniEval 預測的分數在各個方面都與人類判斷最一致。

如上一部分所示，G-EVAL 在 Topical-Chat 基準測試中也大大超越了之前所有最先進的評估器。值得注意的是，G-EVAL-3.5 可以與 G-EVAL-4 實現類似的結果。這表明這個基準測試對於 G-EVAL 模型來說相對容易。

3.6 幻覺結果

先進的 NLG 模型通常會產生與上下文輸入不匹配的文本 (Cao 等人, 2018 年)，最近的研究發現，即使是強大的法學碩士也存在幻覺問題。這促使最近的研究設計評估器來測量摘要中的一致性方面 (Kry 'sci 'nski 等人, 2020 年; Wang 等人, 2020 年; Cao 等人, 2020 年; Durmus 等人, 2020 年)。我們測試了 QAGS 元評估基準，其中包括兩個不同的摘要資料集：CNN/DailyMail 和 XSum (Narayan 等人, 2018 年) 表 3 顯示，BARTScore 在更具提取性的子集 (QAGS-CNN) 上表現良好，但在更抽象的子集 (QAGS-Xsum) 上相關性較低。UniEval 在資料的兩個子集上都有良好的相關性。平均而言，G-EVAL-4 在 QAGS 上的表現優於所有最先進的評估器，在 QAGS-Xsum 上有很大的優勢。另一方面，G-EVAL-3.5 在此基準測試中表現不佳，這表明一致性方面對 LLM 的容量很敏感。該結果與表 1 一致。

4 分析

G-EVAL 會更喜歡基於 LLM 的輸出嗎？使用 LLM 作為評估器的一個擔憂是，它可能更喜歡 LLM 本身產生的輸出，而不是高品質的人類編寫的文字。為了研究這個問題，我們在摘要任務上進行了一項實驗，比較了 LLM 生成的摘要和人類編寫的摘要的評估分數。我們使用 Zhang 等人 (2023 年) 收集的資料集，他們首先要求自由撰稿人為新聞文章撰寫高品質的摘要，然後要求註釋者比較人類撰寫的摘要和 LLM 產生的摘要 (使用 GPT-3.5, text-davinci-

計量指標	自然性	連貫性	吸引力	接地氣	AVG						
	r	r	r	r	r	r	r	r	r	r	r
胭脂-L	0.176	0.146	0.193	0.203	0.295	0.300	0.310	0.327	0.243	0.244	BLEU-4
0.180	0.175	0.131	0.235	0.232	0.316	0.213	0.310	0.189	0.259	0.212	流星
0.250	0.302	0.367	0.439	0.333	0.391	0.290	0.290	0.290	0.290	0.212	0.191
-0.367	0.439	-0.333	0.391	0.290	0.290	0.212	0.191	0.250	0.302	-0.367	-0.439
0.391	0.290	0.290	0.212	0.191	0.250	0.302	0.367	0.439	0.333	0.391	0.290
-0.290	0.212	-0.191	0.250	0.302	0.367	0.439	0.333	0.391	0.290	0.290	0.212
0.191	0.250	0.302	0.367	0.439	0.333	0.391	0.290	0.290	0.290	0.212	0.191
0.290	0.212	0.191	0.250	0.302	0.367	0.439	0.333	0.391	0.290	0.290	0.212

表 2：Topical-Chat 基準上不同指標的回合級 Spearman (ρ) 和 Kendall-Tau (τ) 相關性。

003).

資料集可以分為三類：1) 人類評委評分高於 GPT-3.5 摘要的人工撰寫摘要，2) 人類評委評分低於 GPT-3.5 摘要的人工撰寫摘要，以及 3) 人類評委對人類撰寫摘要和 GPT-3.5 摘要的評分相同。我們使用 GEVAL-4 來評估每個類別的摘要，並比較平均分數。

結果如圖 2 所示。我們可以看到，當人類評委也更喜歡人類撰寫的摘要時，G-EVAL-4 會給人類撰寫的摘要分配更高的分數，而當人類評委更喜歡 GPT-3.5 摘要時，G-EVAL-4 會給出較低的分數。然而，G-EVAL-4 總是給 GPT-3.5 摘要比人類撰寫的摘要更高的分數，即使人類評委更喜歡人類撰寫的摘要。我們提出了造成這種現象的兩個潛在原因：

1. 高品質系統的 NLG 輸出自然難以評估。原始論文的作者發現，註釋者間在判斷人類撰寫和 LLM 生成的摘要方面的一致性非常低，Krippendorff 的 α 為 0.07。
2. G-EVAL 可能對 LLM 生成的摘要有偏見，因為模型在生成和評估過程中可能共享相同的評估標準概念。

我們的工作應該被視為對這個問題的初步研究，需要更多的研究來充分理解基於 LLM 的行為。

我們在這個實驗中使用了 G-E-4，因為它在評估摘要任務方面具有優越性。儘管它與 GPT-3.5 的分佈不同，但這兩個 LLM 在文本生成方面應該具有相似的行




圖 2：G-E-4 對人工書面摘要和 GPT-3.5 摘要的平均分數，除以人類評委的偏好。

評估者減少其對 LLM 生成文本的固有偏見。我們在以下背景下強調了這一擔憂，即如果將評估分數用作進一步調整的獎勵信號，則基於 LLM 的評估者可能會導致 LLM 的自我強化。這可能導致 LLM 過度擬合其自己的評估標準，而不是 NLG 任務的真正評估標準。

思維鏈的影響我們在 SummEval 基準上比較了有和沒有有思維鏈 (CoT) 的 G-EVAL 的表現。表 1 顯示，G-EVAL-4 與 CoT 在所有維度上都比沒有 CoT 的 G-EVAL-4 具有更高的相關性，尤其是在流暢性方面。這表明 CoT 可以為 LLM 提供更多的上下文和指導來評估生成的文本，也可以幫助解釋評估過程和結果。機率歸一化的影響我們在 SummEval 基準測試中比較了有和沒有機率歸一化的 G-EVAL 的性能。表 1 顯示，在 KendallTau 相關性上，G-EVAL-4 的機率為

計量指標	QAGS-CNN QAGS-XSUM 平均值									
	r	r	t							
胭脂-2	0.459	0.418	0.333	0.097	0.083	0.068	0.278	0.250	0.200	胭脂-L
-0.357	0.324	0.254	0.024	-0.011	-0.009	0.190	0.156	0.122	BERTScore	0.576
0.505	0.399	0.024	0.008	0.006	0.300	0.256	0.202	MoverScore	0.414	0.202
347	0.271	0.054	0.044	0.036	0.234	0.195	0.153	事實 CC	0.416	0.484
0.297	0.259	0.212	0.356	0.371	0.294	QAGS	0.545	- -	0.175	- -
BARTScore	0.735	0.680	0.557	0.184	0.159	0.130	0.459	0.420	0.343	CTC
0.619	0.564	0.450	0.309	0.295	0.242	0.464	0.430	0.346	UniEval	0.682
0.662	0.532	0.461	0.488	0.399	0.571	0.575	0.465	G-EVAL-3.5	0.477	0.516
-0.410	0.211	0.406	0.343	0.344	0.461	0.377				
G-EVAL-4	0.631	0.685	0.591	0.558	0.537	0.472	0.599	0.611	0.525	

表 3：QAGS 基準上不同指標的 Pearson (r)、Spearman (ρ) 和 Kendall-Tau (τ) 相關性。

在 SummEval 上，有機率的 G-EVAL-4 不如沒有機率的 G-EVAL-4。我們認為這與 Kendall-Tau 相關性的計算有關，該相關性基於一致和不一致對的數量。沒有機率的直接評分可能會導致許多平局，這些平局既不算作一致，也不算作不一致。這可能會導致更高的 Kendall-Tau 相關性，但它並不能反映模型評估生成文本的真實能力。另一方面，概率歸一化可以獲得更細粒度、連續的分數，從而更好地捕捉生成文本之間的細微差異。這反映在 G-EVAL-4 與機率的較高 Spearman 相關性上，該相關性基於分數的排名順序。

模型大小的影響 我們比較每個 G-EVAL 在 SummEval 和 QAGS 基準測試中具有不同模型大小的表現。表 1 和表 3 顯示，除了 Topical-Chat 基準測試上的參與度和基礎性外，G-EVAL-4 在大多數維度和資料集上都比 G-EVAL-3.5 具有更高的相關性。這表明更大的模型大小可以提高 G-EVAL 的性能，特別是對於更具挑戰性和複雜性的評估任務，例如一致性和相關性。

它計算修改後的 n-gram 精度的幾何平均值和簡潔性懲罰。ROUGE (Lin, 2004) 是一種用於摘要評估的以召回為導向的指標，用於測量生成的摘要和一組參考摘要之間的 n-gram 重疊。研究表明，最近關於 NLG 的論文中有超過 60% 僅依賴 ROUGE 或 BLEU 來評估其系統 (Kasai 等人, 2021 年)。然而，這些指標無法衡量內容質量 (Reiter 和 Belz, 2009) 或捕獲句法錯誤 (Stent 等人, 2005 年)，因此無法準確反映 NLG 系統的可靠性。基於嵌入的指標基於嵌入的指標是指透過測量生成的文字和基於單字或句子嵌入的參考文字之間的語義相似性來評估 NLG 模型的分數。WMD (Kusner 等人, 2015 年) 是一個根據單字嵌入來衡量兩個文字之間距離的指標。BERTScore (Zhang 等人, 2019 年) 根據 BERT 的上下文文化嵌入來衡量兩個文本之間的相似性 (Devlin 等人, 2019 年)。MoverScore (Zhao 等人, 2019 年) 透過添加軟對齊和新的聚合方法來改進 BERTScore，以獲得更穩健的相似性度量。Clark 等人 (2019 年) 提出了一個指標，透過根據句子嵌入計算生成的文字和參考文字之間的相似性來評估多句子文字。

5 相關工作

基於 Ngram 的指標基於 Ngram 的指標是指通過測量生成文本和參考文本之間的詞彙重疊來評估 NLG 模型的分數。BLEU (Papineni et al., 2002) 是機器翻譯評估中使用最廣泛的指標

任務特定評估器任務特定指標
請參閱分數，透過根據特定任務要求測量生成文本的質量來評估 NLG 模型。例如，摘要任務需要評估生成的總和的一致性

摘要任務需要評估生成摘要的一致性

(Kry'sci'nski et al., 2020; Wang et al., 2020; Cao et al., 2020; Durmus et al., 2020), 對話回應生成任務需要評估生成回應的連貫性 (Dziri et al., 2019; Ye et al., 2021)。然而, 這些指標不能推廣到其他 NLG 任務, 也無法衡量生成文本的整體質量。

統一評估器最近, 開發了一些評估器, 透過改變輸入和輸出內容 (Yuan et al., 2021) 或他們使用的模型變體 (Mehri and Eskenazi, 2020) 來從多個維度評估文字品質。UniEval (Zhong et al., 2022) 是一個統一的評估器, 可以評估文字生成的不同方面作為 QA 任務。透過改變問題格式, 它可以處理不同的評估任務。

基於 LLM 的評估者 Fu 等人 (2023 年) 提出了 GPTScore, 這是一個使用 GPT-3 等生成式預訓練模型評估文本的新框架。它假設生成式預訓練模型將按照給定的指令和上下文分配更高的高質量生成文本的機率。Wang et al. (2023) 對使用 ChatGPT 作為 NLG 評估器進行了初步調查。Kocmi 和 Federmann (2023) 提議使用 GPT 模型來評估機器翻譯任務。

6 結論

在本文中, 我們提出了 G-EVAL, 這是一個使用 LLM 與思維鏈 (CoT) 來評估生成文本質量的框架。我們對文本摘要和對話生成這兩個 NLG 任務進行了廣泛的實驗, 並表明 G-EVAL 可以超越最先進的評估器並實現更高的人類對應性。我們還提出了對基於 LLM 的評估者的行為的初步分析, 並強調了基於 LLM 的評估器對 LLM 生成的文本有偏見的潛在問題。我們希望我們的工作能夠激發更多關於使用 LLM 進行 NLG 評估的研究, 並提高人們對使用 LLM 作為評估者的潛在風險和挑戰的認識。

參考

薩坦吉夫·班納吉和阿隆·拉維。2005. Meteor: 一種用於 mt 評估的自動指標, 具有改進的與人類的相似性。在 *ACL 研討會-關於機器翻譯和/或摘要的內在和外評估措施*, 第 65-72 頁。

關於機器翻譯和/或摘要的內在和外評估措施的 ACL 研討會-
tion, 第 65-72 頁。

曹孟、東岳、吳佳鵬和張傑傑。2020. 抽象摘要模型的事實糾正。在 *論文集*

2020 年自然語言處理實證方法會議 (EMNLP), 第 6251-6258 頁。

Ziqiang Cao, Furu Wei, Wenjie Li, and Sujian Li. 2018. 忠於原著: 事實感知神經抽象總結。在第三十二屆 AAAI 人工智能會議上。

伊麗莎白·克拉克、阿斯利·切利基爾馬茲和諾亞·史密斯。2019. 句子移動器的相似性: 多句文本的自動評估。計算語言學協會第 57 屆年會論文集, 第 2748-2760 頁。

雅各布·德夫林、張明偉、李肯頓和克里斯蒂娜·圖塔諾娃。2019. 伯特: 深度預訓練用於語言理解的雙向轉換器-
ing。計算語言學協會北美分會 2019 年會議論文集: 人類語言技術, 第 1 卷 (長論文和短論文), 第 4171-4186 頁。

埃辛·杜爾穆斯、何和莫娜·迪亞布。2020. Feqa: 抽象總結中忠實度評估的問答評估框架。在

計算語言學協會第 58 屆年會論文集, 第 5055-5070 頁。

努哈·齊里、埃桑·卡馬盧、科里·馬修森和奧斯馬爾·扎伊安。2019. 使用蘊含評估對話系統的連貫性。在 *論文集*

2019 年計算語言學協會北美分會會議: 人類語言技術, 第 1 卷 (長論文和短論文), 第 3806-3812 頁。

亞歷山大·法布里、沃伊切赫·克里科學、布萊恩·麥肯、熊彩明、理查德·索徹和德拉戈米爾·拉德。2021. 總結: 重新評估總結
評估。計算語言學協會彙刊, 9: 391-409。

Jinlan Fu, See-Kiong Ng, Zhengbao Jiang 和 Pengfei Liu. 2023. Gptscore: 隨心所欲地評估。
在 *論文集*

卡爾·莫里茨·赫爾曼、托馬斯·科西斯基、愛德華·格雷芬斯特特、拉塞·埃斯佩霍爾特、威爾·凱、瑪斯·赫爾曼和赫爾曼。2015. 新機器
並理解。神經信息處理系統的進展, 28。

Jungo Kasai、Keisuke Sakaguchi、Ronan Le Bras、Lavinia Dunagan、Jacob Morrison、Alexander R Fabbri、Yejin Choi 和 Noah A Smith。2021. 二維排行榜：攜手生成和評估語言模型。arXiv 預印本 arXiv：2010.04100。

湯姆·科奇米和克里斯蒂安·費德曼。2023. 大型語言模型是最先進的評估者
翻譯品質。arXiv 預印本 arXiv：2302.14520。

Wojciech Kry 'sci 'nski、Bryan McCann、Caiming Xiong 和 Richard Socher。2020. 評估
2020 年自然語言處理實證方法會議論文集 (EMNLP)，第 9332-9346 頁。

馬特·庫斯納、孫宇、尼古拉斯·科爾金和基利安·溫伯格。2015. 從單詞嵌入到文檔
距離。在機器學習國際會議上，第 957-966 頁。PMLR。

邁克·劉易斯、劉銀涵、納曼·戈亞爾、馬里安·加茲維尼內賈德、阿卜杜勒拉赫曼·穆罕默德、奧
BART：用於自然語言生成、翻譯和理解的序列到序列預訓練的去噪。計算語言學協會第 58 屆年會論文集，ACL 2020，在線，2020 年 7 月 5 日至 10 日，第 7871-7880 頁。

計算語言學協會。

林中耀。2004 年。胭脂：用於自動評估摘要的軟件包。在文本摘要分支中，第 74-81 頁。Shikib Mehri 和 Maxine Eskenazi。2020. Ustr：無監督且無參考的評估指標

對話生成。arXiv 預印本 arXiv：2005.00456。

沙希·納拉揚、謝伊·科恩和米雷拉·拉帕塔。2018. 不要給我細節，只給我總結！用於極端摘要的主題感知卷積神經網絡。2018 年自然語言處理實證方法會議論文集，第 1797-1807 頁。

歐陽龍、吳傑弗裡、江徐、迪奧戈·阿爾梅達、卡羅爾·溫賴特、帕梅拉·米什金、張崇、桑迪尼
2022. 訓練語言模型遵循人類反饋的指令。神經信息處理系統的進展，35：27730-

基肖爾·帕皮內尼、薩利姆·魯科斯、托德·沃德和朱偉靜。2002. Bleu：一種自動評估機器翻譯的
計算語言學協會第 40 屆年會，第 311-318 頁。

科林·拉菲爾、諾姆·沙澤爾、亞當·羅伯茨、凱瑟琳·李、莎蘭·納朗、邁克爾·馬特納、周燕琪、李偉和劉彼得。2020. 通過統一的文本到文本傳輸
舊。機器學習研究雜誌，21：1-67。

埃胡德·賴特和安雅·貝爾茲。2009. 對自動評估自然語言生成系統的一些指標有效性的調查。計算語言學，35 (4)：529-558。阿曼達·斯坦特、馬修·瑪吉和莫希特·辛海。

2005. 評估存在變異時生成的評估方法。第六屆計算語言學和智能文本處理國際會議論文集，第 341-351 頁。

亞歷克斯·王、曹京賢和邁克·劉易斯。2020. 提出和回答問題以評估摘要的事實一致性。計算語言學協會第 58 屆年會論文集，第 5008-5020 頁。

Jiaan Wang, Yunlong Liang, Fandong Meng, Haoxiang Shi, Zhixu Li, Jinan Xu, Jianfeng Qu, and Zhiyao Zhang。2023. Chatgpt 是一個好的 nlg 評估器嗎？一項初步研究。arXiv 預印本 arXiv：2303.04048。
傑森·魏、王雪芝、戴爾·舒爾曼斯、馬丁·博斯馬、埃德·奇、樂國和丹尼·周。2022. 思路提示引發大體推理語言模型。arXiv 預印本 arXiv：2201.11903。

Zheng Ye, Liucun Lu, Lishan Huang, Liang Lin, and Xiaodan Liang. 2021. Towards quantifiable
連續性評估。計算語言學協會第 59 屆年會和
第 11 屆自然語言處理國際聯合會議論文集 (第 1 卷：長論文)，第 2718-2729 頁。

Weizhe Yuan, Graham Neubig, and Pengfei Liu. 2021. Bartscore：將生成的文本評估為文本生成器
ation。神經信息處理系統的進展，34。

張天一、Varsha Kishore、Felix Wu、Kilian Q Weinberger 和 Yoav Artzi。2019. Bertscore：使用 bert 評估文本生成。arXiv 預印本 arXiv：1904.09675。

張天一、費薩爾·拉達克、埃辛·杜爾穆斯、梁珀西、凱瑟琳·麥基翁和橋本龍典。

2023. 對新聞摘要的大型語言模型進行基準測試。

Wei Zhao, Maxime Peyrard, Fei Liu, Yang Gao, Chris-田 M 邁耶和史蒂芬·埃格爾。2019. Moverscore：使用上下文嵌入和推土機距離評估文本生成。2019 年自然語言處理實證方法會議和第 9 屆自然語言處理國際聯合會議 (EMNLP-IJCNLP) 論文集，第 563-578 頁。

Ming Zhong, Yang Liu, Da Yin, Yuning Mao, Yizhu Jiao, Pengfei Liu, Chenguang Zhu, Heng Ji, and 韓佳偉。2022. 邁向用於文本生成的統一多維評估器。arXiv 預印本 arXiv：2210.07197。

範例提示

評估摘要任務中的一致性

您將獲得一篇為新聞文章撰寫的摘要。

您的任務是根據一個指標對摘要進行評分。

請確保您仔細閱讀並理解這些說明。請在審閱時保持本文件開啟，並根據需要參考。

評審標準：

連貫性（1-5） - 所有句子的集體品質。我們將此維度與結構和連貫性的 DUC 品質問題保持一致，即「摘要應該結構良好且組織良好。摘要不應只是一堆相關信息，而應從一個句子到另一個句子構建為有關某個主題的連貫資訊主體。」

評估步驟：

1. 仔細閱讀新聞文章，確定主題和重點。
2. 閱讀摘要並將其與新聞文章進行比較。檢查摘要是否涵蓋了新聞文章的主要主題和要點，以及是否以清晰、合乎邏輯的順序呈現。
3. 根據評估標準，以 1 到 5 的等級分配連貫性分數，其中 1 為最低，5 為最高。

例：

原文：

{{文件}}

摘要：

{{摘要}}

評估表（僅限分數）：

- 連貫性：

評估對話生成任務的參與度

您將獲得兩個人之間的對話。然後，您將在對話的下一回合獲得一個潛在的回應。該回應涉及一個有趣的事實，也將提供該事實。

您的任務是根據一個指標對回應進行評分。

請確保您仔細閱讀並理解這些說明。請在審閱時保持本文件開啟，並根據需要參考。

評估標準：

參與度（1-3） 回應是否沉悶/有趣？

- 分數 1（遲鈍）表示回應是通用且遲鈍的。
 - 2 分（有點有趣）表示回應有點有趣，可以讓您參與對話（例如，意見、想法）
 - 3 分（有趣）表示回應非常有趣或呈現有趣的事實
- 評估步驟：

1. 仔細閱讀對話、相應的事實和回應。2. 根據上述標準，以 1-3 的等級對回應的參與度進行評分。

3. 簡要解釋您的評分，參考回應和對話的具體方面。

例：

對話記錄：

{{文件}}

對應事實：

{{事實}}

反應：

{{回應}}

評估表（僅限分數）：

- 參與度：

評估幻覺

文字摘要系統的人工評估：

事實一致性：摘要是否包含源文本不支持的不真實或誤導性事實？

原文：

{{文件}}

摘要：

{{摘要}}

摘要是否包含事實不一致？

答：