




ScienceDirect 上提供的內容列表

決策支援系統

期刊主頁: www.elsevier.com/locate/dss

使用權杖分類自動識別使用者產生內容中的客戶需求

奧利弗·埃特里奇，斯文·斯塔爾曼，亨里克·利奧波德，克里斯蒂安·巴羅特

^a 德國庫內物流大學
^b 德國科隆大學

ARTICLE INFO

阿、乙、特、阿、克、特

關鍵詞：

數據驅動的決策 需求挖掘 代幣
分類 深度學習 產品開發

用戶每天都在互聯網上生成大量數據。這種所謂的用戶生成內容（UGC）對組織來說是有價值的輸入，因為它可能包括個人對其提供的產品和服務的經驗、意見和願望。為了自動處理 UGC，已經開發了自動化技術，通常稱為 Needmining。現有的 Needmining 方法通過將非結構化文本數據二分為需求內容和無需求內容進行二進制分類，從 UGC 中提取客戶需求。但是，他們無法提取特定需求。我們通過開發一個決策支持工件來解決這一研究差距，該工件將 Needmining 從二元分類問題重新概念化為標記分類問題，以從信息內容中提取特定需求。為了實現這一目標，我們將客戶需求分解為組件，即屬性和特徵，並開發代幣分類工件。工件準確識別需求組成部分，因此可以在用戶生成的內容中識別特定的客戶需求。我們組織和討論工件輸出的價值，並進一步豐富模型的情緒數據，以區分相關需求。如果應用，工件可以自動快速地識別相關的消費者需求，從而為產品開發領域的決策者實現效率提升。

1. 介绍

Web 2.0 網站和社交媒體平台每天都會產生大量數據。這種所謂的數字用戶生成內容（UGC）反映了用戶願意通過互聯網上的各種渠道分享的個人體驗。示例包括 Twitter 上的帖子、YouTube 上的視頻、Instagram 上的圖片，以及亞馬遜和阿里巴巴等電子商務平台上的電影評論、食物食譜和產品評論。

許多組織已經意識到 UGC 包含對客戶及其需求的寶貴見解，因此應該進行系統分析和探索。例如，UGC 可以支持決策者分析產品的競爭優勢 [1] 和預測公司股權價值 [2]。然而，UGC 大多被認為是非正式的輸入 [3]，可能是因為 UGC 的手動分析由於其大量和非結構化性質而既成本又耗時。已經有幾次嘗試在這方面提供自動化支持。在文獻中，這種從 UGC 自動引出和收集客戶需求的任務已被確立為“需求挖掘” [4]

這個想法是，通過 Needmining 提取的信息可以補充通過傳統商業實踐（例如調查、專家小組和現場觀察）產生的見解 [5]，從而支持產品開發和創新背景下的決策。

現有的 Needmining 方法將 Needmining 概念化為二元分類問題，即它們旨在確定給定的 UGC 是否包含需求。Kuehl 等人（2016）[4] 進行了最早的研究，他們研究了各種機器學習演算法在 Twitter 微博資料中將需求內容與無需求內容區分的能力。後來，其他幾位作者跟進並研究了機器和深度學習可以在多大程度上用於在 UGC 中區分資訊內容和無資訊內容 [5–7]。所有現有的 Needmining 方法的共同點是它們無法提取特定的客戶需求。透過將 Needmining 概念化為二元分類問題，他們只能檢測 UGC 是否包含需求。Kühl 等人（2020）[8] 透過多標籤分類器擴展了這種方法，將句子分類為預定類別。不過，此方法只會識別

* 通訊作者：Großer Grasbrook 17, 20457 Hamburg, Germany。

電子郵件地址: oliver.ettlich@the-klu.org (O. Ettlich)、stahlmann@wim.uni-koeln.de (S. Stahlmann)、henrik.leopold@the-klu.org (H. Leopold)、基督徒。
barrot@the-klu.org (C.巴羅特)。

<https://doi.org/10.1016/j.dss.2023.114107> 2022 年 12 月 21 日收到;2023 年 10 月 23 日以修訂表格
收到;2023 年 10 月 24 日接受

可在線獲取 2023 年 11 月 2 日 0167-9236/ © 2023 愛思
唯爾 B.V.版權所有。

在訓練樣本中先驗地存在的需求。這嚴重限制了它對決策者的有用性，因為未知的需求最有可能提供競爭優勢 [5]。

本研究遵循設計科學研究 (DSR) [9]，提出了一種新穎的 Needmining 方法，克服了現有工作的這一限制。為了實現這一目標，我們將 Needmining 問題從二元分類任務重新概念化為標記分類任務。這使我們能夠將問題從巨集層面（對評論和句子進行分類）到微觀層面（對單字和詞序進行分類），並提取描述給定客戶需求的確切單字。我們的方法使決策者能夠透過相應的文字內容來評估檢測到的需求，採用情感分析等技術，或透過計算它們在資料中的出現來估計重要性。透過提取特定需求，我們將自己與根據預定類別對句子進行分類的研究（如 Kuhl 等人（2020）[8]）區分開來，並提供發現以前未知需求的能力。

2. 問題陳述

Needmining 使從 UGC 中提取客戶需求變得大規模可行。然而，提高實現這一目標的效率仍有很大的潛力。之前所有研究的共同點是確定客戶在其 UGC 中表達的確切客戶需求所需的體力（人力）勞動量。文獻中還不止一次出現了一個研究空白，要求在 UGC 二元分類之後進一步自動化分析步驟 [4,5]。我們的研究旨在通過手動提取特定需求並有意義地組織它們來進一步自動化流程，從而提高 Needmining 的效率，從而解決這一研究差距。這為決策者提供了大量 UGC 客戶需求的即時概覽。

大量的 UGC 帶來了需要解決的特定技術挑戰。如上所述，這項研究將 Needmining 問題從二元分類轉移到標記分類。然而，在處理此類資料時，我們仍然可以參考先前的方法尋求建議。先前的二進位 Needmining 方法採用各種機器學習模型來分析非結構化資料。此外，機器學習的最新發展，特別是 transformer [10] 和遷移學習 [11] 的引入，顯著提高了自然語言處理的性能，使語言模型在處理文字資料時具有顯著優勢 [12]。與其他機器學習模型一樣，一旦經過訓練以執行特定任務，語言模型也可以輕鬆擴展到大型資料集，而無需額外的計算工作。因此，我們選擇實現基於 transformer 的語言模型，以反映最先進的性能並與其他方法競爭。

基於大量 UGC 的技術挑戰，我們建議訓練我們的標記分類器，以根據預先訓練的單字嵌入來檢測產品屬性和特徵。這種方法最適合本研究中指出的問題，因為它允許透過訓練基於專家輸入的模型，將專業知識整合到新需求的發現中。

3. 相關文獻

3.1. 客戶需求

客戶需求是行銷、創新和產品開發管理人員的重要資訊來源。它們為產品設計的管理決策提供資訊，這可能會影響單一產品的成功，進而影響整個企業的成功。儘管需求有很多定義，但我們專注於那些源自行銷和創新的定義。在行銷中，客戶扮演著至關重要的角色，因此定義以客戶為中心。一種常見的觀點認為客戶需求是詳細的

對客戶期望產品或服務實現的利益的自我表達描述，而不僅僅是解決方案或物理測量 [5,13]。另一種常見的觀點將需求分為三個不同的類別，即需求、願望和需求 [14-17]，其中需求是人類的基本需求，需求是需求吸引客戶的特定對象，需求是個人為對象付費的能力和意願 [16]。

在 Needmining 的上下文中，將客戶需求拆分為需求、願望和要求沒有任何好處。客戶專門創建用戶生成的內容，以使用自己的語言表達自己。在某些情況下，例如產品評論作為 UGC 的明確形式，營銷人員用於需求的定義更加貼合。客戶使用產品評論來描述他們對任何給定產品的體驗。它們通常包括有關他們對產品的期望、產品是否滿足他們的期望、他們期望產品滿足哪些需求、產品未滿足哪些需求，以及有時體驗產品產生哪些新需求的信息。

為了充分了解客戶需求，了解他們的一些應用也是相關的。有一種概念是產品是屬性的集合，旨在通過接近每個屬性的特定目標值來滿足客戶需求 [18]。這是聯合分析的一個關鍵原則，聯合分析是一種通過找到屬性和屬性目標值（或屬性維度）的完美組合來確定最佳產品設計的分析方法。一種聯合分析變體專門識別了產品屬性，這些屬性可以為客戶帶來獨特的好處 [19]，從而增強客戶需求和產品屬性之間的聯繫。

這些需求應用與需求採礦理論高度相容。當客戶表達他們對產品的體驗並透過解決缺乏的功能來批評他們的缺點時，屬性和屬性維度經常出現在 UGC 中。在本文的其餘部分，我們將屬性維度稱為特徵，因為它們描述了產品屬性的特徵。

3.2. 需求採礦

利用客戶需求進行創新正日益成為資訊系統文獻中的一個重要主題 [1,20,21]。Kuehl 等人（2016）[4] 最初創造了術語 Needmining 來描述他們的工件，該工件從 UGC 中提取包含包含內容的需求。一系列研究使用各種方法遵循了這種方法。然而，Needmining 相關研究的基本機制始終是一個二元分類器，它從需求內容中刪除不需要的內容。更籠統地說，它們將資訊內容與無資訊內容區分開來 [5]。

有一系列分類器已被用於 Needmining 的目的，例如支持向量機 [4,7]、朴素貝葉斯分類器 [4]、基於樹的分類器 [4] 和神經網絡 [5,6,22]。經驗證據表明，此類 Needmining 工具的應用可以通過識別新的需求來支持產品開發人員和創新經理的決策，否則這些需求在龐大的用戶生成內容中被證明是“大海撈針”[5]。Timoshenko 和 Hauser（2019）[5] 進一步支持了這一點，他們既為 Needmining 賦予了經濟價值，又用他們自己的話說，識別了“隱藏的機會”，即客戶評論分析揭示了客戶需求，但專業產品開發人員沒有發現。此外，Kühl 等人（2019）[23] 將文獻中的需求與 Twitter 微博數據中表達的需求進行了比較。他們發現這些來源之間需求的頻率分佈存在顯著差異。然而，他們強調了跟踪社交媒體與客戶需求的相關性，以使公司能夠更快地響應市場變化。

對使用者生成內容進行分類的研究發現的關鍵研究差距之一是需要手動分析來提取特定需求 [4,5]。然而，到目前為止，我們只討論了 Needmining 作為二元分類問題。這意味著可用的自動化

方法只能將資訊內容與非資訊內容分開，而客戶需求的進一步處理和分析仍然是手動工作。我們認為 Needmining 的範圍也需要包括下游步驟的自動化。具體來說，我們建議在 Needmining 中添加第二個支柱，用於處理從 UGC 自動提取特定客戶需求。在下文中，我們將討論處理 Needmining 的第二個支柱並與我們的研究相關的研究。Kühl 等人 (2020) [8] 通過創建一個工件，使用監督機器學習將 UGC 分配給預定的需求類別，從而為需求提取過程做出了貢獻。這是邁向全自動需求採礦方法的關鍵一步，包括提取特定需求。然而，專家們仍然必須為每個研究領域確定相關類別，這是大量的體力勞動。其他研究應用了前面討論的產品作為屬性向量的觀點，例如，通過使用詞性標記和基於字典的情感分析來識別和評估屬性 [24]。它們解決了挖掘用戶生成內容的關鍵問題，特別是大量可用內容、可用內容中缺乏相關信息，以及推而廣之，客戶和生產者在分析此類內容時可能遇到的缺乏監督。Roelen-Blasberg 等人 (2022) [25] 還使用詞性標記結合依賴解析來從 UGC 中提取名詞-形容詞組合。隨後，他們通過單詞嵌入將它們分組在一起，並通過情感分析和聯合分析來評估屬性的重要性。這種方法在單詞層面上發揮作用；然而，我們假設在單詞層面需求挖掘的背景下，這將導致許多誤報識別，因為沒有過濾器來確定這些組合中的哪些代表相關需求。相比之下，Lee 和 Bradlow (2011) [26] 使用將句子轉換為單詞向量、餘弦相似性和 K 均值聚類等方法組合，從產品評論中識別產品屬性和特徵，這些評論表示為積極和消極方面列表。他們的研究結果支持這樣一種觀點，即傳統的市場研究方法，例如專家小組和調查，很可能會忽略重要的產品屬性，否則這些屬性可能會為管理決策提供資訊。最後，Wang 等人 (2022) [27] 將聚類方法應用於嵌入空間，以確定產品專家在自動預處理文本數據後手動提取的“工程屬性”與更相關的產品優勢之間的關係。

其他間接的 Needmining 研究包括使用網絡學和情感分析來識別相關關鍵字並將其與客戶服務的特定方面聯繫起來的方法 [28]，以及使用他們所謂的語義網絡分析和詞空間模型（即詞嵌入）來過濾 UGC [29] 來尋找需求-解決方案對。雖然這些研究也與 Needmining 相關，但與其他更自動化的方法相比，它們需要更多的體力勞動來識別需求。然而，兩者都為已確定的客戶需求的後處理提供了寶貴的見解，特別是情感分析有助於量化已確定的需求，以實現產品開發的進一步步驟。

最後，可以說，LDA [30] 等主題建模方法可以用於詞級需求挖掘，因為這種方法用於描述主題的詞可以代表需求。然而，此類信息的有效性有其缺點，因為需要大量勞動力來分析此類模型創建的潛在主題並將信息轉化為需求。

3.3. 代幣分類

在自然語言處理中，標記化是指將文本分割成更小的基本處理單元，稱為標記 [31]。標記通常代表單詞級單位，而最近的深度學習研究使用子單詞標記 [11,32]。文本的標記化是其在許多任務中進一步處理的先決條件，例如，用於解析器的句法分析、文本挖掘或信息檢索。

權杖分類是一種對字串內給定範圍進行分類的方法。

在字串「天氣很好」中，每個單字都獲得一個位置編碼。跨度是這些單字位置的序列。如果「The」獲得位置一，而「nice」獲得位置四，則跨度 1:2 將代表單字「天氣」。與文字分類相反，該模型預測文字中的每個標記，而不是對整個文字進行單一預測（見圖 1）。這種方法最著名的應用是「命名實體識別」。命名實體識別是識別字串中特定子字串並根據模型訓練的內容對它們進行分類的過程，例如人員、位置、數值、公司或國家 [33]。假設模型經過訓練來檢測這些類別，我們期望它能夠識別出句子「Michael Jeffrey Jordan 出生於紐約布魯克林」中的三個跨度或實體：Michael Jeffrey Jordan (人)、布魯克林 (地點) 和紐約 (地點) [34]。

有許多不同的架構可用於命名實體識別，然而，深度學習和神經網路似乎在命名實體識別任務中設定了最高基準 [35]。理論上，如果有簡潔的訓練資料，實體的樣子就沒有限制。此前，研究使用命名實體識別進行詞性標記 [36]，以及從特定領域的文獻中提取生物醫學實體 [37,38]。然而，命名實體識別在廣泛的應用中發揮著重要作用，例如資訊提取、問答、機器翻譯、文字摘要、文字聚類、意見挖掘等 [39]。由於 Needmining 是資訊提取的應用，因此我們將 Needmining 問題從二元分類重新概念化為標記分類問題。在下一節中，我們將在概念層面上介紹我們的 Needmining 方法。

4. 研究方法和工件設計

4.1. 設計科學研究

該設計科學項目以 Kuechler 和 Vaishnavi (2008) [40] 的設計科學研究過程模型為指導。圖 2 說明了我們對該過程模型的應用，並顯示了我們用於生成有助於知識庫的相關工件的研究步驟的結構。第一步，也可以說是最關鍵的一步，是通過收集利益相關者的見解並進行深入的文獻分析來清晰地理解問題。清楚地了解基於 Needmining 領域的問題、客戶需求的組成以及客戶需求的應用是對知識庫做出有影響力貢獻的關鍵。接下來，我們開發問題的初步解決方案。這個過程步驟是根據我們對上一步中提出的問題的理解和我們廣泛的文獻綜述來決定的。我們將這些解決方案轉化為工件特徵，我們設計這些特徵是為了直接解決我們的解決方案的現有問題。最後，我們根據合適的性能指標評估和討論工件，並總結我們的研究結果。

4.2. 需求

從實際角度來看，與專門從事數據驅動創新公司的行業專家的對話揭示了從產品評論中提取相關信息的幾個問題。首先，他們重申，大量內容對產品開發人員來說是一個問題，因為分析所需的輸入成本太高。這不僅包括閱讀評論，還包括手動分析、提取和組織內容中的信息。專家們提到，只需閱讀一小部分評分最好和最差的評論，就可以深入了解某些現有產品成功或失敗的驅動因素。然而，研究表明，這可能意味著錯過與新產品開發相關的“隱藏需求”，因為他們迷失在




圖 1.文字分類和標記分類的概念模型架構。



圖 2.基於 Kuechler 和 Vaishnavi (2008) 的設計科學研究過程。

研究表明，這可能意味著錯過與新產品開發相關的“隱藏需求”，因為它們會吸引更廣泛的關注和討論，而不是客戶需求。然而，由於我們可以將需求分成兩部分，因此可以組織訊息，以便我們可以快速識別客戶對某個屬性所說的所有內容。在 AirPods 保護殼的範例中，我們還可以捕獲有關其他需求的訊息，例如重量、顏色、電池壽命等。這說明了我們如何將客戶需求分解為子部分，以識別對產品開發人員有用的資訊。

了解客戶需求的組成部分使我們能夠指定一種機器學習方法來提取相關的屬性特徵組合，這超出了先前 Needmining 方法的二進位方法。為此，有必要確定以正確粒度發揮作用的方法。在文獻綜述中，我們已經將權杖分類確定為一種專為此目的而設計的方法，因為它允許我們根據自訂資料訓練機器學習模型，以對句子中的特定單字進行分類。這特別有效，因為由於轉換器和遷移學習，對自然語言處理的進步有了新的見解。總而言之，工件必須能夠從大量 UGC 中提取不同的客戶需求，然後有意義地總結這些需求，以提供易於存取的概述。

接下來，我們必須了解管理者在 UGC 中尋求什麼，以便他們可以用來做出明智的決策。在先前的 Needmining 研究中，這是體力勞動從演算法識別為需要包含的 UGC 中提取客戶需求的過程步驟。因此，我們需要了解什麼構成了特定的客戶需求。為了實現這一目標，我們將我們的問題理解與有關客戶需求的文獻相結合，以找出相關的客戶需求如何在 UGC 中體現出來。

我們將產品作為屬性和特徵向量的觀點與客戶需求的定義（客戶期望從產品中獲得的好處）相結合。在產品評論的背景中，我們發現客戶透過指定所需的屬性和特徵來表達他們的需求。屬性通常描述產品的某個功能，而特徵則描述該功能應如何實現。例如，考慮第三代 Apple AirPods 評測中的以下一句話：遺憾的是，充電盒仍然無法無線充電。在這句話中，客戶將「外殼」作為屬性，將「無線充電」作為特徵，以表達他們總體上需要具有無線充電功能的外殼。雖然句子包含其他信息，例如情感（「羞恥」）和否定（「仍然不能」），但特徵-屬性組合捕捉了需求的本質，而附加信息僅提供上下文。

4.3. 型號規格

在本章中，我們開發了工件實現其主要目標的必要步驟，即從 UGC 中確定確切的客戶需求。我們在圖 3 中總結了這些步驟，提供了通用的步驟並將它們與具體示例相結合。首先，該方法需要輸入，該輸入通過一個過程來產生輸出，幫助決策者進行產品開發和創新過程。因此，第一步需要某種形式的內容採樣作為輸入。

產品經理可以從一系列平台對 UGC 進行採樣，例如文本內容，例如來自在線商店（例如亞馬遜、沃爾瑪、Costco）的評論、博客文章（例如 Twitter 和 Reddit）、轉錄的視頻評論和對這些視頻的評論（例如 YouTube）。有了這樣的來源，決策者可以創建高度多樣化的數據或特定數據，例如通過考慮一系列競爭對手對單個產品類別的評論，或者分別僅考慮主要競爭對手的產品。為了獲得所需的輸出，即有組織的特定客戶需求，數據必須經歷一個轉換步驟，提取相關的特徵屬性組合。如前所述，這是我們將 Needmining 從二元問題重新概念化為標記分類問題的步驟。因為我們採用了機器學習演算法，所以該過程的第一步是讓工件將非結構化文字資料（即產品評論）轉換為機器可解釋的格式，用於下游任務。為了實現這一目標，我們首先對每條評論應用句子標記化，以有效地將評論拆分為單獨的句子。為此，我們使用自然語言工具包。稍後，此步驟允許決策者在可能需要額外資訊的情況下快速識別需求的來源。我們還嘗試根據整個評論而不是句子進行標記化，但發現它降低了模型的效能。此外，在句子層級進行操作的優勢是，對於後續步驟（例如情感分析）進行更精細的分析，因為我們維護了更多的資訊。

下一步是“標記嵌入”。在這裡，我們將評論句子轉換為標記。對於我們的嵌入策略，我們使用了字節對編碼（BPE）。BPE 將單詞進一步拆分為子單詞以生成最終的標記。例如，它可以將單詞“煩人”拆分為標記 煩人 和 ly。我們選擇這種標記化策略是因為它能夠保留複合詞結構的含義。從這些標記中創建最終的嵌入，這是單詞在實值向量空間中的上下文表示，其中具有相似含義的單詞彼此更接近 [41]。為了轉換文檔，我們將矢量化文檔通過預訓練的轉換器。我們測試了這一步各種流行的基於預訓練 Transformer 的模型（BERT [11]、RoBERTa [32]、XLNet [42]、ALBERT [43]、DistilBERT [44]）。預訓練嵌入 [11] 是現代自然語言處理模型在計算效率更高和性能更好的關鍵。

接下來，該方法繼續進行“標記分類”，其中神經網絡做出最終預測。首先，使用均值池層池化子詞標記來生成單詞嵌入。然後，這些嵌入被輸入到一個三層全連接的神經網絡中，該網絡輸出最終預測。令牌分類器需要識別產品屬性和屬性特徵。但是，只有在客戶在評論設置中明確討論這些內容而不是在通用句子中的情況下，它才必須這樣做。當客戶對屬性發表通用評論而沒有為其分配可量化的價值時，它對產品開發人員毫無用處。可能發生的大量邊緣情況清楚地表明了為什麼基於規則的系統不適合此類任務。例如，考慮一下在亞馬遜上找到的有關固態硬盤驅動器的評論的以下部分：“快速啟動時間，冷啟動平均 18 秒”。在這句話中，

boot」可能被視為屬性，而「fast」是屬性特徵。然而，在句子的後半部分，我們再次遇到屬性「boot」和潛在特徵「cold」，它們提供了一個我們不希望分類器偵測這些標記的設定。

這就是基於 transformer 的上下文標記嵌入和神經網絡的組合變得相關的地方，因為各個標記相對於彼此的位置編碼教導了上下文標記可能被分類或可能不分類的神经网络。實際上，工件應該僅將相關跨度分類為屬性或特徵。為了實現這一目標，我們要求註釋的訓練數據具有高精度，以僅反映相關標記。

成品的最後一步是「需求擷取」。在最後一步中，我們組織預測的屬性和特徵，以提供所有客戶需求的快速概觀。這些屬性是消費者想要在評論中討論的產品功能。對於決策者來說，它們是有用的資訊，因為它們暗示了客戶想要改變的產品。因此，我們為每個屬性建立提及的頻率概觀，以確定客戶討論最多的內容。接下來，我們將每個屬性與其各自的特徵結合，即出現在出現該屬性的句子中的所有特徵。這會產生與每個屬性相關聯的特徵概觀。如需其他資訊，我們會新增每個已識別屬性特徵組合出現的每個完整句子的清單。這為決策者提供了一個快速概觀，以重申消費者在什麼情況下討論已識別的需求，並且與現有的權杖分類管道有很大不同。

總而言之，該工件提供了幾個概念和技術貢獻。首先，我們通過將這個抽象概念拆分為更明確的組件（即屬性和特徵），並使用令牌分類來識別它們，從而提取特定的客戶需求，從而添加到 Needmining 文獻中。反之亦然，對令牌分類文獻的技術貢獻是，我們測試了最先進的語言模型驅動的令牌分類的能力，以解決抽象概念，例如客戶需求。為了實現這一目標，工件由圖 3 所示的五個步驟組成，即內容採樣、句子標記化、標記嵌入、標記分類和需求提取。輸入是精心挑選的 UGC 樣本，在本例中為客戶評論。在執行標記分類（工件最重要的步驟）之前，句子標記化和標記嵌入的變革步驟是必要的。它會自動識別屬性和特徵，這些屬性和特徵結合成完整的客戶需求。在最後一步中，主要有助於分類內容的可用性，我們有意義地組織決策者的需求，以便快速了解所有相關信息，本質上為管理人員提供了一個決策支持系統。

4.4. 訓練

訓練令牌分類器需要一個經過適當註釋的文本數據集。在我們的問題理解的指導下，我們將客戶評論確定為產品開發人員最相關的消費者需求來源。亞馬遜作為全球領先的電子商務平台之一，是涵蓋多種產品類別的大量消費者評論的絕佳來源。在與領域專家的一致意見下，我們選擇了第二代“Apple AirPods”作為產品來訓練和測試該工件。截至今天，第二代 Apple AirPods 在亞馬遜上累積了超過 400,000 條產品評論。在 2019 年 11 月期間，我們根據亞馬遜的使用條款抓取了 1036 條最新的產品評論。我們付錢給一群學生工作者來註釋評論。學生們根據文獻輕描淡寫地了解了這個問題。這確保了他們充分理解本文的整體問題以及我們如何將客戶需求理解為屬性和特徵。有了這些知識，每個標記者都會收到一組完整的客戶評論。我們分析了 1036 條評論，包含 3059 個句子，圖 4 顯示了屬性和特徵的分佈。有

¹ <https://www.nltk.org/>




圖 3.工件概述。




圖 4.句子中的代幣分佈。

有 1438 個句子包含至少一個註釋，而 1621 個句子沒有註釋。雖然需要句子和不需要句子是平衡的，但數據中總體上特徵多於屬性。有些句子識別了相關特徵，但缺乏附加屬性，可能指的是產品一般或僅包含描述性詞語，例如“它們很好地留在耳朵裡”或“輕巧舒適”。表 1 概述了已識別的標記如何在類別中組成，即單個跨度中有多少個單詞，以及類別如何分佈到句子中，即

句子中出現多少個屬性和特徵。平均而言，註釋為屬性的記號包含的單字比標註為特徵的記號少。此外，句子通常包含比屬性更多的特徵。

5. 模型評估

對我們方法的評估由幾個部分組成。首先，我們根據常用指標呈現性能，以量化模型正確識別客戶需求相關方面的能力。這使得它與未來的研究具有可比性，並為字級 Needmining 模型創建了基線。其次，我們討論了我們對文獻的貢獻，並討論了模型輸出的一些一般方面。最後，我們詳細闡述了如何使用模型的輸出來指導決策者。這需要展示原始模型輸出，並提出使用相關資訊（例如頻率和情緒）進一步豐富資料的想法，以突出重要需求。最後，我們討論了一些基於 Timoshenko 和 Hauser (2019) [5] 二進位的實證評估的現實效率影響

表 1
句子組成的描述性統計。

班	平	問 25	問 50	問 75	最大值	部
屬性	每個跨度的權杖	1	1	2	9	1.51
	句子中的跨度	0	0	1	4	0.41
特徵	每個跨度的權杖	1	2	2	12	2.03
	句子中的跨度	0	0	1	5	0.59

s (2019) [5] 二進位需求挖礦的實證評估。

5.1. 分類器效能

我們根據 k 折交叉驗證 ($k = 5$) 評估分類器，這是隨機化所有採樣資料，然後將其拆分為 k 個大小相等的子集的過程。然後，我們訓練 k 個模型，每個模型都基於由 $k-1$ 子集組成的訓練集，並使用剩餘的子集作為測試集。這避免了在資料的訓練/測試分割過程中因隨機機會而導致的過於樂觀的效能輸出 [45]。最終分數是所有 k 個模型之間的平均效能指標。

我們使用的測量是經典混淆矩陣產生的典型指標，即我們在真陽性 (TP)、真陰性 (TN)、假陽性 (FP) 和假陰性 (FN) 的範圍內區分每個分類。表 2 給出了常用指標召回率、精確度和 F1 分數的數學表示 [46,47]。精確度是正確識別的陽性 (TP) 樣本與樣本內所有陽性案例 (TP+ FP) 之間的比率。召回率衡量樣本 (TP + FN) 中模型能夠正確識別 (TP) 的陽性案例數量 [47]。最後，F1 分數是精度和召回率的諧波平均值 [48]。

Needmining 旨在從大量使用者產生的內容中擷取消費者需求，以提高產品開發人員在處理使用者產生內容時的效率。在訓練和測試環境中，我們有興趣正確識別盡可能多的正面案例。然而，如果只有一小部分已識別案例反映了專家標記者所識別的實際需求，則其對效率的影響就會減少，因為開發人員將不得不審查許多非實際需求的案例。這種效果是透過精確度來衡量的。同樣地，工件應該盡可能多地找到專家標記者所識別的需求，以反映專家標記者提供的資訊。如果召回率較低，則模型會遺漏許多專家先前確定為相關的需求。鑑於 F1 分數是精確度和召回率之間的調和平均值，它將這兩個指標組合成一個測量值，從產品開發人員的角度反映了模型整體成功的兩個重要因素。由於本質上沒有簡單的方法來掌握 F1 分數的含義，因此我們始終包括各個分數以提高準確性和回憶性。所有報告的指標都介於 0 到 1 之間，分數越接近 1 越好。

這項研究的目標不是為新一代語言模型創建一種自下而上的方法，而是使用現有的框架來展示代幣分類如何在單詞層面為 Needmining 提供新的見解和可能性。因此，我們使用流行且眾所周知的 Spacy 框架來訓練一個模型，用於命名實體識別，從而採用已經實現的、開源的、開箱即用」的基礎設施來提供概念驗證。為了使訓練過程盡可能簡單，我們將優化器調整為與 spacy 框架提供的建議相等。這意味著從 0.00005 的學習率開始，有 20,000 個預熱步驟。優化器是 Adam.v1 的實現，beta 為 0.9，beta2 為 0.999，L2 權重衰減為 0.01，從 0.01 開始。由於我們的主要重點是優化 F1 分數，因此 F1 的指標重要性權重設置為 1，準確性和召回率設置為 0。

可以在評論級別（即訓練數據是完全註釋的產品評論）或句子級別訓練此模型類型

我們首先將每篇評論分成單獨的句子。我們測試了這兩種方法，發現對句子進行訓練可以帶來更好的結果。因此，我們報告了對評論的單個句子進行訓練的模型的性能。在訓練過程中，我們採用了基於摘要模型的 F1 分數的提前停止演算法。在訓練過程中，訓練過程每兩百個訓練步驟計算一次該指標。與將每個模型訓練一段時間（這將更加耗費資源和時間）不同，一旦模型在一定次數的迭代中沒有改進，提前停止就會自動退出訓練過程。我們將這種所謂的提前停止耐心設定為 1600 步，即模型一旦循環 1600 步，就會停止訓練，而不會提高 F1 分數。平均而言，折疊訓練了 183 個紀元。

表 3 顯示了所有實體的所有 k 折的平均效能以及基於預先訓練的 Transformer 模型產生的不同嵌入的「屬性」和「特徵」標記類別。RoBERTa 表現最佳，所有實體的 F1 分數為 71.2%，屬性的平均 F1 分數為 79.22%，特徵的平均 F1 分數為 67.28%。雖然 BERT 在特徵類別中比 RoBERTa 略有優勢，但我們發現大多數基於 Transformer 的嵌入表現相似。

此外，我們還透過抓取和註釋「嬰兒」、「寵物」和「運動」產品類別中的 500 個句子來測試標記分類器的泛化能力。我們測試了這些，因為它們與 AirPod 評論有關的訓練資料有很大不同。表 4 總結了我們泛化測試的結果。它顯示了三個不同的指標，每個指標都與不同的等級相關。使用這些等級背後的基本原理是，權杖分類器是一種針對註釋和模型預測之間的精確匹配傳回真陽性的方法。然而，該模型通常會識別個人需求，而不是註釋指定的確切單字範圍，從而導致誤報。因此，我們引入了一種新的效能指標來衡量標記重疊。我們進一步引入了指標句子匹配，將我們的模型與現有的二進位 Needmining 模型進行比較。從結果來看，我們可以看到各個層次之間的差異相當大。對於運動類別，我們在精確匹配級別上獲得了 49.11% 的 F1 分數，而在句子匹配級別上獲得了 77.03% 的 F1 分數。在其他類別中也可以觀察到類似的模式。總體而言，這些數字表明我們的模型泛化良好，並且優於現有的二元方法。

5.2. 討論

我們將 Needmining 方法從二元分類問題重新概念化為代幣分類問題，並成功創建了一個從 UGC 中提取產品屬性和特徵的工件。表 4 顯示了該工件如何通過成功為識別 UGC 中特定客戶需求的問題提供解決方案，為 Needmining 文獻做出貢獻。我們的代幣分類模型識別了 UGC 中代表需求的特定代幣。因此，我們可以將特定需求提取為屬性特徵組合。此外，通過刪除沒有任何識別屬性和特徵的所有內容，工件還能夠將 UGC 的整體主體簡化為其信息豐富的內容，從而有效地與現有的 Needmining 方法競爭。

在接下來的段落中，我們將詳細研究我們的工件的輸出，並討論其性能、如何呈現我們的工件產生的信息的問題，以及我們的工件的經濟影響和效率增益。

5.3. 需要識別

最好的模型達到了 72.06% 的交叉驗證 F1 分數，使其性能可與二進位 Needmining 模型相媲美，同時解決本質上更複雜的任務。它能夠正確標記屬性和特徵的很大一部分。然而，它在識別屬性方面表現更好，這些屬性通常較短，

表 2
相關效能指標。

精密	— 目標值 TP + FP	正確識別為正數的所有正值百分比
召回	— 目標值 TP + FN	模型發現的專家確定的所有需求的百分比
F1 分數	2·精確度·召回率 + 召回率	精確度與召回率之間的諧波平均數

表 3
權杖分類器透過內嵌交叉驗證效能。

		所有實體			屬性			特性		
嵌入	羅伯塔	精密	召回	F1	精密	召回	F1	精密	召回	F1
		72.2%	70.2%	71.2%	79.7%	77.7%	78.7%	67.2%	65.3%	66.2%
	伯特	72%	69.8%	70.8%	79.3%	76%	77.5%	67.2%	65.7%	66.4%
	XLNet	71%	70.4%	70.7%	77.4%	78.2%	77.8%	66.6%	65.3%	65.9%
	阿爾伯特	69.8%	69.8%	69.8%	77.9%	76.2%	77%	64.5%	65.6%	65%
	蒸餾 BERT	71.7%	67.5%	69.5%	79%	74.2%	76.4%	66.9%	63.1%	64.9%

表 4
根據效能層級的記號分類器效能（以百分比表示）。

		嬰兒			寵物			運動的		
平	句子匹配	精密	召回	F1	精密	召回	F1	精密	召回	F1
		69.75	92.62	79.58	68.53	71.01	69.75	67.7	89.34	77.03
	權杖重疊	66.67	79.14	72.37	62.41	54.19	58.01	64.11	74.11	68.75
	完全匹配	42.6	52.36	46.98	34.86	31.13	32.89	44.84	54.29	49.11

平均長度為 1.5 個單詞，而特徵的平均長度為兩個單詞。特徵可能更複雜，可能由多個語義上可能無法連結在一起的標記組成，例如範例「留在披薩上」。這種複雜性增加了正確識別標記的難度，因為只有完全正確的跨度才會計入真陽性測量。即使缺少部分令牌也會對所有效能指標產生負面影響，從而導致誤報。

當利用 AirPods 訓練模型來預測泛化任務中的需求時，這一挑戰尤其明顯。精確匹配功能在「嬰兒」、「寵物」和「運動」類別中產生的平均 F1 分數僅為 42.99%。然而，重疊性能識別了對產品開發人員仍然具有資訊量的略有不同的跨度，仍然具有競爭力，跨類別的平均 F1 分數為 66.37%。微調應該能夠輕鬆地將該指標提升到 70% 以上的閾值。最後，與二進位 Needmining 相比，我們模型的泛化性達到了 75.45% 的性能，使其與專門從事二進位 Needmining 的模型相當 [22,49]。

權杖分類器的輸出是所有句子的清單，包括已識別的跨度及其預測類別。在我們的範例中，AirPods 資料中有 303 個唯一措辭的屬性。不過，唯一措辭屬性的數量並不代表屬性的實際數量。UGC 的自由文字性質可讓客戶使用不同的措辭來表達相同的資訊。例如，一個經常提及的屬性是「降噪」，但除了「消除雜訊」和「降噪」等替代拼字之外，分類器還正確識別「降噪」和「降噪功能」等措辭。這是分析 UGC 時的常見主題。若要進一步處理屬性和

識別出我們的工件的特徵，產品開發人員可以使用聚類演算法對語義相關的標記進行分組。這將顯著減少要分析的屬性數量，並且還可能突出與不太常提及的屬性相關的需求。應用預處理步驟，例如停用詞刪除、詞幹提取和詞形還原 [50]，甚至可以進一步提高生成的叢集品質。

5.4. 資訊組織

一旦從我們的工件中獲得最終結果，產品開發人員就需要決定如何組織可用資訊。雖然沒有本質上正確的數據呈現方式，但有不同的方法可以幫助決策者解決與 Needmining 相關的問題。

在圖 5 中，我們提出了一種使用顏色代碼評論來組織信息的方法。僅呈現模型檢測到需求的句子可以發揮二元分類模型的作用，而顏色編碼則增強了評論的可讀性，這有助於提高手動提取需求的效率。我們的成品提供的另一個選項是根據屬性和屬性的相關特徵產生產品的描述。這為產品開發人員提供了相關屬性的明確清單、每個屬性在評論中出現的頻率，以及客戶可能對個別屬性的體驗（以特徵總和表示）。

這種屬性摘要可以通過使用情感分析來進一步增強 [24,28]。情感分析是一個有用的工具，可以在評估產品開發人員時為產品開發人員提供額外信息。




圖 5.屬性「配對」的顏色編碼評論的偽影輸出。

探索到的需求。這讓他們深入了解客戶對某個屬性的正面或負面感受，據此他們可以進一步調查未來發展的潛在需求。對於未來的開發，對某個屬性的正面情緒表明，該產品的未來迭代應該繼續採用客戶喜歡的屬性特徵組合。相反地，對某個屬性的負面情緒表示有改進的空間，即使不是完全缺乏預期的功能。

為了在我們的環境中採用情緒分析，我們為每個提及屬性的句子都加上正面或負面標籤。然後，我們收集每個屬性的正面和負面標籤的總和，以確定效價分數，該分數反映了正面情緒與負面情緒的相對數量。圖 6 顯示了整個評論中提及最多的 25 個屬性的正面和負面提及的相對比例，範圍從 -1 到 1，其中 1 表示完全負面的情緒，其中 100% 的評論是負面的，-1 表示完全正面的情緒，所有評論都是正面的。

除了提及沒有相關屬性的特徵（“產品”）的評論句子外，正面情緒最少的屬性是“案例”。在仔細檢查與“案例”屬性相關的負面評論後，我們能夠確定與該案例的無線充電支持相關的客戶需求。在與外殼相關的特徵中，我們發現“不兼容無線充電”和“不兼容無線充電”這兩個特徵。在這裡，重要的是要認識到第二代 AirPods 根本沒有這個功能。然而，通過將我們的工件應用於產品評論，我們能夠將其識別為潛在相關的客戶需求。回想一下，我們在 2019 年 11 月抓取了數據，遠早於 2021 年 10 月發布的新款 AirPods，而新款 AirPods 實際上支持此功能。

5.5. 經濟影響和效率提升

識別所提議工件的現實生活中的經濟範例很複雜，因為它需要大量產品開發流程的知識。然而，我們能夠證明我們的工件可以為原本手動執行的任務提供實質性支援。假設手動處理評論平均需要 25 秒，這意味著我們的工件每 1000 條評論可以節省近 7 小時的體力勞動。意識到如前所述，流行的產品通常有數十萬條評論，我們相信我們的工件可以顯著提高生產力。雖然我們的 Needmining 工件需要根據註釋資料進行訓練，但這只需要完成一次。訓練後

我們的工件可以一遍又一遍地預測客戶對其他用戶生成內容集的特定需求，只需更改輸入模型的樣本即可。此外，它還量化了需求的發生，從而為產品經理提供與客戶最相關的決策支持。只需很少的額外努力，我們的工件還可以提取其他信息，例如評論的平均情緒。這可以概述客戶如何看待產品的某些方面，這對於識別市場目前未滿足的具有創新潛力的需求非常有用。

與其他 Needmining 方法的主要區別在於，我們直接提取需求成分，而不是識別句子或評論中是否存在需求。與其他方法相比，單詞級 Needmining 可能只需要根據具體情況對內容進行全面審查。在二進制 Needmining 中，每個已識別的句子仍必須手動審查。單詞級 Needmining 減少了這項工作，因為它會自動量化需求，並允許專家根據我們的模型識別的需求輕鬆訪問句子。

6. 局限性和未來研究

當然，我們的研究受到一些限制。首先，目前的方法沒有總結相似或密切相關的屬性。這導致頻率識別的前三個屬性中有兩個是「聲音」和「音質」。未來，我們計劃透過對它們的嵌入進行聚類並將所有相關特徵組合成屬性來總結這些。此步驟允許產品開發人員透過減少冗餘資訊來節省更多時間。

其次，工件僅識別句子中出現的所有屬性和特徵。如果一個句子包含多個屬性，則目前的解決方案是將所有特徵附加到句子中的所有屬性上，從而無法將特徵與正確的屬性完全匹配。雖然這種方法仍然提供了相關屬性特徵匹配的概述，但僅基於特徵在給定屬性上下文中出現的總量，未來我們計劃使用句子中的詞性標記來完善屬性特徵匹配的準確性。

最後，應該注意的是，並非所有評論都是純文字。許多評論平台，包括亞馬遜的產品評論部分，讓客戶有機會附加某些元數據，例如星級或有用性評級。我們相信，從已識別的屬性和屬性特徵對到元數據的因果推斷可以為產品開發人員提供有用的信息。例如，知道產品的某些屬性會持續將評論的星級降低給定的數量，這可能表明產品開發人員應該




圖 6.25 個最常被提及的屬性的情緒。

在未來的產品中關注此屬性，以提高產品的整體性能，特別是考慮到產品評論對客戶的購買決策有多麼重要。

7. 結論

這項研究是第一個將 Needmining 從二元分類重新概念化為標記分類任務的研究。我們將需求概念分解為代表需求的兩個組成部分。屬性是客户討論的產品中的“什麼”，特徵是客户談論該屬性的“方式”。例如，句子“The crust was too doughy”包含一個可以用屬性“crust”和特徵“too doughy”來表示的需求。我們構建了一個工件，可以準確識別 UGC 中的相關代幣，並根據確定的需求組件對其進行分類。擴展而言，相同的方法還可以根據需求內容（是、否）對 UGC 進行二元分類，將具有已識別標記的句子視為信息性，而沒有識別標記的句子則視為無信息性，從而有效地與先前的 Needmining 模型競爭。這在三個方面為知識庫做出了貢獻。首先，它提供了一種方法來解決先前研究中發現的研究差距，即精確識別客户需求需要額外的自動化。其次，工件本身是標記分類的一種新穎且創新的用途，用於解決以前未解決的問題。第三，我們將需求的抽象概念拆分為屬性和特徵的更明確的子部分。到目前為止，目前的研究大多使用標記分類來對簡單的概念進行分類，例如詞性標籤和實體（位置、人物等）。生物醫學研究透過識別特定於其文獻的實體，發現了該概念在他們自己的領域中的新用途。我們展示了這種方法的其他用法，人們可以分解抽象概念，例如需求，然後使用標記分類來識別非結構化文字資料中產生的組件。

CRediT 作者貢獻聲明

奧利弗·埃特里希：概念化、方法論、寫作—原稿、軟體、驗證、形式分析、調查、寫作—審查和編輯、視覺化。斯文·斯塔爾曼：概念化、方法論、軟體、資源、調查、資料管理、寫作—審查和編輯、視覺化。亨里克·利奧波德：寫作—審查和編輯。克里斯蒂安·巴羅特：寫作—審查和編輯。

競爭利益聲明

作者聲明，他們沒有已知的競爭性經濟利益或個人關係，這些利益或個人關係似乎會影響本文報告的工作。

數據可用性

數據將根據要求提供。

鳴謝

該研究項目由德國研究基金會（DFG）資助 - FOR 1452 / TP1 SCHO 1321/3-2。

參考

- [1] Y. Liu, C. Jiang, H. Zhao, 評估產品競爭優勢
通過在社交媒體上挖掘用戶生成的內容來了解客戶的觀點，Decis. 撐。系統 123 (2019), 113079, <https://doi.org/10.1016/j.dss.2019.113079>。
[2] Y. Yu, W. Duan, Q. Cao, 社會和傳統媒體對公司的影響
股權價值：一種情緒分析方法，Decis. 撐。系統 55 (2013) 919–926, <https://doi.org/10.1016/j.dss.2012.12.028>。

- [3] N. Bashir, KN Papamichail, K. Malik, 社交媒體應用程序的使用
支持跨國公司的新產品開發流程，技術。張。120 (2017) 176–183, <https://doi.org/10.1016/j.技術報.2017.02.028>。
[4] N. Kuehl, J. Scheurenbrand, G. Satzger, Needmining：識別微博數據
2016 年過制客戶需求，ECIS, 2016 年。https://aisel.aisnet.org/ecis2016_rp/185。
[5] A. Timoshenko, J.R. Hauser, 從用戶生成的客戶需求中識別客戶需求
內容，馬克。科學 38 (2019) 1–20, <https://doi.org/10.1287/mksc.2018.1123>。
[6] 張明、范伯、張恩、王偉、范偉，礦業產品創新思路
來自在線評論，Inf. 管理。58 (2021), 102389, <https://doi.org/10.1016/j.ipm.2020.102389>。
[7] K. Christensen, S. Nørskov, L. Frederiksen, J. Scholderer, 尋找新產品
想法：通過機器學習和文本挖掘識別在線社區中的想法，創造力和創新，管理。26 (2017) 17–30, <https://doi.org/10.1111/caim.12202>。
[8] N. Kühl, M. Mühlthaler, M. Goutier, 支持以客戶為導向的營銷
人工智慧：自動量化來自社群媒體的客戶需求，Electr. 標。30 (2020) 351–367, <https://doi.org/10.1007/s12525-019-00351-0>。[9] AR Hevner, ST March, J. Park, S. Ram, 信息系統研究中的設計科學，MIS Q. 28 (2004) 75–105, <https://doi.org/10.2307/25148625>。
[10] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A.N. Gomez, 皇帝
I. Polosukhin, 注意力就是你所需要的，Adv. Neural Inf. Proces. 系統 30 (2017), 收錄於：
https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee919d55c1c484588f4c0.pdf。
[11] J. Devlin, M. Chang, K. Toutanova, BERT：深度預訓練
用於語言理解的雙向轉換器，載於：計算語言學協會北美分會 2019 年會議論文集：人類語言技術，計算語言學協會，明尼蘇達州明尼阿波利斯，2019 年，第 4171–4186 頁，<https://doi.org/10.18653/v1/N19-1423>。
[12] A. Talmor, Y. Elazar, Y. Goldberg, J. Berant, oLMpics-關於什麼語言模型
預訓練捕獲，計算語言學協會彙刊 8.2020 年，第 743–758 頁，https://doi.org/10.1162/tacl_a_00342。
[13] A. Griffin, J.R. Hauser, 客戶的聲音，馬克。科學 12 (1993) 1–27。[14] J. Arndt, 營銷概念應該有多廣泛？它應該發展成一門成熟的行為科學嗎？J. 馬克。42 (1978) 101–103。[15] P. Kotler, G. Armstrong, J. Saunders, V. Wong, Principles of marketing, 收錄於：
企業通訊：國際期刊，第 2 版 6.2001 年，第 164–165 頁，<https://doi.org/10.1108/ccij.2001.6.3.164.1>。
[16] P. Kotler, KL Keller, M. Brady, M. Goodman, T. Hansen, 營銷管理，第 4 版，歐洲版，Pearson, Harlow, 英格蘭，2019 年。[17] MB Line, 定義草案：信息和圖書館需求、需求、需求和用途，美聯社 26.1974 年，第 87 頁，<https://doi.org/10.1108/eb050451>。[18] V. Krishnan, KT Ulrich, 產品開發決策：文獻綜述，Manag. 科學 47 (2001) 1–21。[19] DS Kim, RA Bailey, N. Hardt, GM Allenby, 基於收益的聯合分析，馬克。科學 36 (2017) 54–69, <https://doi.org/10.1287/mksc.2016.1003>。[20] F. Liu, K.-H. Lai, J. Wu, W. Duan, 聆聽在線評論：共享經濟中客戶體驗的混合方法調查，Decis. 撐。系統。149 (2021), 113609, <https://doi.org/10.1016/j.dss.2021.113609>。
[21] J. Ma, Y. Lu, S. Gupta, 用戶創新評估：來自
在線遊戲社區，Decis. 撐。系統 117 (2019) 113–123, <https://doi.org/10.1016/j.dss.2018.11.003>。
[22] S. Stahlmann, O. Etrrich, D. Schoder, 深度學習支援消費者研究
2022 年產品開發，ECIS, 2022 年。https://aisel.aisnet.org/ecis2022_rp/19。
[23] N. Kühl, M. Goutier, A. Ensslen, P. Jochem, 文學與推特：實證
對電動汽車客戶需求的見解，J. Clean. 產品 213 (2019) 508–520, <https://doi.org/10.1016/j.jclepro.2018.12.003>。
[24] M. Hu, B. Liu, 挖掘和總結客戶評論，載於：會議記錄
第十屆 ACM SIGKDD 知識發現和數據挖掘國際會議，計算機協會，美國紐約州紐約，2004 年，第 168–177 頁，<https://doi.org/10.1145/1014052.1014073>。
[25] T. Roelen-Blasberg, J. Habel, M. Klarmann, 乘積的自動推理
用戶生成內容的屬性及其重要性：我們可以取代傳統的市場研究嗎？國際 J. Res. 馬克。40 (2023) 164–188, <https://doi.org/10.1016/j.ijresmar.2022.04.004>。
[26] T.Y. Lee, E.T. Bradlow, Automated marketing research using online customer reviews, J. Mark. 決議 48 (2011) 881–894。[27] X. Wang, J. He, D.J. Curry, J.H. Ryoo, 屬性嵌入：分層學習
消費者評論中產品屬性的表示，J. Mark. 86 (2022) 155–175, <https://doi.org/10.1177/00222429211047822>。
[28] F. Misopoulos, M. Mitic, A. Kapoulas, C. Karapiperis, 揭示客戶服務
Twitter 的經驗：航空業的案例，Manag. 德西斯。52 (2014) 705–723, <https://doi.org/10.1108/MD-03-2012-0235>。
[29] E. von Hippel, S. Kaulartz, 下一代消費者創新搜索：
識別網絡上的早期需求-解決方案對，Res. Policy 50 (2021), 104056, <https://doi.org/10.1016/j.respol.2020.104056>。
[30] DM Blei, AY Ng, MI Jordan, 潛在狄利克雷分配，J. Mach. 第 3 號決議 (2003) 993–1022。[31] JJ Webster, C. Kit, 標記化作為 NLP 的初始階段，載於：Proceedings of
第 14 屆計算語言學會議 - 第 4 卷，美國計算語言學協會，1992 年，第 1106–1110 頁，<https://doi.org/10.3115/992424.992434>。

- [32] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, V. Stoyanov, Roberta: 穩健優化的 bert 預訓練方法, 收錄於: ArXiv 預印本 ArXiv: 1907.11692, 2019 年。
- [33] D. Nadeau, S. Sekine, 命名實體識別和分類調查, 語言學調查. 30 (2007) 3–26, <https://doi.org/10.1075/li.30.1.03nad>。
- [34] J. Li, A. Sun, J. Han, C. Li, 用於命名實體識別的深度學習調查, IEEE Trans. 知識. 數據工程 34 (2022) 50–70, <https://doi.org/10.1109/TKDE.2020.2981314>。
- [35] V. Yadav, S. Bethard, 關於命名實體識別最新進展的調查
來自深度學習模型, 載於: 第 27 屆國際計算語言學會議論文集, 計算語言學協會, 美國新墨西哥州聖達菲, 2018 年, 第 2145–2158 頁。 <https://aclanthology.org/C18-1182>。
- 訪問日期: 2023 年 5 月 15 日。
- [36] A. Ritter, S. Clark, M. Mausam, O. Etzioni, 推文中的命名實體識別: 一個實驗研究, 載於: 2011 年自然語言處理實體方法會議論文集, 計算語言學協會, 英國蘇格蘭愛丁堡, 2011 年, 第 1524–1534 頁。 <https://aclanthology.org/D11-1141>。
- 訪問日期: 2023 年 5 月 15 日。
- [37] Y. Song, S. Upadhyay, H. Peng, S. Mayhew, D. Roth, Towards any-language zero-text document classification, Artif. 情報. 274 (2019) 133–150, <https://doi.org/10.1016/j.artint.2019.02.002>。
- [38] L. Weber, M. S'anger, J. Münchmeyer, M. Habibi, U. Leser, A. Akbik, HunFlair: 易於使用的工具, 用於最先進的生物醫學命名實體識別、生物信息學。37 (2021) 2792–2794, <https://doi.org/10.1093/bioinformatics/ctab042>。
- [39] A. Goyal, V. Gupta, M. Kumar, 最近命名的實體識別和分類
技術: 系統評價, Comp. Sci. Rev. 29 (2018) 21–43, <https://doi.org/10.1016/j.cosrev.2018.06.001>。
- [40] B. Kuechler, V. Vaishnavi, 關於設計科學研究的理論發展:
研究項目的解剖學, Eur. J. Inf. Syst. 17 (2008) 489–504, <https://doi.org/10.1057/EJIS.2008.40>。
- [41] J. 圖里安, 洛杉磯 Ratino, Y. Bengio, 單詞表示: 簡單而通用
半監督學習方法, 載於: 計算語言學協會第 48 屆年會論文集, 計算語言學協會, 瑞典烏普薩拉, 2010 年, 第 384–394 頁。 <https://aclanthology.org/P10-1040>。訪問日期: 2023 年 5 月 15 日。
- [42] Z. Yang, Z. Dai, Y. Yang, J. Carbonell, R. Salakhutdinov, Q.V. Le, XLNet: 語言理解的廣義自回歸預訓練, 2020 年, <https://doi.org/10.48550/arXiv.1906.08237>。
- [43] Z. Lan, M. Chen, S. Goodman, K. Gimpel, P. Sharma, R. Soricut, ALBERT: 用於語言表示自監督學習的精簡 BERT, 載於: https://iclr.cc/virtual_2020/poster_H1eA7AEtvS.html, 2020 年。
- [44] V. Sanh, L. Debut, J. Chaumond, T. Wolf, DistilBERT, BERT 的蒸餾版本: 更小、更快、更便宜、更輕, 2020 年, <https://doi.org/10.48550/arXiv.1910.01108>。
- [45] G.C. Cawley, N.L. Talbot, 關於模型選擇中的過度擬合及其後續
績效評估中的選擇偏差, J. Mach. 第 11 號決議 (2010) 2079–2107。
- [46] M. Egger, A. Lang, D. Schoder, 《我們在聽誰? 檢測用戶生成的網絡上的內容 (UGC)》, ECIS 2015 年完成的研究論文, 2015 年, <https://doi.org/10.18151/7217308>。
- [47] C.D. Manning, P. Raghavan, H. Schütze, 《資訊檢索導論》, 劍橋大學出版社, 紐約, 2008 年。[48] D. Chicco, G. Jurman, 馬修斯相關係數的優點
(MCC) 超過二元分類評估的 F1 分數和準確性, BMC 基因組學 21 (2020) 6, <https://doi.org/10.1186/s12864-019-6413-7>。
- [49] S. Stahlmann, O. Ettrich, M. Kurka, D. Schoder, 客戶對我的貨? 用於需求識別的機器學習模型基準測試, 載於: 第 56 屆夏威夷國際系統科學會議論文集, 夏威夷國際系統科學會議, 2023 年。
- [50] J. Hartmann, J. Huppertz, C. Schamp, M. Heitmann, 比較自動文本分類方法, Int. J. Res. Mark. 36 (2019) 20–38, <https://doi.org/10.1016/j.ijresmar.2018.09.009>。

奧利弗·埃特里希 (Oliver Ettrich) 是漢堡庫恩物流大學的博士生。他的研究重點是利用用戶生成的內容來開發消費者驅動的創新和產品開發。他的作品已在歐洲信息系統會議和夏威夷國際系統科學會議上發表。

Sven Stahlmann 是科隆大學科隆信息系統研究所的博士生。他的研究興趣集中在數據驅動的產品開發以及從大規模文本數據中獲得見解。他的作品發表在歐洲信息系統會議、ACM 文檔工程研討會和夏威夷國際系統科學會議等上。

Henrik Leopold 是庫內物流大學 (KLU) 的副教授, 也是波茨坦大學數字工程學院哈索普拉特納研究所 (HPI) 的高級研究員。他在德國柏林洪堡大學獲得信息系統博士學位。在加入 KLU/HPI 之前, Henrik 曾在阿姆斯特丹自由大學和維也納 WU 任職。他的研究主要涉及利用人工智能來分析和改進業務流程。他在 IEEE Transactions on Software Engineering、Decision Support Systems 和 Information Systems 上發表了 100 多篇科學貢獻。他的博士論文因戰略信息管理領域的最佳論文而獲得德國 Targion 獎。

Christian Barrot 是漢堡庫內物流大學 (KLU) 的行銷與創新教授。他的研究興趣包括創新的傳播、社交網路以及用戶生成內容的影響等主題。他曾在《行銷雜誌》、《國際行銷研究雜誌》、《服務研究雜誌》、《商業道德雜誌》、《國際電子商務雜誌》和 ICIS 論文集等雜誌上發表過文章。他的工作獲得了著名的認可, 例如 2018 年 Sheth/行銷雜誌獎。他還擔任 DFG 研究小組 1452“社交媒體如何改變營銷”的首席研究員, 以及德國研究基金會、瑞士國家科學基金會和以色列科學基金會的審稿人。